

L'arbre de la recherche d'alphas

Traité de recherche quantitative — equity cross-sectionnel & crypto

Anthony Bordier

Version de travail du 24 juillet 2026

chiffres et attributions non vérifiés — passe de vérification à venir

Contents

I	Cadre et conventions	3
1	0. Cadre et conventions	4
1.1	0.1 Le panel et ses deux axes	4
1.2	0.2 La définition de l'alpha	5
1.3	0.3 Mesurer le pouvoir prédictif : IC et ICIR	5
1.4	0.4 Breadth et loi fondamentale	6
1.5	0.5 Notations	7
1.6	0.6 Conventions de calcul	7
1.7	0.7 La relativité de la frontière alpha / beta	8
1.8	0.8 Plan et mode de lecture	8
II	Recherche du signal	9
2	§1.1 Familles d'alphas	10
3	§1.2 Feature engineering	14
4	§1.3 Normalisation	22
5	§1.4 Cibles & labels	26
6	§2.1 Métriques du signal	29
7	§2.2 Backtest cross-sectionnel	32
8	§2.3 Anti-overfitting	35
9	§2.4 Non-stationnarité & régimes	38
10	§3.1 Pondérations simples	41
11	§3.2 Régression régularisée	45
12	§3.3 Stacking & méta-modèles	48
13	§3.4 Orthogonalisation & gestion du pool	51
14	§3.4.5 Combinaison sous coûts — l'interface	54
III	Mise en œuvre	55
15	§4.1 Modèles de risque	56

<i>CONTENTS</i>	2
16 §4.2 Construction de portefeuille	59
17 §4.3 Coûts dans l'optimisation	62
18 §4.4 Sizing & levier	65
19 §4.5 Gestion des risques	68
20 §5.1 Microstructure	71
21 §5.2 Impact de marché	74
22 §5.3 Scheduling	77
23 §5.4 Tactique & alphas d'exécution	80
24 §5.5 Transaction cost analysis	83
25 §6.1 Données	86
26 §6.2 Moteur de backtest	88
27 §6.3 Production	90
28 §6.4 Organisation	92
 IV Encadrés transversaux	 94
29 Encadré A — Le shrinkage, un théorème sous huit habits	95
30 Encadré B — Croissance & survie	97
31 Encadré C — La sélection adverse, quatre technologies	99
32 Encadré D — Le chevauchement & Newey-West	101
33 Encadré E — La surveillance séquentielle	103
 V Annexes	 105
34 Annexe — Table des notations	106
34.1 Symboles	106
34.2 Collisions interdites (règles dures)	107
34.3 Conventions de calcul associées (rappel §0.6)	107

Part I

Cadre et conventions

Chapter 1

0. Cadre et conventions

Préambule au squelette gelé. Cette section pose les objets, les axes, les métriques et les notations que les six branches suivantes tiennent pour acquis.

1.1 0.1 Le panel et ses deux axes

Toute la recherche d'alphas opère sur un **panel** : une matrice dont les lignes sont les actifs — indexés par $i \in \{1, \dots, N\}$ — et les colonnes les dates, indexées par $t \in \{1, \dots, T\}$. Chaque cellule contient les observations disponibles pour l'actif i à la date t : prix, volume, fondamentaux, flux, métriques on-chain. Cette matrice est l'unique matière première ; toutes les décisions méthodologiques qui suivent découlent de la façon dont on la découpe.

La coupe cross-sectionnelle est une colonne : une date fixée, tous les actifs comparés entre eux. Elle pose la question « parmi les N actifs d'aujourd'hui, lesquels vont surperformer les autres sur les h prochaines périodes ? ». C'est une question de *classement relatif*, jamais de niveau : un signal cross-sectionnel est indifférent à la direction du marché — si tous les actifs montent de 5%, seul compte l'ordre dans lequel ils montent. Cette propriété n'est pas un accident, elle est construite : la standardisation par date (§1.3.1) démoymenne le signal à travers les actifs, ce qui annule la position nette et élimine le facteur commun — la source de variance dominante — *avant* toute estimation. On ne prédit que le résidu, là où le ratio signal/bruit est le plus favorable.

La coupe time-series est une ligne : un actif, son histoire. La question devient « cet instrument va-t-il monter ou baisser ? » — une question de niveau, qui autorise l'exposition nette directionnelle et le levier variable. C'est le cadre des CTA, du trend-following, du carry par instrument, et le seul disponible lorsque l'univers est trop étroit pour offrir un cross-section (un desk sur quelques contrats futures liquides).

Les deux régimes ne sont pas concurrents mais orthogonaux, et un book complet fait tourner les deux en parallèle : sleeves cross-sectionnels pour l'alpha relatif, sleeves time-series pour le timing directionnel, la normalisation (§1.3) étant ce qui permet de les faire cohabiter dans une même combinaison. Un même jeu de données produit des signaux différents selon l'axe : un signal qui bouge identiquement pour tous les actifs est nul en cross-section (le démoymennage l'efface) et peut être excellent en time-series ; un signal constant dans le temps est nul en time-series et peut être excellent en cross-section.

Le prisme dominant de cet ouvrage est cross-sectionnel, pour deux raisons : c'est le cadre de l'equity statistical arbitrage, qui a produit l'essentiel de la littérature et du formalisme, et c'est celui où le breadth (§0.4) rend exploitables des pouvoirs prédictifs très faibles. Le crypto est le cas hybride : avec un univers investissable de l'ordre de 150 à 300 tokens, le cross-section existe mais reste étroit — assez riche pour un momentum ou un funding relatif, trop pauvre pour les partitions fines (double sorts 5×5, §1.2.3). Les spécificités crypto sont signalées au fil des sections plutôt que reléguées dans un chapitre séparé.

1.2 0.2 La définition de l'alpha

L'objet central de l'ouvrage est défini une fois pour toutes :

$$\alpha_{i,t} \approx E[r_i, t \rightarrow t+h \mid F_t]$$

Un alpha est une **statistique ayant un pouvoir prédictif sur les cours** — l'approximation d'une espérance de rendement futur, conditionnelle à l'information disponible à l'instant t . Trois termes méritent d'être explicités.

F_t est la *filtration* : l'ensemble de l'information légitimement connaissable en t . Sa définition est le premier acte de discipline de tout le processus, et l'objet de la section 1.2.4 : une donnée n'entre dans F_t qu'au moment où elle devient *connaissable*, pas au moment où elle décrit. Un bilan clos le 31 décembre n'entre dans F que mi-février.

h est l'**horizon** de prédiction. Il n'existe pas d'alpha sans horizon : le même conditionnement produit des prévisions de signes différents selon qu'on regarde à une seconde ou à six mois (le reversal court terme et le momentum moyen terme sont extraits des mêmes prix). Préciser h est donc constitutif de la définition, pas un détail d'implémentation.

Le signe $\approx$ porte tout le poids pratique. On ne cherche jamais à estimer l'espérance conditionnelle complète : on se contente d'une statistique **positivement corrélée** avec le rendement futur. C'est ce déplacement — de l'estimation d'une espérance vers la construction d'un prédicteur corrélé — qui rend le problème soluble, et qui fait de la corrélation la métrique reine (§0.3).

Deux conséquences architecturales découlent immédiatement de cette définition et gouvernent l'organisation de l'ouvrage :

1. **La prévision n'est pas une position.** L'alpha est un nombre attaché à un actif et une date, pas un ordre. La transformation prévision $\rightarrow$ portefeuille est un problème distinct, avec ses propres objets (modèle de risque, contraintes, coûts) — d'où la séparation des branches 1-3 (recherche du signal) et 4-6 (mise en œuvre), et l'interface minimale entre les deux : un vecteur d'alphas normalisés.
2. **L'alpha est un objet standardisable.** Puisque c'est une prévision et non une stratégie, il devient testable, mesurable et comparable selon un protocole uniforme — condition nécessaire à l'organisation industrielle de la recherche (§6.4), où des centaines de signaux produits indépendamment doivent être évalués et agrégés selon la même grille.

L'espérance conditionnelle n'est cependant que le premier moment. Prévoir $E[r \mid F]$ sans prévoir $\text{Var}[r \mid F]$ laisse le dimensionnement aveugle : la volatilité conditionnelle intervient dans la normalisation des cibles (§1.3.2), le sizing (§4.4) et le conditionnement par régime (§1.2.3). L'objet complet est la distribution conditionnelle ; l'alpha en est la partie qu'on estime le mieux.

1.3 0.3 Mesurer le pouvoir prédictif : IC et ICIR

L'**information coefficient** (IC) est la corrélation entre le signal et le rendement réalisé. Dans le cadre cross-sectionnel, il se calcule **par date** :

$$\text{IC}_t = \text{corr}(s_{\cdot,t}, r_{\cdot, t \rightarrow t+h}) \text{ sur les } N \text{ actifs}$$

On obtient donc une **série temporelle d'IC**, dont on résume la moyenne — le pouvoir prédictif — et l'écart-type — sa régularité. Le rapport des deux est l'**ICIR** :

$$\text{ICIR} = \text{moyenne}(\text{ICt}) / \text{écart-type}(\text{ICt})$$

C'est l'ICIR, et non l'IC moyen, qui gouverne le Sharpe du sleeve : un IC de 0,03 stable domine un IC de 0,05 qui alterne +0,15 et -0,05. La convention dominante est le **rank IC** (corrélation de Spearman plutôt que de Pearson) : robuste aux outliers et invariant aux transformations monotones du signal, ce qui rend la mesure indépendante des choix d'échelle faits en amont.

Trois repères d'ordre de grandeur, valables en equity cross-sectionnel quotidien :

- Un IC exploitable vit entre **0,02 et 0,06**. Au-delà de 0,10 de façon durable, suspecter un look-ahead avant de célébrer.
- Puisque $R^2 \approx \text{IC}^2$, un IC de 0,03 correspond à un R^2 d'environ 10-3. Le régime de travail est celui du **très faible ratio signal/bruit** — c'est la contrainte structurante de toute la branche 2.
- L'écart-type temporel de l'IC quotidien, $\sigma(\text{IC})$, se situe typiquement entre **0,10 et 0,20**, ce qui fixe la précision de tout ce qu'on peut affirmer (§3.1.2 : valider un IC demande des mois, classer deux IC voisins demande des années).

En time-series, la même quantité se calcule le long de la ligne — corrélation entre le signal et le rendement futur sur l'historique d'un instrument — et s'agrège ensuite entre instruments. Les formules diffèrent, l'interprétation est identique.

1.4 0.4 Breadth et loi fondamentale

Le lien entre pouvoir prédictif unitaire et performance du portefeuille est donné par la **loi fondamentale de la gestion active** (Grinold) :

$$\text{IR} \approx \text{IC} \times \sqrt{\text{BR}}$$

où IR est l'information ratio du portefeuille et **BR le breadth** — le nombre de paris indépendants pris par unité de temps. C'est l'équation qui explique pourquoi un pouvoir prédictif dérisoire produit une stratégie viable : en cross-section, chaque date fournit N paris quasi simultanés, et 3 000 actifs × 250 jours donnent un breadth annuel de plusieurs centaines de milliers. Un IC de 0,02 devient alors un IR à un chiffre confortable. En time-series sur quelques instruments, le breadth ne vient que de la répétition dans le temps : il faut des IC d'un ordre de grandeur supérieur pour le même résultat.

Deux corrections importantes doivent accompagner tout usage de cette loi :

L'indépendance est une fiction. BR n'est pas $N \times T$ mais le nombre de paris *effectivement indépendants*. La corrélation cross-sectionnelle entre actifs (les titres d'un même secteur ne sont pas des paris distincts) et l'autocorrélation du signal dans le temps (un signal de demi-vie longue reproduit le même pari plusieurs jours d'affilée) réduisent toutes deux le breadth effectif, souvent d'un ordre de grandeur. La loi donne un plafond, pas une prévision.

Le transfer coefficient. La formulation généralisée (Clarke, de Silva & Thorley) insère un terme supplémentaire :

$$\text{IR} \approx \text{TC} \times \text{IC} \times \sqrt{\text{BR}}$$

où **TC**, le *transfer coefficient*, est la corrélation entre les prévisions et les positions effectivement prises. Il vaut 1 si le portefeuille est exactement proportionnel aux alphas, et chute dès qu'interviennent contraintes, coûts, limites de liquidité ou interdiction de vendre à découvert. C'est le terme qui relie les branches 1-3 aux branches 4-5 : un alpha ne vaut que ce que la mise en œuvre en transfère, et une neutralisation faite en amont (§1.3.3) sert précisément à ce que l'IC mesuré soit un IC transférable.

1.5 0.5 Notations

Symboles utilisés uniformément dans tout l'ouvrage.

Symbole	Signification
i, N	indice d'actif ; taille de l'univers à une date
t, T	indice de date ; longueur de l'historique
h	horizon de prédiction (en périodes)
H	demi-vie d'une pondération exponentielle (§1.2.2)
$\mathbf{F}_t$	filtration : information connaissable en t
$r_i, t \rightarrow t+h$	rendement de l'actif i entre t et $t+h$
$\alpha_{i,t}$	prévision (alpha) pour l'actif i en t
s_k	signal k après normalisation (moyenne 0, variance 1)
K	nombre de signaux dans le pool
ρ_k	IC du signal k
$\mathbf{C}$	matrice de corrélation entre signaux (§3)
$\mathbf{w}$	vecteur des poids de combinaison (§3)
$\beta_i, \mathbf{F}_{\text{fac}}$	expositions factorielles ; rendements des facteurs (§4.1)
$\varepsilon_{i,t}$	rendement résiduel (idiosyncratique)
σ	volatilité (contexte précisé localement)
λ	facteur de décroissance d'une EMA, $\lambda = \exp(-\ln 2 / H)$
κ	pénalité de régularisation (ridge, §3.2)
τ	dispersion vraie des IC dans le prior hiérarchique (§3.1.3)
B	facteur de shrinkage bayésien, $B = s^2 / (\tau^2 + s^2)$
φ	vitesse de decay de l'alpha , $\varphi = \ln 2 / H\alpha$ (mesurée en §2.1.2)
IC, ICIR, IR, TC	cf. §0.3 et §0.4

Deux collisions de notation sont fréquentes dans la littérature et **évitées ici** : h désigne l'horizon et jamais une demi-vie (notée H) ; λ désigne la décroissance exponentielle et jamais la pénalité ridge (notée κ).

1.6 0.6 Conventions de calcul

Rendements. Log-rendements par défaut pour l'agrégation temporelle et l'estimation de volatilité ; rendements simples pour l'agrégation cross-sectionnelle (un portefeuille est une moyenne pondérée de rendements simples, pas de log-rendements). En equity, les rendements sont *totaux* (dividendes réinvestis) sauf mention contraire. En crypto, le rendement pertinent d'une position en perpétuel est **funding inclus** : ignorer cette composante fausse simultanément les features et les cibles.

Annualisation. $\sqrt{252}$ en equity (jours de bourse), $\sqrt{365}$ en crypto (marché continu). Mélanger les deux conventions fausse silencieusement tous les ratios d'environ 20% — la source d'erreur la plus commune et la plus discrète des comparaisons inter-classes d'actifs.

Dates. Toute table de données porte une colonne « connaissable à partir de », et aucune jointure temporelle ne se fait sur une autre colonne. Le signal calculé sur la clôture de t est exécuté au plus

tôt à l'ouverture de $t+1$. Les horodatages crypto sont en UTC, avec mention explicite lorsque la grille du funding (00/08/16 UTC) intervient.

Univers. Point-in-time strict : les constituants sont ceux qui existaient à la date considérée, les sorties (radiations, faillites, rachats, tokens morts) sont conservées avec leur rendement terminal. Les filtres de liquidité sont appliqués avec les données connaissables à la date, jamais rétrospectivement.

Signes. Chaque signal est publié avec un signe fixé par un prior économique explicite. Un signe déterminé par backtest est un degré de liberté supplémentaire, comptabilisé comme tel (§1.2.3, §2.3).

1.7 0.7 La relativité de la frontière alpha / beta

Un dernier point, épistémologique mais aux conséquences pratiques constantes : **la définition §0.2 rend l'alpha relatif au conditionnement**. Ce qui est alpha pour un desk est beta exotique pour un autre qui inclut ce facteur dans son modèle de risque ou dans sa filtration. Une prime de portage est un alpha tant qu'aucun facteur « carry » ne figure au modèle de risque ; elle devient une exposition rémunérée dès qu'il y figure.

Il n'existe donc pas de frontière absolue entre alpha et beta, seulement une frontière *relative à un modèle de risque donné* — celui de la section 4.1. C'est pourquoi la neutralisation (§1.3.3) et la mesure des expositions résiduelles (§2.1) ne sont pas des raffinements mais des étapes constitutives : elles définissent, opérationnellement, ce que la maison choisit d'appeler alpha. Deux desks aux modèles de risque différents peuvent légitimement porter des jugements opposés sur le même signal.

1.8 0.8 Plan et mode de lecture

L'ouvrage suit le pipeline dans son ordre logique, en deux moitiés séparées par une interface étroite — un vecteur d'alphas normalisés.

Recherche du signal, qui opère exclusivement sur des prévisions : la branche **1** construit les signaux (familles, feature engineering, normalisation, cibles) ; la branche **2** les valide et sert de système immunitaire (métriques, backtest, anti-overfitting, non-stationnarité) ; la branche **3** les agrège en une prévision unique (pondérations, régularisation, orthogonalité du pool).

Mise en œuvre, où les prévisions rencontrent les frictions : la branche **4** transforme les prévisions en positions (modèle de risque, optimisation, coûts, levier) ; la branche **5** transforme les positions en transactions (microstructure, impact, scheduling, TCA) ; la branche **6** porte l'ensemble (données, backtest, production, organisation de la recherche).

Chaque section est rédigée pour être lisible isolément, avec des renvois explicites vers les nœuds dont elle dépend. Deux fils traversent l'ouvrage de bout en bout et méritent d'être suivis dès la première lecture : le **budget de degrés de liberté** — chaque choix pris en branche 1 est une dette remboursée en branche 2 — et le **budget de turnover** — chaque unité de pouvoir prédictif capturée en branche 1 se paie en coûts dans les branches 4 et 5. La recherche d'alphas est, pour l'essentiel, la gestion disciplinée de ces deux budgets.

Part II

Recherche du signal

Chapter 2

§1.1 Familles d'alphas

État : relu (intégré s.2, harmonisé s.14 — renvois et notation vérifiés) — source : M128 (version finale, remplace M126) ; vérification des chiffres à venir.

La branche 1 ouvre la moitié « recherche » de l'arbre : elle transforme des données brutes en signaux normalisés que la branche 2 évaluera et que la branche 3 combinera. Son premier nœud est une taxonomie. Ce qui distingue les familles d'alphas, c'est la composante de **Ft** qu'elles exploitent — les prix eux-mêmes, la comptabilité, la demande, l'information extra-financière, le calendrier des événements — et l'horizon naturel qui en découle. Les cinq gisements sont présentés chacun avec son couple constitutif : le *mécanisme de persistance* qui explique pourquoi le pouvoir prédictif existe et survit, et la *formule de construction* qui le rend mesurable. C'est ce couple (mécanisme, formule), et non la formule seule, qui entre au registre comme hypothèse pré-spécifiée (§2.3.5).

1.1.1 Prix & volumes — le gisement le plus dense

Le **momentum cross-sectionnel** (Jegadeesh-Titman, JF 1993) : la caractéristique canonique est

$$MOM_i = P_{i,t-21}/P_{i,t-252} - 1, \text{ puis } z\text{-score cross-sectionnel (§1.3.1)}$$

— le skip-month excluant la zone de reversal (§1.2.1). Son risque de queue est *conditionnel* : Daniel & Moskowitz (JFE 2016) montrent que le beta de la jambe perdante explose en marché baissier (les perdants deviennent des options sur la survie), et dérivent le remède en forme close — le momentum dynamique pondéré par son propre ratio moyenne/variance conditionnel,

$$w^*t = (1/2\lambda a) \cdot \hat{\mu}MOM_{t,t}/\hat{\sigma}^2MOM_{t,t}$$

avec $\hat{\mu}$ prédit par l'état (indicateur bear $\times$ vol) et $\hat{\sigma}^2$ par GARCH — qui double environ le Sharpe en amputant les crashes : le conditionnement de §1.2.3 avec ses paramètres. (λa est ici une constante d'aversion au risque, locale à cette formule — sans rapport avec la décroissance EMA notée λ en §0.5.) Le **time-series momentum** (Moskowitz-Ooi-Pedersen, JFE 2012) : $position_{i,t} = \text{sign}(r_{i,t-252:t}) \cdot \sigma^*/\hat{\sigma}_{i,t}$ — le vol-scaling est constitutif du résultat ; la version continue est le banc multi-échelles de §1.2.2, $x_k = (EMAS_k - EMAL_k)/\sigma_P$ passé dans la réponse $R(x) = x \cdot e^{-x^2/4}$. Le **reversal** : $REVi = -\epsilon_{i,t-5:t}$ (le résidu factoriel de la semaine, §1.2.1), avec la loi de Nagel (RFS 2012) : $E[\text{profits du reversal}] \approx a + b \cdot VIX_t$, $b > 0$ — la rémunération de la liquidité est proportionnelle au prix du risque de la porter ; miroir daily de la relaxation d'impact de §5.2.2. La **microstructure agrégée** en features quotidiennes : l'illiquidité d'Amihud $ILLIQ_i = (1/D) \cdot \sum_d |r_{i,d}|/Vol_{i,d}$ (à la fois prime et conditionneur), l'OFI moyen, l'imbalance de clôture. La **volatilité** : le variance risk premium $VRPt = IV^2t - E_t[RV^2t \rightarrow t+21]$ (implicite moins réalisée prévue), positif en moyenne — le prix de l'assurance — et prédicteur du marché : $r_{t \rightarrow t+h} = a + b \cdot VRPt$ avec R^2 maximal vers $h \approx 3-6$ mois (Bollerslev-Tauchen-Zhou, RFS 2009). Le **betting-against-beta** (Frazzini-Pedersen, JFE 2014) : le facteur auto-financé et beta-neutre

$$BAB_t = (1/\beta_L) \cdot (r_L - r_f) - (1/\beta_H) \cdot (r_H - r_f), \tilde{\beta}_i = 0,6 \cdot \hat{\beta}_i + 0,4$$

(le shrinkage de Vasicek de §4.1.4, dans la définition même du facteur — voir l'encadré A) — long low-beta levé, short high-beta délevé : la prime des contraintes de levier. Les **saisonnalités** (Heston-Sadka, JFE 2008) : $si = (1/K) \cdot \Sigma_k ri$, même mois, année $t-k$ — la moyenne des rendements aux mêmes mois calendaires passés prédit positivement, une raie spectrale à 12 mois dans le cross-section.

1.1.2 Fondamentaux — la comptabilité comme Ft

Le **value** : composite z de $\{E/P, B/P, CF/P\}$ within-secteur (§1.2.1, §1.3.1) ; la construction factorielle de référence (Fama-French, JFE 1993) est le double tri 2×3 ,

$$HML = \frac{1}{2}(SV + BV) - \frac{1}{2}(SG + BG)$$

— la neutralisation de taille par construction, l'ancêtre artisanal du §1.3.3. La **profitabilité** (Novy-Marx, JFE 2013) : $GPI = (Revenus - COGS)/Actifs - corr(GP, B/P) < 0$ en coupe : l'orthogonalité au value est native (§3.4.1), d'où RMW au cinq-facteurs. Les **accruals** (Sloan, TAR 1996) :

$$ACCi = [(\Delta CA - \Delta Cash) - (\Delta PC - \Delta DetteCT - \Delta Impôtsdus) - Dotations] / Actifsmoyens$$

— la part non-cash du résultat, prédictif *néгатif* (hedge décile d'environ 10 % par an sur l'échantillon d'origine) : le résultat comptable se décompose en cash-flow + accruals, et le marché tarife mal la persistance inférieure du second terme. Les **révisions** : $REVi = \Delta(\text{consensus EPS})/Pi$ (ou $/\sigma_i$) — le changement, pas le niveau (§1.2.1). Le **carry** unifié (Kojen-Moskowitz-Pedersen-Vrugt, JFE 2018) :

$$Ci = (Si - Fi)/Fi = \text{le rendement à prix spot inchangé}$$

— en equity index $C \approx (q - rf)/(1+rf)$ (dividendes moins taux), en FX le différentiel de taux, en commodities la convenance yield nette ; prédictif partout avec des $t > 3$ en coupe globale. En crypto : le funding annualisé d'un perp, $C = E[\text{funding}] \times 1095$ (3 règlements/jour $\times 365$), est un carry *observé* — zéro estimation, la version la plus pure de la famille, avec la discipline de non-double-compte de §1.4.1 (le funding vit dans la cible *ou* dans le signal selon la construction, jamais les deux).

1.1.3 Flux & positionnement — la demande comme information

Le fondement quantitatif (Gabaix-Kojen, 2021) : l'hypothèse des marchés inélastiques,

$$\Delta P/P \approx M \cdot f, f = \text{flux net} / \text{capitalisation}, M \approx 5$$

— un multiplicateur macro d'ordre 5 (contre $M \rightarrow 0$ en marché parfaitement élastique), estimé par identification granulaire ; en coupe micro, l'élasticité par titre est plus grande mais finie — le pont avec l'impact de §5.2 (la loi en racine est la version métaordre du même fait). Les instances mesurables : le **short interest** — $SIRi$ = actions vendues à découvert / flottant, $DTCi = SI/ADV$; en agrégé, Rapach-Ringgenberg-Zhou (JFE 2016) : $rmkt,t \rightarrow t+1 = a - b \cdot SIIt$ (l'agrégat détrendé), l'un des R^2 out-of-sample les plus élevés de la littérature de prédiction du marché ; en coupe, niveau et Δ , avec le fee d'emprunt qui ampute (§2.1.3). Les **fire sales** (Coval-Stafford, JFE 2007) : la pression par titre

$$PRESSURE_{i,t} = \Sigma_j : \text{flux}_j < \text{percentile 10 ventes forcées}_{j,i} / Vol_i$$

— les fonds en décollecte extrême vendent leurs positions communes : baisse pendant, réversion complète en $\sim 12-18$ mois, le profil type du flux non informé. Le **dealer gamma** : l'exposition agrégée

$$GEX = \Sigma \text{options } OI \cdot \Gamma \cdot S^2 \cdot (\pm 1 \text{ selon le côté dealer présumé})$$

— gamma net positif $\Rightarrow$ le hedging vend les hausses et achète les baisses (flux $\propto -\Gamma_{net} \cdot \Delta S$: amortisseur, vol réalisée comprimée) ; négatif $\Rightarrow$ amplificateur — un conditionneur de régime intraday plus qu'un signal directionnel. Le **COT** : l'index de positionnement ($\text{nett} - \min_{3a} / (\max_{3a} -$

$\min_{3a}$), contrarian aux extrêmes. Et l'**on-chain** : $\text{netflow_exchanges}/\text{float}$ comme pression latente — la mesure vivant en §1.1.4, le mécanisme étant Gabaix-Koijen appliqué à un actif à flottant fin.

1.1.4 Données alternatives — l'information avant qu'elle soit un prix

Le **NLP** : la mesure lexicale de base (Loughran-McDonald, JF 2011, dictionnaires financiers) :

$$\text{TONEd} = (\text{Npos} - \text{Nneg}) / (\text{Npos} + \text{Nneg}), \text{ pondération tf-idf des termes}$$

— et le signal le plus robuste de la famille n'est pas le ton mais le *changement* : Cohen-Malloy-Nguyen (« Lazy Prices », JF 2020) — la similarité cosinus entre filings successifs,

$$\text{sim}(\text{dt}, \text{dt}-1) = \langle \text{xt}, \text{xt}-1 \rangle / (\|\text{xt}\| \cdot \|\text{xt}-1\|)$$

($\mathbf{x}$ = vecteurs tf-idf) : les sociétés qui *réécrivent* leur 10-K sous-performent — le marché ne lit pas les diffs ; §1.2.1 (changements vs niveaux) appliqué au langage. Piège propre à la génération LLM : le look-ahead sémantique (§1.2.4) — scorer 2015 avec un embedding entraîné en 2024 injecte du futur par le vocabulaire. Le **physique** (satellite, AIS) : la forme générique est la régression de nowcasting, $\text{Revenusq} = a + b \cdot (\text{comptage physiqueq}) + e$, dont le résidu de consensus fait un SUE anticipé (§1.1.5 pris à revers) ; l'edge est le délai, le coût d'entrée la barrière. Les **transactions** : même structure, panel de cartes → CA trimestriel. La dynamique d'érosion commune : $\alpha(t) = \alpha_0 \cdot e^{-t/T_{\text{comm}}}$ — le McLean-Pontiff des données (§2.4.2), T_{comm} se comptant en années depuis la mise en vente. L'**on-chain par cohortes** :

$$\text{MVRV} = \text{MC} / \text{RC}, \text{RC} = \Sigma \text{coins} (\text{quantité} \times \text{prix du dernier mouvement}) \quad \text{SOPR} = \Sigma \text{valeur au spend} / \Sigma \text{valeur à l'acquisition} (\text{coins dépensés du jour})$$

— MVRV est un P/coût-de-base agrégé (z-score long comme signal de cycle, §1.3.2), $\text{SOPR} < 1$ = ventes à perte en cours (capitulation) ; les deux sous le piège de vintage du §1.2.4 (clustering recalculé rétroactivement).

1.1.5 Événementiel — le breadth par la répétition

Le formalisme (MacKinlay, JEL 1997) : en temps d'événement τ ,

$$\text{AR}_{i,\tau} = r_{i,\tau} - (\hat{\alpha}_i + \hat{\beta}_i \cdot r_{m,\tau}), \text{CAR}_i(\tau_1, \tau_2) = \Sigma \tau_1 \tau_2 \text{AR}_{i,\tau}, t = \text{CAR} / (\sigma_{\text{AR}} \cdot \sqrt{L} \cdot \sqrt{(1/n)})$$

— l'inférence en coupe d'événements (n événements, fenêtre de L jours), le breadth par répétition ; la courbe de CAR moyenne est la signature (saut sec = efficience ; dérive = sous-réaction). L'instance canonique, le **PEAD** (Bernard-Thomas, JAR 1989) : après $\text{SUE}_i = (E_i - \hat{E}_i) / \sigma_i$ (surprise) (§1.2.1), $\text{CAR}(+2, +60) \approx +4\%$ pour le décile haut contre bas (de l'ordre de 18 % annualisés avant coûts) — et la structure fine : les surprises sont *autocorrélées saisonnièrement* ($\text{corr}(\text{SUE}_q, \text{SUE}_{q-4}) > 0$), le marché extrapolant mal la composante saisonnière des bénéfices. Les **recompositions d'indices** : la demande mécanique se chiffre, $Q_i = \Delta w_{i,\text{index}} \cdot \text{AUM}_{\text{indexé}}$, et l'impact attendu passe par la loi en racine (§5.2.1) : $I \approx Y \cdot \sigma_i \cdot \sqrt{(Q_i / \text{ADV}_i)}$ — le signal (front-run entre annonce et effet, réversion après) et le coût (§1.1.3) dans la même formule ; la timeline annonce/effet comme piège de §2.2.2. Le **pinning** d'expiration : $P(\text{clôture au strike de max OI})$ excède le hasard — le GEX de §1.1.3 concentré dans le calendrier. Et le **crypto** : les unlocks — ratio $u = \text{tokens libérés}/\text{float}$, impact attendu par la même racine carrée avec l'ADV *nettoyé* (§2.2.5), CAR type négatif de l'annonce à l'effet ; les listings (event study de l'inclusion, version exchange) ; l'érosion par publication des calendriers en années (§2.4.2).

Le fil de la section : chaque famille porte son mécanisme de persistance *et* sa formule de construction — c'est le couple (mécanisme, formule) qui entre au registre comme hypothèse pré-spécifiée (§2.3.5). Ce que ce nœud produit — des prédicteurs bruts, hétérogènes en échelle et en horizon — est la matière première du feature engineering (§1.2) et de la normalisation (§1.3).

Renvois : §0.5 (notations) ; §1.2.1 (transformations : skip-month, résidualisation, changements vs niveaux) ; §1.2.2 (banc multi-échelles) ; §1.2.3 (conditionnement par régime) ; §1.2.4 (point-in-time, look-ahead sémantique, vintages on-chain) ; §1.3.1–§1.3.3 (normalisation, neutralisation) ; §1.4.1 (non-double-compte du funding) ; §2.1.3 (fee d'emprunt) ; §2.2.2 (timeline) ; §2.2.5 (nettoyage crypto) ; §2.3.5 (pré-spécification) ; §2.4.2 (érosion post-publication) ; §3.4.1 (orthogonalité native) ; §4.1.4 (shrinkage de Vasicek — encadré A) ; §5.2.1–§5.2.2 (loi en racine, relaxation).

Chapter 3

§1.2 Feature engineering

État : relu (intégré s.2, harmonisé s.14 — renvois et notation vérifiés) — sources : M018 (1.2.1), M025 (1.2.2), M027 (1.2.3), M029 (1.2.4), M016 (cadrage) ; vérification des chiffres à venir.

Le feature engineering est l'atelier où la donnée brute devient un prédicteur candidat : entre les gisements de la taxonomie (§1.1) et la normalisation qui rendra les signaux combinables (§1.3), ce nœud concentre les choix de construction — transformations, fenêtres, interactions, datation de l'information. Deux principes le gouvernent de bout en bout. D'abord, les choix de construction *sont* des choix de signal : la même donnée contient des effets de signes opposés que la transformation sépare ou laisse se neutraliser. Ensuite, chaque degré de liberté pris ici est une dette remboursée dans la branche 2 — le budget de degrés de liberté annoncé en §0.8 se dépense d'abord dans ce nœud, et sa comptabilité (§1.2.3, §2.3) n'est pas une formalité mais la condition de crédibilité de tout ce qui suit.

1.2.1 Transformations — de la série brute au prédicteur

Rendements multi-horizons. L'idée fondatrice : un rendement cumulé est une somme téléscopique de sous-périodes, et les sous-périodes portent des informations de *signes opposés*. Le rendement 12 mois se décompose en $r(t-252, t-21) + r(t-21, t)$: la première composante prédit positivement (momentum, sous-réaction à l'information fondamentale), la seconde négativement (reversal, sur-réaction aux chocs de liquidité). Le momentum « 12-1 » n'est donc pas une convention arbitraire mais une chirurgie : utiliser le rendement 12 mois brut, c'est additionner un signal et son antidote. Novy-Marx a poussé la dissection plus loin en montrant que l'essentiel du pouvoir prédictif loge dans la partie *ancienne* de la fenêtre (le rendement des mois 12 à 7 bat celui des mois 6 à 2) — controversé sur sa robustesse hors échantillon US (Goyal & Wahal ne le répliquent pas sur les marchés internationaux), mais illustratif de la démarche : traiter l'axe temporel du rendement passé comme un spectre dont chaque bande a son propre IC, mesurable séparément (§1.2.2 en donne la version filtrée). Au-delà du découpage, les *reparamétrisations* du chemin : le momentum ajusté de la volatilité (rendement/vol réalisée — un titre monté de 30% en ligne droite et un monté de 30% en dents de scie ne portent pas la même information), la fraction de jours positifs sur la fenêtre (l'« information discreteness » de Da-Gurun-Warachka : le momentum issu d'une dérive régulière persiste mieux que celui issu de quelques sauts, cohérent avec une histoire de sous-réaction à un flux continu d'information), et la distance au plus haut 52 semaines (un ancrage comportemental : les titres proches de leur plus haut voient leur bonne nouvelle sous-incorporée car les investisseurs hésitent à « acheter au plus haut »). En crypto, la même grammaire avec des horizons compressés : le time-series momentum vit sur 1 à 4 semaines plutôt que 6 à 12 mois, le reversal court terme sur des heures à quelques jours, et — spécificité structurelle — le rendement pertinent d'une position en perpétuel est le rendement *funding inclus* : un token flat en prix avec un funding à -0,05% par 8h a rapporté du carry substantiel au short ; ignorer cette composante fausse à la fois les features et les cibles (§0.6, §1.4.1).

Résidualisation factorielle. La mécanique : régression rolling (ou EWMA) des rendements du titre

sur des facteurs — $r_{i,t} = \beta_i' F_t + \varepsilon_{i,t}$ — puis on construit la feature sur les $\varepsilon_{i,t}$ (cumulés pour un momentum résiduel, instantanés pour un reversal résiduel). Le choix du modèle factoriel est un curseur : marché seul, marché + secteurs, modèle commercial complet (Barra, §4.1.1), ou facteurs statistiques par PCA. Plus le modèle est riche, plus le résidu est « pur » — et plus le signal résultant est orthogonal aux primes de risque que le portefeuille détient déjà par ailleurs, ce qui augmente sa valeur *marginale* dans la combinaison même à IC égal (§3.4.1). Pourquoi ça marche si bien sur le momentum : le momentum brut d'un titre est en grande partie du momentum de son beta (un titre à beta 1,5 dans un marché haussier a mécaniquement un « bon momentum »), et cette composante-là est précisément celle qui se retourne violemment dans les rebonds de marché — les crashes de momentum de 2009 ou 2020 sont des crashes du momentum *factoriel*. Le momentum résiduel (Blitz-Huij-Martens) garde la sous-réaction à l'information spécifique du titre et jette le pari factoriel déguisé : ICIR supérieur, drawdowns amputés. Même chose pour le reversal : un titre qui a baissé de 3% quand son secteur baissait de 3% n'a subi aucun choc spécifique, donc n'a rien à « reverser » ; le reversal résiduel concentre le signal sur les vrais chocs idiosyncratiques, là où la fourniture de liquidité est effectivement rémunérée (§1.1.1, loi de Nagel). Les précautions : les betas estimés sont bruités, et résidualiser avec des betas bruités *injecte* du bruit — d'où le shrinkage des betas vers 1 ou vers la moyenne sectorielle (à la Vasicek, §4.1.4, encadré A), et des fenêtres d'estimation qui arbitragent réactivité contre variance. Et un piège point-in-time subtil : des facteurs PCA estimés sur l'échantillon complet contiennent le futur (la structure de corrélation de 2020 « connaît » le Covid) ; les facteurs statistiques doivent être ré-estimés en expanding window comme n'importe quelle feature (§1.2.4). En crypto, la résidualisation naturelle est contre BTC et ETH — la paire qui joue le rôle du « marché » — mais les betas y sont remarquablement instables (le beta d'un alt contre BTC change de régime en quelques semaines), ce qui pousse vers des fenêtres courtes, du shrinkage agressif, ou des approches par rangs qui contournent l'estimation de beta. Poussée à sa limite, la résidualisation devient le stat arb classique : les résidus de cointégration d'une paire ou d'un panier ne sont qu'une résidualisation où le « facteur » est l'autre jambe.

Ratios et standardisation. Un fondamental brut (bénéfice, book value, volume) n'est pas cross-sectionnellement comparable ; le ratio est ce qui le transforme en signal. Détails de construction qui comptent : préférer E/P à P/E (quand le bénéfice traverse zéro, P/E explose et change de signe de façon discontinue, E/P reste continu et ordonnable), préférer les mesures *hautes* du compte de résultat (la gross profitability de Novy-Marx — marge brute/actifs — prédit mieux que le résultat net, car moins polluée par les choix comptables et les éléments exceptionnels, §1.1.2), et traiter les dénominateurs proches de zéro par des rangs ou un signed-log plutôt que de laisser trois micro-caps dominer la queue de distribution (§1.3.1). Le choix de standardisation est un choix de *pari* : un E/P comparé à tout l'univers fait de « value » un pari structurel long banques/énergie contre tech ; un E/P standardisé within-secteur (z-score par industrie GICS) parie sur les titres décotés *relativement à leurs comparables* — deux signaux différents, avec des profils de risque différents, et le second est presque toujours celui qu'on veut dans un portefeuille neutralisé par ailleurs (§1.3.3). Côté ratios techniques : prix/moyenne mobile (une reparamétrisation du momentum), volume relatif (volume du jour / ADV — un détecteur d'événement générique), et l'illiquidité d'Amihud $|r|/\text{volume monétaire}$, à la fois signal (prime d'illiquidité) et variable de conditionnement (l'impact attendu de ses propres trades, §5.2.1). En crypto, les ratios sont le cœur de l'analyse on-chain : MVRV (valeur de marché / valeur réalisée — le prix moyen d'acquisition de chaque coin au moment de son dernier mouvement, un « cost basis » agrégé dont les extrêmes marquent les zones de capitulation et d'euphorie, §1.1.4), NVT (capitalisation / volume on-chain transféré, un « P/E » où les transactions jouent le rôle des bénéfices), et le ratio volume réel / volume reporté par venue — qui est autant un filtre de qualité de données (§2.2.5) qu'une feature.

Changements vs niveaux. Le principe théorique découle directement de la définition racine (§0.2) : si $\alpha_t \approx E[r_{t+h} | F_t]$, alors ce qui prédit doit être ce qui n'est *pas encore* dans les prix — et un niveau public et stable a eu tout le temps d'y entrer. Le contenu prédictif se loge dans l'innovation : la composante surprise du dernier point de donnée. La forme canonique est le SUE (standardized unexpected earnings) : (réalisé – attendu) / écart-type des surprises passées, où l'« attendu » vient

du consensus des analystes ou d'un modèle de série temporelle. Le post-earnings announcement drift (§1.1.5) — la dérive qui suit la surprise pendant des semaines — est l'illustration historique que le marché sous-réagit aux innovations, pas aux niveaux. La même logique produit les révisions d'estimations (le *changement* du consensus, plus puissant que son niveau), le delta du short interest, les changements de recommandations, et en crypto les deltas de flux vers les échanges, l'accélération du funding (sa dérivée signale la construction de levier plus finement que son niveau), ou les changements de dominance BTC. La distinction n'est pourtant pas un dogme, et savoir quand elle cède est aussi important : certains niveaux prédisent durablement — la profitabilité, la qualité de bilan, l'illiquidité. La grille de lecture : un *changement* prédit via la sous-réaction (le marché met du temps à digérer l'innovation ; l'alpha decay est rapide, semaines), un *niveau* prédit via une prime de risque ou une friction persistante (le marché rémunère en continu le fait de porter cette caractéristique ; le decay est lent, années). Les deux sont des alphas au sens de la racine, mais tout diffère en aval — turnover, capacité, crowding, et la taxonomie de persistance qui gouverne les demi-vies de combinaison (§2.4.3, §3.2.4).

1.2.2 Fenêtres et pondération temporelle — la mémoire du signal

EMA vs fenêtres plates. La fenêtre plate donne un poids $1/n$ aux n dernières observations, puis zéro. Ce profil rectangulaire a une pathologie structurelle : quand une observation extrême franchit le bord arrière de la fenêtre, l'estimateur saute — le signal change alors qu'*aucune information nouvelle n'est arrivée*. Concrètement, un momentum 252 jours peut basculer de long à short le jour où le krach d'il y a un an sort de la fenêtre ; le trade déclenché a une espérance nulle par construction et un coût réel. L'EMA, avec ses poids λ_k décroissants, n'a pas de bord : chaque observation s'éteint continûment. On la paramètre en *demi-vie* H ($\lambda = \exp(-\ln 2 / H)$, cf. §0.5) plutôt qu'en span ou en λ brut — « la moitié du poids porte sur les H derniers jours » est une phrase qu'on peut raisonner, $\lambda = 0,997$ non. La comparaison rigoureuse se fait à retard égal : le retard moyen d'une fenêtre plate de n jours est $(n-1)/2$, celui d'une EMA est $\lambda/(1-\lambda) \approx H/\ln 2 - 1/2$. À retard apparié, la fenêtre plate est l'estimateur de variance minimale *si la quantité estimée est constante* — mais c'est précisément l'hypothèse fautive en finance. La lecture state-space éclaire tout : l'EWMA est le filtre de Kalman en régime permanent du modèle où le paramètre sous-jacent (l'espérance, la vol) suit une marche aléatoire observée avec bruit. Autrement dit, choisir l'EMA n'est pas un choix esthétique, c'est déclarer que le monde dérive — et sa demi-vie optimale est déterminée par le ratio entre la vitesse de dérive du paramètre et le bruit d'observation. Deux détails pratiques : le *warm-up* (les premières valeurs d'une EMA sont dominées par l'initialisation — soit on tronque, soit on renormalise par la somme des poids effectivement disponibles), et le fait que le turnover d'un signal EMA se calcule analytiquement à partir de sa demi-vie (§1.3.4), ce qui permet de budgéter les coûts avant même de backtester.

Multi-échelles — le banc de filtres. L'erreur méthodologique classique est de chercher la bonne fenêtre par grid search — chaque valeur testée incrémente le compteur N du deflated Sharpe (§2.3.2), et la « meilleure » fenêtre in-sample est presque toujours un artefact d'échantillon. L'approche mûre : construire un *banc* de demi-vies espacées géométriquement (8, 16, 32, 64, 128 jours — l'espacement géométrique, pas arithmétique, car l'information est approximativement log-uniforme en fréquence) et déléguer la pondération à la branche combinaison (§3), qui mesurera l'IC de chaque échelle et les agrégera. La référence canonique est le trend-following à la AHL (Baz et al., « Dissecting Investment Strategies ») : trois croisements de moyennes exponentielles avec les paires de demi-vies (8, 24), (16, 48), (32, 96), chacun normalisé par la volatilité du prix, puis passé dans la réponse non linéaire $R(x) = x \cdot e^{-x^2/4}$ qui sature et se retourne aux extrêmes (§1.3.2). La lecture en traitement du signal est la bonne : la *différence* de deux EMA est un filtre passe-bande — elle annule les composantes très lentes (que les deux EMA capturent identiquement) et les très rapides (que les deux lissent), isolant une bande de fréquences du spectre du prix. Le banc multi-échelles est donc une décomposition spectrale grossière du processus de prix, cousin pauvre mais robuste des ondelettes, et la question « quelle fenêtre ? » devient la question mesurable « quelles bandes de fréquence portent de l'IC ? ». Réponse empirique typique : en equity cross-sectionnel, les bandes lentes portent le momentum et les rapides le reversal, avec une zone morte au milieu ; en

crypto, tout le spectre est décalé vers les hautes fréquences — les bandes qui correspondraient à des demi-vies de plusieurs mois en actions vivent sur des semaines.

Estimation de volatilité. La vol apparaît partout : au dénominateur des cibles (§1.4.1), dans les z-scores (§1.3), dans le sizing (§4.4.1), dans les variables de régime (§1.2.3) — c'est la feature dont la qualité se propage à tout le système. La base est l'EWMA sur rendements carrés (l'héritage RiskMetrics, $\lambda = 0,94$ en daily, soit une demi-vie d'environ 11 jours), avec une subtilité d'usage : des demi-vies différentes pour des rôles différents — courte (5-20 j) pour le sizing qui doit réagir, longue (60-120 j) pour la définition de régimes qui doit être stable. Utiliser la même estimation partout couple des décisions qui ne devraient pas l'être. Les estimateurs *range-based* extraient plus d'information des mêmes journées : Parkinson (à partir du high-low, environ 5 fois plus efficace que le close-to-close — efficacité relative théorique $\approx 4,9$, Parkinson 1980 —, car le range d'un brownien renseigne davantage sur σ que son point d'arrivée), Garman-Klass (OHLC complet), Rogers-Satchell (robuste au drift — important pour les titres en tendance forte), et Yang-Zhang, qui combine composante overnight et intraday et gère les gaps — l'estimateur par défaut raisonnable en equity, où le gap d'ouverture est une part majeure de la variance totale. Au-delà, la *realized volatility* : somme des rendements carrés intraday (échantillonnés à ~ 5 minutes — en dessous, le bruit de microstructure et le bid-ask bounce biaisent vers le haut, §5.1.1). En crypto, la RV est un luxe démocratisé : marché 24/7, pas de gap overnight sur les perps, données tick accessibles — il n'y a aucune raison de se contenter d'un close-to-close. Deux pièges spécifiques : l'annualisation ($\sqrt{252}$ en equity, $\sqrt{365}$ en crypto — mélanger les conventions fausse silencieusement tous les ratios d'environ 20%, §0.6) et les venues (la vol mesurée sur une venue à faible profondeur est contaminée par son propre bruit de microstructure ; mesurer sur la venue directrice ou sur un prix composite).

Fréquence et horizon. Règle d'ordre de grandeur : la demi-vie des features doit être commensurable avec l'horizon h du signal — prédire $h = 21$ jours avec des features de demi-vie 2 jours produit un signal dont le turnover détruit l'edge, l'inverse produit un signal en retard permanent. Et la symétrie avec la branche évaluation est directe : dès que $h > 1$ avec des features quotidiennes, les observations se chevauchent — c'est exactement l'autocorrélation des labels qui exige purging et Newey-West (§1.4.2, §2.3.1, encadré D) ; le choix de grille fait ici détermine la sévérité de la correction là-bas. L'agrégation intraday $\rightarrow$ daily est la façon d'enrichir la grille quotidienne sans la quitter : imbalance moyen du carnet, part du volume en fin de séance, RV, asymétrie du profil de volume — des features quotidiennes *fabriquées* à partir de la microstructure (§5.4.2). En equity, la décomposition la plus féconde de la journée est overnight vs intraday : ce sont deux régimes économiques distincts (le rendement overnight concentre la dérive et les réactions aux annonces, l'intraday concentre le reversal et les flux), et beaucoup de signaux ont des IC de signes différents sur les deux segments — les traiter comme deux « fenêtres » séparées est une transformation à part entière. En crypto, la journée UTC est une pure convention (aucune clôture économique à minuit UTC), mais le marché a ses grilles naturelles : le funding des perps toutes les 8 heures (00/08/16 UTC) crée des points de synchronisation où le positionnement se règle, les sessions US/Asie structurent la liquidité intra-journalière, et les week-ends — sans être fermés — sont des régimes de profondeur réduite où les mêmes signaux ont des coûts et des IC différents. Les features calendaires (heure de session, distance au prochain funding, jour de semaine) ne sont pas du folklore : elles conditionnent des différences de régime mesurables.

1.2.3 Interactions et conditionnement — où le signal devient contextuel

Conditionnement par régime. Le point de départ empirique : le pouvoir prédictif de presque tous les signaux varie avec l'état du marché, et cette variation a souvent une logique économique. Le reversal court terme paie davantage en haute volatilité — c'est la rémunération de la fourniture de liquidité, et le prix de la liquidité monte avec le risque de la porter (§1.1.1). Le momentum s'affaiblit aux points de retournement et en haute dispersion cross-sectionnelle, et son fameux crash est concentré dans les rebonds qui suivent les krachs. Le carry, dans toutes ses incarnations, gagne petit en régime calme et perd gros en risk-off. Ignorer ces conditionnements, c'est laisser de l'ICIR sur la table ; les modéliser, c'est ouvrir un espace de sur-apprentissage — d'où l'importance de la *forme*. La forme recommandable est multiplicative et lisse : $\alpha_{\text{conditionné}} = \alpha \times g(z)$, où z est la variable

de régime (z-score de vol, de dispersion, de liquidité agrégée) et g une fonction douce — sigmoïde, rampe saturée — plutôt qu'un seuil dur. Le seuil dur (« couper le momentum si $VIX > 30$ ») a trois défauts : il crée des discontinuités de position (trades violents quand z oscille autour de la frontière), le niveau du seuil est un degré de liberté caché optimisé sur une poignée d'épisodes historiques, et il jette l'information ordinale de z . L'alternative par commutation explicite (HMM, Markov-switching) est séduisante conceptuellement mais souffre du *lag de détection* : le régime est identifié avec retard, précisément quand son exploitation ne vaut plus rien — et la version filtrée en temps réel d'un HMM ressemble beaucoup à... une fonction lisse d'un z-score (le même arbitrage détection/gradualité se retrouve en surveillance, encadré E). Règle transversale : la variable de régime est une feature comme une autre, soumise à la même discipline point-in-time (un régime défini avec la vol *future* de l'épisode est le look-ahead le plus élégamment déguisé du répertoire, §1.2.4). En crypto, les conditionnements naturels : le niveau et le signe du funding agrégé (un marché à funding extrême positif est un marché où le levier long est empilé — le reversal y mord plus fort), la dominance BTC (les alphas cross-sectionnels sur alts changent de nature selon que le marché est en phase BTC ou en phase alts), et la corrélation réalisée BTC-Nasdaq, qui commute entre des régimes où le crypto est un actif macro et des régimes où il vit sa vie propre.

Double sorts. L'outil non paramétrique canonique, hérité de Fama-French : trier l'univers en quintiles de la variable conditionnante z , puis, à l'intérieur de chaque quintile, en quintiles du signal α — 25 cellules, et le spread long-short du signal calculé quintile de z par quintile de z donne le profil complet de l'IC conditionnel, sans imposer de forme à g . Si le spread du reversal croît monotonement du quintile bas-vol au quintile haute-vol, l'interaction est établie ; si elle n'apparaît que dans une cellule, c'est du bruit. La distinction technique qui compte : sorts *indépendants* (les deux tris faits séparément sur tout l'univers, puis intersection) vs *conditionnels* (tri séquentiel, z d'abord, α dans chaque groupe). Quand α et z sont corrélés — le cas fréquent : la plupart des signaux sont corrélés à la taille ou à la vol — les sorts indépendants produisent des cellules quasi vides (il n'y a presque pas de titres à la fois petits et très liquides), aux rendements dominés par trois noms ; les sorts conditionnels garantissent des cellules équi-peuplées et répondent à la question qu'on pose réellement : « le signal marche-t-il à z donné ? ». C'est aussi le test qui départage une vraie interaction d'une simple corrélation de caractéristiques — si « le momentum marche mieux sur les titres illiquides » disparaît en sort conditionnel, c'était juste que momentum et illiquidité sélectionnaient les mêmes titres. La limite est le breadth : 25 cellules exigent un univers de plusieurs milliers de titres pour que chaque cellule soit diversifiée. En crypto, avec 150-300 tokens investissables, on rétrograde en 3×3 , et encore — c'est une des raisons structurelles pour lesquelles la recherche crypto s'appuie davantage sur les priors et moins sur la granularité statistique (§0.1, §2.4.4).

Non-linéarités ML. Le résultat de référence est Gu-Kelly-Xiu (« Empirical Asset Pricing via Machine Learning », RFS 2020) : sur le panel US complet, les gradient boosted trees et les réseaux peu profonds dominant nettement les modèles linéaires, et la décomposition du gain montre qu'il vient *majoritairement des interactions* — momentum $\times$ liquidité, value $\times$ taille, signaux $\times$ état macro — précisément ce que le linéaire ne peut pas représenter et que le chercheur ne peut pas énumérer. Le message pratique n'est pas « les NN profonds gagnent » (ils ne gagnent pas : au-delà de 2-3 couches, la performance se dégrade sur données financières — le ratio signal/bruit ne finance pas la profondeur) mais « les arbres boostés peu profonds avec régularisation lourde sont l'outil de découverte d'interactions ». La discipline d'usage : cibles en rangs ou z-scores cross-sectionnels (jamais les rendements bruts — le modèle passerait sa capacité à apprendre la vol, §1.4.1), profondeur d'arbre 3-4 (une profondeur d , c'est des interactions d'ordre $\leq d$; l'ordre 2-3 suffit et au-delà on modélise le bruit), subsampling agressif des features et des observations, et *ensembling sur les seeds* — la variance entre deux runs identiques à seed différente est un diagnostic gratuit : si elle est du même ordre que l'IC, le modèle raconte du bruit. Les *contraintes de monotonie*, natives dans XGBoost/LightGBM, sont le pont entre le ML et les priors : imposer que la prédiction reste croissante en E/P ou en momentum résiduel garde la liberté sur les interactions tout en interdisant les zigzags appris de l'échantillon. Enfin l'interprétation — SHAP values, partial dependence sur les paires — n'est pas cosmétique : une interaction *découverte* par le modèle a le statut d'hypothèse, pas de résultat ; le

geste correct est de l'extraire, la reformuler comme feature explicite avec une histoire économique, et la re-tester isolément en out-of-sample. Le modèle ML comme générateur d'hypothèses, pas comme boîte de production — c'est la position de la plupart des desks sérieux, et elle enchaîne directement sur le quatrième point. S'y ajoute la règle qualitative : toute interaction retenue doit avoir une *histoire économique* énonçable en une phrase — qui perd de l'argent de l'autre côté, et pourquoi ça persiste. Une interaction sans histoire compte comme un essai de data mining, pas comme une hypothèse.

Coût en degrés de liberté. C'est la sous-branche qui donne son prix à tout le reste. Chaque choix fait dans ce nœud — la forme de g , le nombre de quintiles, la profondeur des arbres, chaque hyperparamètre — est un essai, et l'espace des interactions explose combinatoirement : p features offrent $p(p-1)/2$ paires, chacune déclinable en plusieurs formes. Le lien quantitatif avec la branche évaluation est direct : le Sharpe maximal attendu sous l'hypothèse nulle croît en $\sqrt{2 \ln N}$, donc explorer 1 000 configurations *fabrique* un Sharpe maximal attendu de l'ordre de 1 à 1,5 à partir de rien sur cinq à dix ans de données quotidiennes ($E[\max] \approx 3,3 \cdot \sigma(\hat{SR})$ pour $N = 1\,000$, avec $\sigma(\hat{SR}) \approx 1/\sqrt{T}$ années — le calcul de §2.3.2), et le deflated Sharpe exige N en entrée (§2.3.2). Subtilité importante : les essais corrélés comptent moins — mille variantes d'un même momentum ne font pas mille essais indépendants — et le N *effectif* s'estime à partir de la corrélation moyenne entre les backtests de la famille explorée (§2.3.4, §6.2) ; c'est plus favorable que le comptage brut, mais seulement si on a effectivement loggé les essais pour pouvoir le calculer — la question du registre, qui appartient à la branche infra (§6.2). D'où la hiérarchie de crédibilité qui structure la pratique : au sommet, l'interaction *pré-spécifiée* — hypothèse économique écrite avant le test, forme et paramètres fixés par défaut raisonnable plutôt qu'optimisés, un seul backtest qui confirme ou infirme (le pré-enregistrement, importé de la recherche clinique, existe informellement dans les meilleurs desks : le document d'hypothèse date d'avant les résultats, §2.3.5). Au milieu, l'interaction découverte par ML puis re-testée comme hypothèse explicite sur données non utilisées par la découverte. En bas, le grid search assumé, qui n'est acceptable que passé au DSR avec son vrai N . Et la ressource ultime qui contraint tout : les données out-of-sample sont *non renouvelables* — chaque regard sur le holdout le consomme un peu (le « holdout » regardé dix fois est devenu un training set), d'où la règle du holdout intouchable qu'on n'ouvre qu'une fois, en toute fin, sur la version finale (§2.3.5, §6.2). En crypto, où l'histoire utile fait cinq ans, ce budget est dramatiquement plus serré : la tentation de tout tester sur tout est maximale exactement là où on peut se le permettre le moins.

1.2.4 Discipline point-in-time — la comptabilité de l'information

Lags de publication. Le principe unique : chaque donnée porte deux dates — la période qu'elle décrit et le moment où elle devient *connaissable* — et seule la seconde compte pour construire F_t (§0.2). En equity, l'écart entre les deux est massif : un bilan clos au 31 décembre est déposé mi-février (10-K américain : jusqu'à 60-90 jours selon la taille de la société), et indexer les fondamentaux par leur date de période injecte six à douze semaines de futur. La convention académique paresseuse — un lag forfaitaire de 3 ou 6 mois à la Fama-French — est conservatrice mais destructrice d'information : elle rate le drift post-publication qui vit précisément dans les semaines suivant le dépôt (§1.1.5). La bonne pratique est le *filing date* réel titre par titre (disponible via EDGAR ou les bases point-in-time des vendeurs), avec une subtilité : l'information fuit souvent *avant* le dépôt formel via le communiqué de résultats — pour les signaux d'earnings, la date pertinente est celle de l'annonce, pas du filing. Les autres flux ont chacun leur calendrier : les estimations d'analystes arrivent en continu mais les agrégateurs consolident avec un délai de traitement (le consensus « du jour » chez certains vendeurs intègre des révisions saisies le lendemain — il faut la date d'enregistrement dans la base, pas la date de la révision), le short interest américain est publié deux fois par mois avec ~9 jours ouvrés de retard (la donnée « du 15 » est connaissable vers le 25), les données de prêt-emprunt quotidiennes ont leur propre latence contractuelle, et la macro (CPI, NFP) a des heures de publication à la seconde près qui comptent dès qu'on descend en intraday. La règle opérationnelle : chaque table de la base de features porte une colonne « connaissable à partir de », renseignée par flux, et aucune jointure temporelle ne se fait sur une autre colonne que celle-là (§0.6, §6.1).

Vintages et révisions. Deuxième couche du problème : même correctement datée à l'arrivée, une donnée peut être *réécrite* ensuite. Les restatements comptables remplacent les chiffres historiques

dans les bases courantes — la série « finale » d'une société qui a restaté ses comptes contient une information (la fraude découverte, l'erreur corrigée) que le marché n'avait pas à l'époque, et un signal de qualité comptable backtesté sur données restatées est structurellement embelli : il « détecte » les fraudes avec les chiffres d'après la détection. La macro est pire encore : le PIB et l'emploi sont révisés sur des années, et l'écart premier-jet / série finale est parfois du même ordre que le signal qu'on cherche — la recherche sérieuse sur signaux macro utilise les bases de vintages (type ALFRED de la Fed de St. Louis) où chaque observation existe en autant de versions qu'il y a eu de publications. La réponse architecturale est la base *bitemporelle* : chaque enregistrement porte la date de l'événement ET la date de validité de cette version de l'enregistrement, et toute requête historique se fait « telle que la base était au jour t » (la sémantique exacte est en §6.1). Concrètement, pour un desk qui démarre : snapshotter quotidiennement les tables critiques coûte du stockage trivial et rend le problème soluble rétroactivement ; ne pas le faire rend certains backtests *définitivement impossibles à assainir*, car les vintages perdus ne se reconstituent pas. C'est un des rares points de tout l'arbre où une décision d'infrastructure prise au jour 1 conditionne la validité de la recherche des années suivantes — le pont avec la branche 6 est ici structurel, pas anecdotique.

Corporate actions et continuité des séries. Les prix « ajustés » des splits et dividendes sont recalculés rétroactivement à chaque nouvel événement : le facteur d'ajustement d'aujourd'hui réécrit toute l'histoire du titre, donc toute feature qui compare un prix à un seuil absolu (le filtre « prix > 5\$ », la distance à un strike, un niveau rond) doit être calculée sur prix *bruts* contemporains, pas sur la série ajustée téléchargée aujourd'hui. Les dividendes eux-mêmes créent une bifurcation : rendement total vs rendement prix ne diffèrent que de ~2% par an en moyenne, mais systématiquement et avec une structure cross-sectionnelle (les value stocks paient plus) — un backtest de value sur rendements prix sous-estime le facteur (§0.6). La continuité de l'identité est l'autre versant : les tickers sont réutilisés (un ticker mort réattribué à une autre société colle deux histoires sans rapport), les fusions et spin-offs exigent des règles de succession explicites, et l'univers doit inclure les morts avec leur *rendement terminal* — le delisting return, souvent -30% à -100%, dont l'omission est le biais de survivance au sens strict : un signal short sur les sociétés en détresse paraît médiocre si ses plus grands succès disparaissent de l'échantillon la veille de leur faillite (les forfaits de Shumway sont en §2.2.3). La pratique standard : identifiants permanents (PERMNO chez CRSP, ou identifiants internes mappés sur FIGI), table de correspondance datée ticker↔identifiant, et politique documentée par type de sortie (faillite, rachat, radiation) — le rendement de sortie d'un rachat cash est parfaitement connu, celui d'une radiation pour insolvabilité doit être conservativement forfaitisé.

Pièges crypto — les mêmes maladies, sans les institutions qui les soignent. Le crypto reproduit chaque pathologie ci-dessus en version aggravée, car il n'existe ni CRSP, ni EDGAR, ni convention de place. Les chandelles historiques ne sont pas immuables : les échanges corrigent des trades, réagrègent après incidents, et l'API qui resert « l'historique » aujourd'hui ne restitue pas toujours ce que le flux temps réel montrait — la seule défense est la capture propriétaire continue (enregistrer soi-même trades et carnets, horodatés à la réception), qui transforme le problème de vintages en simple problème de stockage (§6.1). L'identité des instruments est fragile : migrations de contrats ERC-20 (le « même » token change d'adresse et parfois de décimales, cassant les séries de supply et de prix), rebrandings avec redénomination (MATIC→POL et ses semblables), et côté dérivés, les changements de spécification des perps — taille du contrat, plafonds de funding, méthodologie du prix d'indice — qui font qu'une série de funding « continue » sur cinq ans enjambe plusieurs régimes contractuels différents. Les données on-chain ont un problème de vintage épistémologiquement intéressant : les métriques par cohortes (MVRV, supply des « long-term holders », flux d'échanges) dépendent d'heuristiques de clustering des wallets que les fournisseurs améliorent en continu — la série MVRV servie aujourd'hui pour 2021 est calculée avec le clustering d'aujourd'hui, pas celui qui était affiché en 2021 ; backtester dessus, c'est utiliser une science forensique rétrospective (§1.1.4). S'ajoutent les timestamps (mélange d'heure d'échange, d'heure de bloc et d'heure de réception ; le règlement du funding à 00/08/16 UTC qui doit être attribué au bon côté de la barrière), et le wash trading, qui est un problème point-in-time au second degré : les volumes historiques des venues de second rang sont partiellement fictifs, et les *estimations* de volume réel sont elles-mêmes des séries

révisées à mesure que les méthodes de détection progressent (§2.2.5, §5.2.4).

Le test qui coiffe les quatre feuilles de ce sous-nœud : la *reproduction à date* — pouvoir rejouer le calcul du signal au jour t en n'utilisant que le snapshot de la base telle qu'elle existait ce jour-là, et retrouver le backtest au bit près. Ce test ne se code pas après coup ; il se conçoit dans le schéma de données dès l'origine (§6.1, §6.2).

Ce nœud produit les prédicteurs candidats que la normalisation (§1.3) rendra combinables et que la branche 2 filtrera — les deux communiquent en permanence, chaque degré de liberté pris ici étant une dette remboursée là-bas. Il pointe aussi deux fois vers la combinaison (le banc multi-échelles et les IC conditionnels par bande et par régime sont des inputs directs de §3), et pose la question du registre des essais qui appartient à l'infrastructure (§6.2).

Renvois : §0.2 (filtration) ; §0.5–§0.6 (notations, conventions) ; §1.1 (familles : les prédicteurs transformés ici) ; §1.3 (normalisation, turnover analytique) ; §1.4.1–§1.4.2 (cibles vol-scalées, chevauchement) ; §2.2.3 (delistings), §2.2.5 (nettoyage crypto) ; §2.3.1–§2.3.5 (purge, DSR, N effectif, pré-spécification, holdout) ; §2.4.3–§2.4.4 (persistance par famille, histoires courtes) ; §3 (combinaison des échelles et des régimes) ; §3.4.1 (valeur marginale du résidu) ; §4.1.1, §4.1.4 (Barra, Vasicek — encadré A) ; §4.4.1 (sizing) ; §5.1.1, §5.2.1, §5.2.4, §5.4.2 (microstructure, impact, mesure) ; §6.1–§6.2 (bitemporel, capture propriétaire, registre, replay) ; encadrés D (chevauchement) et E (surveillance séquentielle).

Chapter 4

§1.3 Normalisation

État : relu (intégré s.3, harmonisé s.14 — renvois et notation vérifiés) — sources : M043 ; §1.3.4 enrichi de M062 (demi-vies), M064 (autocorrélation), M066 (turnover), conformément à M068 ; vérification des chiffres à venir.

La normalisation est le dernier étage du pipeline de génération : elle reçoit les prédicteurs candidats du feature engineering (§1.2) et produit l'objet que la branche 3 attend en entrée — des vecteurs approximativement $N(0,1)$, winsorisés, neutralisés, lissés. C'est ici que le signal devient *combinable* : comparable entre signaux, entre dates et entre univers, purgé de ses expositions non voulues, et doté d'un profil de turnover connu avant même le backtest. Les quatre sous-nœuds suivent l'ordre des opérations : standardisation cross-sectionnelle, standardisation temporelle, neutralisation, smoothing.

1.3.1 Cross-sectionnelle — rendre les titres comparables à date fixe

L'ordre des opérations compte : *winsoriser d'abord, standardiser ensuite* — dans l'autre sens, l'outlier qu'on voulait dompter a déjà contaminé la moyenne et l'écart-type qui servent à le mesurer. La winsorisation elle-même se fait aux quantiles (1%/99%) ou, plus robuste, en unités de MAD (écart absolu médian, borné à $\pm 3-4$ MAD autour de la médiane) — le MAD est insensible aux queues par construction, là où l'écart-type est précisément déformé par ce qu'on cherche à écrêter. Puis le z-score cross-sectionnel : $(x - \mu_{cs}) / \sigma_{cs}$ à chaque date, qui centre le signal (espérance de position nette nulle — le signal devient intrinsèquement relatif, §0.1) et fixe son échelle.

L'alternative radicale : les *rangs*, transformés en quantiles uniformes puis passés par l'inverse de la CDF gaussienne — la rank-gaussianisation. Ses vertus : invariance totale aux transformations monotones de la feature (plus aucun débat sur log vs niveau en amont), robustesse absolue aux outliers, distribution de sortie identique chaque jour. Son coût, réel mais souvent mal évalué : elle jette l'information de *distance* — le titre 1er et le titre 2^e sont à écart constant même si l'un est extraordinairement extrême — or pour certaines familles (les surprises d'earnings notamment, §1.1.5), l'intensité porte de l'IC au-delà de l'ordre. Le compromis mûr : rank-gaussianiser par défaut (la robustesse gagne en espérance), garder le z winsorisé pour les signaux dont l'intensité est démontrablement informative. Une subtilité de design souvent invisible : standardiser σ_{cs} chaque jour *efface la dynamique de dispersion du signal* — les jours où le signal discrimine fort et les jours où il ne dit rien deviennent identiques en sortie. C'est un choix, pas une neutralité : si la dispersion du signal est elle-même prédictive (elle l'est parfois — une forte dispersion des surprises annonce un cross-section plus rémunérateur), cette information doit être ré-injectée explicitement comme variable de conditionnement (§1.2.3), sinon elle meurt ici. Enfin le petit univers : avec 100-300 tokens crypto, μ_{cs} et σ_{cs} sont eux-mêmes bruités et la gaussianisation devient quasi obligatoire — un z-score sur 100 points dont 5 outliers n'a pas de sens statistique.

1.3.2 Temporelle — la surprise par rapport à sa propre histoire

Le pendant time-series : $(x - \text{EMA}(x)) / \text{volEMA}(x)$, avec des demi-vies d'1 à 3 ans — chaque signal devient « à combien d'écarts-types suis-je de mon régime récent », comparable entre instruments et entre signaux sans référence à un cross-section. C'est la normalisation naturelle des stratégies

par instrument (trend, carry par marché) et elle véhicule une philosophie différente : le z cross-sectionnel force la neutralité dollar par construction (on est toujours long les uns contre les autres), le z temporel autorise le *net directionnel* — tout l'univers peut être simultanément à $+2\sigma$. Un desk equity/crypto complet mixe les deux : les sleeves cross-sectionnels pour l'alpha relatif, les sleeves temporels pour le timing directionnel, et la normalisation est précisément ce qui permet de les faire cohabiter dans la même combinaison (§0.1, §3).

Le second étage est la *réponse bornée* : clip à ± 2 ou ± 3 , tanh, ou la fonction $x \cdot \exp(-x^2/4)$ du répertoire AHL (§1.2.2) — croissante jusqu'à $|x| \approx 1,4$ puis *décroissante*. Le clip et le tanh disent « au-delà d'un certain extrême, je ne sais plus discriminer » ; la réponse en cloche dit davantage : « un signal très extrême est moins fiable qu'un signal modérément fort ». Les deux justifications se superposent — statistique (les queues de la relation signal-rendement sont estimées sur une poignée d'observations ; y extrapoler la pente du centre est de la foi, pas de l'inférence) et économique (un momentum à $+4\sigma$ décrit un actif en régime parabolique où la dynamique de retournement change de nature ; un carry à $+4\sigma$ signale souvent un risque que le marché price, pas une aubaine). La réponse bornée est aussi ce qui protège l'aval : sans elle, l'optimiseur (§4.2) reçoit des forecasts extrêmes qui écrasent les contraintes et concentrent le book exactement sur les points de données les moins fiables.

1.3.3 Neutralisation — la purge des expositions non voulues

Deux mécaniques emboîtées. Le *démoyennage par groupe* : soustraire à chaque titre la moyenne de son secteur/industrie/cluster — le signal devient strictement within, et le pari sectoriel implicite disparaît (on a vu en §1.2.1 pourquoi : un value non démoynné est un pari permanent banques-contre-tech). En crypto, les « secteurs » sont les clusters fonctionnels — L1, DeFi, memes, infrastructure — soit taxonomiques, soit dérivés d'un clustering de corrélation (§4.1.4) qui a l'avantage de suivre les recompositions du marché sans comité de nomenclature. Puis la *résidualisation factorielle du signal* : régresser, à chaque date, le vecteur de signal sur les loadings du modèle de risque (beta, taille, vol, momentum factoriel...) et garder le résidu — la généralisation continue du démoynnage, qui purge toutes les expositions linéaires d'un coup.

Le point structurant est le *pourquoi*, et il est en aval : si l'optimiseur (§4.2) contraint les expositions factorielles à zéro, alors la composante factorielle d'un signal non neutralisé sera *jetée au moment de la construction du portefeuille* — le signal mesuré en standalone avec son IC de 0,04 n'en transfère peut-être que la moitié une fois ses expositions retirées. Neutraliser en amont aligne ce qu'on mesure sur ce qu'on utilise : l'IC du signal neutralisé est l'IC *transférable*, et le transfert coefficient (§0.4, §4.2.3) se rapproche de 1. C'est le contrat d'interface entre la génération et le portefeuille qui trouve ici sa forme technique — et il explique une asymétrie organisationnelle : dans une usine à alphas, la neutralisation est imposée au chercheur (le signal soumis doit être orthogonal au modèle de risque maison), parce que c'est la seule façon de rendre les IC standalone additifs et comparables entre chercheurs (§3.4.4, §6.4). Cohérence méthodologique : si le signal est neutralisé, la *cible* de son évaluation doit l'être aussi (rendements résiduels, §1.4.1) — mesurer un signal neutralisé contre des rendements bruts mélange à nouveau ce qu'on vient de séparer. La frontière alpha/beta étant relative au modèle de risque (§0.7), la neutralisation est l'acte qui définit opérationnellement ce que la maison appelle alpha.

1.3.4 Smoothing & turnover — le dernier curseur avant la sortie

Les objets d'abord, car l'arbitrage de ce sous-nœud se joue sur trois quantités qu'il faut définir proprement. L'*autocorrélation* d'ordre k d'une série stationnaire st est $\rho(k) = \text{cov}(st, st+k)/\text{var}(st)$, avec $\rho(0) = 1$; dans un panel, la version pertinente est **cross-sectionnelle** :

$$\text{pcs}(k) = \text{moyennet} [\text{corr}(s_t, s_{t+k})]$$

— à chaque date, la corrélation entre le vecteur de signal sur les N actifs et ce même vecteur k jours plus tard. C'est elle qui gouverne le turnover, parce que les positions dépendent du *classement relatif* : si tous les signaux se décalent d'une constante, les séries par actif bougent mais le vecteur cross-sectionnel est inchangé, et aucun trade n'est déclenché — la version par actif sures-time le turnover. Rien ne garantit une décroissance exponentielle : $\rho(k) = \rho^k$ n'est exact que pour

un AR(1) — précisément le cas d'une feature lissée par EMA, d'où la commodité de l'approximation ; un signal événementiel a un profil tout autre (chute brutale puis plateau), et il vaut mieux tracer le corrélogramme ($k = 1, 2, 5, 10, 21$) que se contenter d'un chiffre, exactement comme pour le profil de decay de l'IC (§2.1.2). La *demi-vie du signal* s'en déduit : si $\rho(k) \approx \rho^k$, $H_s = -\ln 2 / \ln \rho$ — une propriété *mesurée* du signal, à distinguer de la demi-vie de pondération H (le paramètre de construction de l'EMA, §0.5, §1.2.2) et de la demi-vie de l'alpha H_α (la vitesse de decay de l'IC quand h s'allonge — une propriété du *marché*, mesurée en §2.1.2, dont $\varphi = \ln 2 / H_\alpha$). Lisser une feature avec une EMA de demi-vie H fabrique un signal dont H_s est au moins H : c'est tout le levier du smoothing. Le *turnover* enfin : la fraction du portefeuille remplacée par unité de temps,

$$\text{turnover} = \sum_i |w_{i,t} - \tilde{w}_{i,t-1}|$$

où $\tilde{w}_{i,t-1}$ est le poids de la veille **après dérive de marché** — pas le poids cible d'hier (un titre qui monte de 3% voit son poids augmenter sans qu'aucun ordre ne soit passé ; ignorer cette dérive fabrique des trades fantômes dans le backtest). Attention à la convention one-way vs two-way : un facteur 2 sur les coûts se cache dans ce choix, et les chiffres publiés sont rarement explicites. Sous hypothèse gaussienne, si les positions sont proportionnelles au signal, $st - st-1$ a pour variance $2\sigma^2(1-\rho(1))$, d'où la formule qui relie tout :

$$\text{turnover} \propto \sqrt{(1 - \rho(1))}$$

Un signal à $\rho(1) = 0,99$ tourne dix fois moins qu'un signal à $\rho(1) = 0,90$ — la sensibilité des coûts à cette seule statistique est extrême, et c'est elle qui permet de *budgéter les coûts avant même de backtester*. Pour une demi-vie longue, $1-\rho \approx \ln 2 / H_s$: le turnover décroît comme $1/\sqrt{H_s}$, doubler la demi-vie divise les coûts par $\sqrt{2}$. Même canal pour le breadth (§0.4) : un signal de demi-vie 20 jours ne produit pas 252 paris indépendants par an mais de l'ordre de $252/H_s \approx 12$.

L'EMA finale sur le signal est alors l'endroit où l'arbitrage IC/coûts se règle explicitement. Les deux termes sont quantifiables : le lissage retarde le signal, et son coût en IC se lit directement sur le profil de decay mesuré en §2.1.2 — un signal dont l'IC est plat sur 21 jours perd presque rien à une EMA de 5 jours, un reversal à demi-vie de 3 jours y perd l'essentiel ; en face, le turnover décroît de façon également calculable par la formule ci-dessus. Le critère est l'IC *net* : IC(lissage) – coût unitaire $\times$ turnover(lissage), maximisé en un point qui dépend du ratio entre le decay du signal et le niveau de coûts — d'où la conclusion structurante : à coûts élevés (compte propre, crypto hors majors — quelques points de base par aller-retour en large caps US, plusieurs dizaines sur les alts), le turnover est le déterminant, et le signal lent à IC modeste bat le signal rapide à IC flatteur. À 10 bps de coût unitaire, un turnover annuel de 2 000% consomme 2% de performance par an — souvent l'essentiel de ce que le signal rapporte brut. L'arbitrage central se lit dans la comparaison des demi-vies : la demi-vie du signal doit être **commensurable avec celle de l'alpha** — un signal qui persiste bien plus longtemps que son pouvoir prédictif porte des positions périmées, un signal qui tourne bien plus vite paie des coûts pour une information qui n'avait pas encore changé ; le smoothing optimal est celui qui aligne les deux.

La question architecturale qui referme le nœud : le lissage peut vivre *dans le signal* (chaque chercheur lisse le sien) ou *dans l'optimiseur* (bandes de non-trading, pénalités de transaction, §4.3.2). Ce sont deux implémentations du même arbitrage, mais pas équivalentes : l'optimiseur voit le book entier et peut netter les trades entre signaux (deux signaux qui se croisent n'exigent aucun trade — le lissage par signal l'ignore et sur-lisse), mais le lissage amont produit des signaux dont l'IC mesuré est directement l'IC exploitable, et il protège contre un optimiseur mal calibré. La pratique dominante : un lissage amont modéré (retirer le bruit haute fréquence sans espérance) plus la gestion fine du turnover dans l'optimiseur — et un *budget de turnover par sleeve*, fixé en gouvernance, qui transforme l'arbitrage en contrainte explicite plutôt qu'en propriété émergente (§0.8, le second budget).

La sortie de ce pipeline est exactement l'objet que la branche 3 attend en entrée — vecteurs $\sim N(0,1)$, winsorisés, neutralisés, lissés — et la boucle génération $\rightarrow$ combinaison est bouclée. Deux points d'ancrage vers la mise en œuvre sont posés ici : le modèle de risque de §4.1 qui définit ce que « neutraliser » veut dire, et les bandes de §4.3.2 qui dialoguent avec le smoothing.

Renvois : §0.1 (CS vs TS), §0.4 (TC, breadth), §0.5 (H, λ, φ), §0.7 (frontière alpha/beta), §0.8 (les deux budgets) ; §1.1.5 (intensité des surprises) ; §1.2.1–§1.2.3 (within, banc AHL, conditionnement) ; §1.4.1 (cohérence cible/signal) ; §2.1.2 (profil de decay — où se mesure $H\alpha$) ; §3 (l'interface), §3.4.4 (usine : IC additifs) ; §4.1.4 (clusters crypto), §4.2 (optimiseur, TC), §4.3.2 (bandes de non-trading) ; §6.4 (neutralisation imposée au chercheur).

Chapter 5

§1.4 Cibles & labels

État : relu (intégré s.3, harmonisé s.14 — renvois et notation vérifiés) — source : M102
; vérification des chiffres à venir.

Dernier nœud de la branche 1, et découverte du gel du squelette : définir le y avant de chercher le $f(x)$. Les trois nœuds précédents ont construit le x — les familles (§1.1), leurs transformations (§1.2), leur normalisation (§1.3) ; celui-ci construit *ce qu'on prédit*. Son principe traverse les quatre sous-nœuds : la cible fait partie de l'hypothèse — le même x contre deux y différents donne deux IC différents, deux signaux différents, et la moitié des faux alphas de la littérature sont des artefacts de cible.

1.4.1 Le choix de la cible — la cible définit l'alpha

Le y naïf est le rendement brut $r_{i,t \rightarrow t+h}$. Trois transformations le dominant presque toujours, chacune répondant à un défaut identifié ailleurs dans l'arbre. Le **vol-scaling** :

$$y_i = r_{i,t \rightarrow t+h} / \hat{\sigma}_{i,t}$$

avec $\hat{\sigma}$ l'EWMA de §1.2.2 — il égalise la contribution des actifs (sans lui, les titres volatils dominant toute régression et tout IC de Pearson), stabilise l'IC à travers les régimes (la relation signal→rendement est plus stationnaire en unités de risque qu'en unités de prix), et empêche un modèle ML de dépenser sa capacité à apprendre la volatilité au lieu de la direction — la raison pour laquelle Gu-Kelly-Xiu et toute la pratique passent en cibles normalisées (§1.2.3). La **résidualisation** : $y_i = \epsilon_i$ (le rendement net des facteurs de §4.1) — la cohérence méthodologique de §1.3.3 rendue obligatoire : un signal neutralisé mesuré contre des rendements bruts mélange ce qu'on vient de séparer, et son IC mesuré n'est pas son IC transférable. Le **démoyennage cross-sectionnel** : $y_i - \bar{y}_t$, la version minimale de la précédente (retirer le marché du jour), implicite dès qu'on mesure un rank IC mais qui doit être *explicite* dès qu'on entraîne un modèle. En crypto s'ajoute la correction déjà établie (§1.2.1) : le rendement d'une jambe perp est **funding inclus** — $y = \Delta p/p + \Sigma$ funding reçus — et celui d'une jambe short spot est net du coût d'emprunt ; une cible qui les omet fabrique de faux alphas de carry, exactement comme le rendement prix vs total en equity (§0.6, §2.2).

Le principe qui coiffe le nœud : la cible fait partie de l'hypothèse. « Momentum prédit le rendement brut » et « momentum prédit le rendement résiduel vol-scalé » sont deux affirmations distinctes, la seconde étant celle qui survit aux crashes de momentum (§1.2.1, le momentum factoriel). Le choix de y est donc **pré-spécifié** avec le signal (§1.2.3, §2.3.5), et en changer compte comme un essai.

1.4.2 Horizons et chevauchement — la structure du y dans le temps

Le choix de h d'abord : il n'est pas unique — la *term structure* de l'IC ($h = 1, 2, 5, 10, 21$, §2.1.2) est l'objet complet, et le h de production se choisit en regard du decay, du turnover et des coûts (§1.3.4, §4.3.3). La convention de calcul ensuite, héritée de §2.2 : le rendement forward court de l'exécution réalisable — clôture de $t \rightarrow$ signal, puis y mesuré de l'ouverture (ou clôture) de $t+1$ à $t+1+h$ — jamais de la clôture de t , le look-ahead d'un jour qui fabrique des IC de reversal fictifs sur le bid-ask bounce (§5.1.1, l'autocovariance de Roll transformée en faux alpha).

Le chevauchement enfin, troisième apparition du même théorème (encadré D) : échantillonner quotidiennement avec $h > 1$ rend les labels consécutifs **MA(h-1)** — y_t et y_{t+1} partagent $h-1$ jours — d'où trois conséquences chiffrées. L'inférence : les erreurs types naïves se corrigent par Newey-West avec $\text{lag} \geq h$ ou block bootstrap à blocs $> h$ (§2.2.1, §3.1.3). La taille d'échantillon : le nombre d'observations *effectivement indépendantes* est $\approx T/h$ — dix ans de labels mensuels chevauchants font ~ 120 points, pas 2 500, le chiffre qui calibre toutes les ambitions de la branche 2. La validation : le purging et l'embargo de §2.3.1 sont précisément la traduction du chevauchement en protocole de CV — la largeur de purge *est* h . L'alternative (échantillonner tous les h jours, labels disjoints) jette de l'information sans supprimer le problème (le choix de la phase devient un degré de liberté) : la pratique correcte est chevauchement assumé + inférence corrigée + pondération d'unicité (§1.4.4).

1.4.3 Labels alternatifs — quand le rendement à date fixe n'est pas le bon objet

Le rendement à horizon fixe ignore le *chemin* — or le trading réel a des stops, des prises de profit, des sorties anticipées. Le **triple-barrier** de López de Prado (AFML, 2018) labellise au premier franchissement : barrière haute à $+u \cdot \hat{\sigma}$, basse à $-d \cdot \hat{\sigma}$ (toutes deux vol-scalées — les barrières fixes en prix sont un non-sens cross-sectionnel), barrière verticale à $t+T_{\max}$; le label est le signe du franchissement (ou le rendement au moment du toucher). Il encode la dépendance au chemin, aligne le label sur la structure de sortie effective, et produit des durées de vie *variables* par observation — d'où la comptabilité d'**unicité** associée (§1.4.4). Le **meta-labeling** (même source) sépare la direction de la taille : un modèle primaire (souvent un signal simple, ou un prior économique) donne le *côté* ; le modèle secondaire apprend $P(\text{le primaire a raison} \mid \text{features})$ — un problème de classification binaire dont la sortie calibrée pilote le *sizing* (parier gros quand le primaire est fiable, zéro sinon). L'intérêt structurel : on améliore la précision sans toucher au rappel du primaire, on rend le ML auditable (il ne décide jamais du côté — le prior économique de §1.2.3 reste aux commandes), et la sortie probabiliste se branche directement sur le Kelly fractionnel de §4.4.2. Enfin les **labels de rang** : $y = \text{rang cross-sectionnel gaussianisé du rendement}$ — le pendant cible de la rank-gaussianisation de §1.3.1, qui immunise l'entraînement contre les queues du y exactement comme elle immunisait les features, au même coût (l'intensité perdue).

1.4.4 Régression, classification, ranking — aligner la loss sur l'usage

Le principe directeur : la fonction de perte de l'entraînement doit ressembler à la métrique d'évaluation (le rank IC, §2.1.1) et à l'usage (trier un cross-section, §4.2) — tout écart est une fuite de performance silencieuse. La **régression** L2 sur rendements utilise toute l'information mais hérite des queues : sur un y leptokurtique, quelques observations dominent le gradient — d'où la perte de **Huber** (quadratique sous un seuil δH , linéaire au-delà), dont Gu-Kelly-Xiu documentent le gain systématique sur données financières, ou la régression sur cibles rank-gaussianisées qui règle le problème à la source. La **classification** sur le signe est robuste mais bute sur le voisinage de zéro : la moitié des labels sont des micro-rendements de signe aléatoire — du bruit d'étiquetage pur ; les corrections standard — exclure la bande $|y| < c \cdot \sigma$ (la bande morte), ou pondérer chaque observation par $|y|$ — reconstruisent de facto une régression robuste. Le **ranking** est l'alignement maximal : des objectifs pairwise/listwise (la famille LambdaRank) optimisent directement l'ordre du cross-section — ce que le portefeuille consomme — au prix d'un entraînement plus lourd ; l'approximation praticienne dominante reste la régression sur cibles en rangs, qui en capture l'essentiel.

Transversal aux trois : la **pondération des observations**. Deux poids se composent — l'*unicité* (AFML) : chaque observation pèse $1/(\text{nombre de labels vivants qui la partagent})$, la correction exacte du chevauchement de §1.4.2 au niveau de l'entraînement (sans elle, un modèle ML sur labels chevauchants sur-apprend les épisodes longs, qui votent h fois) ; et la *récence* : une demi-vie sur les poids (2-4 ans, §2.4) qui encode la non-stationnarité dans la loss plutôt que dans un découpage arbitraire de l'échantillon.

Références du nœud : López de Prado, *Advances in Financial Machine Learning* (2018, chap. 3-4 — triple-barrier, meta-labeling, unicité) ; Gu, Kelly & Xiu (2020 — Huber, cibles normalisées) ; Grinold & Kahn pour le rendement résiduel comme objet natif de la gestion active ; Qian, Hua & Sorensen pour la cohérence cible/signal/IC.

La branche 1 se clôt ici : familles, transformations, normalisation, cibles — le pipeline complet qui produit des couples (signal, cible) pré-spécifiés. Le fil du nœud : le y est une *décision de design* au même titre que les features — vol-scalé, résiduel, funding inclus, pré-spécifié. Ce que la branche 2 reçoit n'est pas un signal isolé mais cette hypothèse jointe, et c'est elle qu'elle va tester.

Renvois : §0.6 (funding inclus, conventions) ; §1.2.1–§1.2.3 (features, EWMA, prior aux commandes) ; §1.3.1, §1.3.3–§1.3.4 (rank-gauss, neutralisation, decay/turnover) ; §2.1.1–§2.1.2 (rank IC, term structure) ; §2.2 (timeline, rendements totaux) ; §2.3.1, §2.3.5 (purge = h, pré-spécification) ; §2.4 (récence, non-stationnarité) ; §3.1.3 (NW sur la série des IC) ; §4.1 (facteurs), §4.2 (l'usage : trier), §4.3.3 (h vs coûts), §4.4.2 (Kelly fractionnel) ; §5.1.1 (Roll, bid-ask bounce) ; encadré D (chevauchement).

Chapter 6

§2.1 Métriques du signal

État : relu (intégré s.4, harmonisé s.14 — renvois et notation vérifiés) — source : M114
(+ cadrage M012) ; vérification des chiffres à venir.

La branche 2 est le système immunitaire de la recherche : elle reçoit les couples (signal, cible) pré-spécifiés que la branche 1 produit, et décide de ce qui mérite d'être cru. Son premier nœud établit la fiche d'identité complète d'un alpha — tout ce qu'on mesure avant de croire un signal : l'IC et son inférence, le profil de decay, les sorts, la viabilité économique, les expositions résiduelles. Le régime de travail est celui du très faible ratio signal/bruit (§0.3 : $R^2 \approx IC^2 \sim 10^{-3}$), et chaque métrique de ce nœud existe pour séparer, dans ce bruit, ce qui se mesure de ce qui s'invente.

2.1.1 Rank IC et son inférence — le plancher de bruit

La définition est posée (§0.3) : $IC_t = \text{corrSpearman}(s, t, r, t \rightarrow t+h)$ sur les N_t actifs, puis la série $\{IC_t\}$ se résume par sa moyenne et son ICIR. Ce qui manquait est l'inférence *par date* : sous l'hypothèse nulle d'indépendance, une corrélation cross-sectionnelle sur N points a pour écart-type

$$\sigma_0(IC_t) = 1/\sqrt{(N_t - 1)}$$

— avec $N = 3\,000$, le plancher vaut $\approx 0,018$; avec 150 tokens, $\approx 0,082$. Première conséquence : un IC quotidien de 0,03 est à peine au-dessus du bruit *d'une date* — c'est l'agrégation temporelle qui crée la significativité ($t = IC/(\sigma(IC)/\sqrt{T})$, Newey-West dès que $h > 1$, §3.1.3, encadré D). Seconde conséquence, la **décomposition de $\sigma(IC)$** : la variance observée de la série des IC se partage en

$$\sigma^2(IC) = 1/(N_{\text{eff}} - 1) [\text{plancher de mesure}] + \tau^2 IC [\text{variation vraie du pouvoir prédictif}]$$

où $N_{\text{eff}} < N$ à cause de la corrélation résiduelle entre titres — les secteurs font qu'un cross-section de 3 000 noms porte l'équivalent de quelques centaines de paris indépendants ; c'est le même N_{eff} que le breadth de §0.4, mesurable par $1/\Sigma \tilde{w}_i^2$ sur les poids de la structure de corrélation, ou simplement par la variance des IC d'un signal *aléatoire* sur le même univers — le contrôle placebo qui étalonne le plancher empiriquement (§2.2.5, §6.2). La part $\tau^2 IC$ est celle qui intéresse le conditionnement (§1.2.3, §3.1.3) ; la part plancher est irréductible — un signal *parfaitement* stable affiche quand même un $\sigma(IC) \geq 1/\sqrt{N_{\text{eff}}}$, et l'ICIR a donc un **plafond mécanique** $\approx IC \cdot \sqrt{N_{\text{eff}}}$ qu'aucun talent ne dépasse. Le diagnostic complémentaire : l'écart rank IC vs Pearson IC — un Pearson sensiblement supérieur signale que la valeur vit dans les queues (surprises, §1.3.1) ; nettement inférieur, que quelques outliers portent tout. Références : Grinold & Kahn ; Qian, Hua & Sorensen (la décomposition y est développée) ; Lo 2002 pour le pont vers l'inférence sur Sharpe (§2.3.2).

2.1.2 Profil de decay — la structure à terme de l'alpha

Deux objets distincts, souvent confondus. L'**IC retardé** : $IClag_k = \text{corr}(st, rt+k \rightarrow t+k+1)$ — le pouvoir prédictif du signal d'aujourd'hui sur le rendement de la *seule* période $t+k$; c'est la réponse impulsionnelle du signal. L'**IC cumulé** : $ICcum(h) = \text{corr}(st, rt \rightarrow t+h)$ — celui de §0.3, qui *intègre* les retardés (approximativement $ICcum(h) \approx \Sigma_k IClag_k / \sqrt{h}$ sous corrélations faibles : le cumulé croît tant que les retardés restent positifs, puis plafonne et décroît en $1/\sqrt{h}$ une fois l'information épuisée

— le maximum du cumulé désigne l'horizon naturel du signal). L'ajustement paramétrique standard sur les retardés,

$$IClagk \approx IC_0 \cdot e^{-k/H_\alpha}, \varphi = \ln 2 / H_\alpha$$

fournit directement le φ de Gârleanu-Pedersen (§4.3.3) et de l'urgence d'exécution (§5.3.3) — c'est *ici* que se mesure le paramètre que toute la mise en œuvre consomme, la raison pour laquelle le ticket d'exécution transporte φ et pour laquelle l'interface de combinaison le véhicule (§3.4.5). Trois précautions de mesure : le chevauchement (les IC cumulés à h long sont massivement autocorrélés — blocs $> h$ au bootstrap, §1.4.2) ; le **biais de sélection d'horizon** — un signal *retenu* pour son IC à $h = 5$ régresse vers la moyenne aux autres horizons, donc le profil de decay se mesure sur données postérieures à la sélection ou en CV, jamais sur l'échantillon qui a servi à choisir h ; et pour les signaux événementiels (§1.1.5), le decay se trace en **temps d'événement** (jours depuis l'annonce), pas en temps calendaire — le mélange des deux aplatit artificiellement le profil.

2.1.3 Portfolio sorts — la version non paramétrique, et ses pièges de composition

La construction : à chaque date, trier en Q quantiles (déciles en equity, terciles-quintiles en crypto — §1.2.3, la contrainte du petit univers), calculer le rendement de chaque quantile, et le spread long-short $Q_{haut} - Q_{bas}$ avec son t -stat Newey-West. Les deux choix de composition qui changent les conclusions : **équipondéré vs cap-pondéré** — l'équipondéré sur-représente les micro-caps illiquides, et le résultat de référence est Hou, Xue & Zhang (« Replicating Anomalies », RFS 2020) : sur 452 anomalies publiées, 65 % échouent au seuil $|t| \geq 1,96$ une fois les micro-caps neutralisées (VW, breakpoints NYSE) — et 82 % au seuil $t \geq 2,78$ du multiple testing — le filtre de réplication minimal avant de croire un sort ; et **la monotonie** — un vrai signal produit des rendements croissants à travers *tous* les quantiles, testable proprement par Patton & Timmermann (« Monotonicity in asset returns », Journal of Econometrics 2010) : H_0 de non-monotonie contre l'alternative de croissance stricte sur toutes les paires adjacentes, par bootstrap — le test qui distingue un signal d'un artefact de cellule extrême (§1.2.3, même logique que les double sorts).

La **symétrie long/short** ensuite : décomposer le spread en (Q_{haut} – marché) et (marché – Q_{bas}). Beaucoup d'anomalies vivent côté short — et le short a des coûts propres : frais d'emprunt, rappels, hard-to-borrow. Drechsler & Drechsler (« The Shorting Premium », 2014) montrent que l'essentiel du rendement des anomalies classiques se concentre dans les titres chers à emprunter — l'alpha brut y est réel, l'alpha *net des frais d'emprunt* largement illusoire ; le sort honnête intègre le fee d'emprunt par titre dans le rendement du short (donnée §6.1, avec son lag de disponibilité §1.2.4). En crypto, la transposition : le « frais d'emprunt » du short est le funding payé/reçu (§1.4.1), déjà dans la cible si elle est bien construite.

2.1.4 Turnover, coverage, capacité — la viabilité avant la beauté

Le turnover du signal se lit dans son autocorrélation cross-sectionnelle ($\propto \sqrt{(1-\rho_{cs}(1))}$, §1.3.4), et la métrique de viabilité est le **break-even de coût** :

$$c^* = \text{spread brut annualisé} / \text{turnover annualisé (en bps par unité tradée)}$$

— le coût unitaire au-delà duquel le signal est mort. Un reversal à spread brut de 8%/an et turnover $40\times$ a un c^* de 20 bps : viable en large caps US, mort sur les alts ; un signal de qualité à 3%/an et turnover $2\times$ a un c^* de 150 bps : viable partout. C'est la statistique qui ordonne les signaux *par marché d'application*, et Novy-Marx & Velikov (« A Taxonomy of Anomalies and their Trading Costs », RFS 2016) en donnent la cartographie systématique — anomalies classées par turnover, coûts effectifs mesurés, et l'effet des techniques d'atténuation (bandes, §4.3.2 : elles sauvent une classe entière de signaux moyenne-fréquence). La **coverage** ensuite : la fraction de l'univers où le signal est défini — une coverage partielle et *variable* (données fondamentales manquantes, événements) réduit le breadth effectif, biaise la normalisation cross-sectionnelle (§1.3.1 : le z -score d'un sous-univers n'est pas celui de l'univers), et exige la règle : normaliser sur l'univers couvert, positionner zéro hors couverture, et *mesurer* la stabilité de la couverture dans le temps. La capacité enfin renvoie à §4.4.4 ($A^* \propto ADV \cdot \alpha^2 / \tau^3$), avec le diagnostic rapide au niveau signal : recalculer le spread sous filtres

de liquidité croissants et en VW — la pente de dégradation est le profil de capacité, et un spread qui s'effondre au premier filtre annonce un A* dérisoire.

2.1.5 Expositions résiduelles — ce qui reste quand les facteurs sont servis

Deux mesures complémentaires du même objet. **Returns-based** : régresser la série du spread long-short sur les rendements factoriels,

$$rLSt = \alpha + \beta'Ft + \varepsilon_t, F = \{MKT, SMB, HML, RMW, CMA, MOM, \dots\}$$

— le $t(\alpha)$ Newey-West est la statistique finale (« l'anomalie survit-elle aux facteurs ? »), les β diagnostiquent le déguisement (un « nouveau » signal à $\beta HML = 0,8$ est du value réempaqueté), et le R^2 dit quelle part du sort est du beta recyclé. Cadres : Fama-French (1993, JFE ; 2015, JFE pour le cinq-facteurs), Carhart (1997) pour MOM. **Holdings-based** : à chaque date, les expositions du portefeuille de signal $bt = Bt'wt$ via le modèle de risque de §4.1 — instantané là où le returns-based est moyen, il capte le *style drift* (un signal dont le β momentum oscille entre $-0,5$ et $+0,5$ a un β moyen nul et un problème réel) et c'est lui que l'optimiseur contraindra (§4.2.2). La cohérence des deux est un test en soi ; leur divergence signale un modèle de risque incomplet ou des expositions non linéaires. Et la clôture conceptuelle, triple renvoi : ce qui survit ici est l'alpha *au sens du modèle choisi* (§0.7 — changer de F déplace la frontière), c'est l'IC *transférable* que la neutralisation amont visait (§1.3.3), et c'est l'entrée du test d'admission au pool (§3.4 — l'IC marginal étant l'exposition résiduelle *au pool lui-même* plutôt qu'aux facteurs).

Le quintet à retenir : plancher $1/\sqrt{(Neff-1)}$ et plafond d'ICIR ; IC retardé vs cumulé et $\varphi = \ln 2/H\alpha$ mesuré ici ; le filtre Hou-Xue-Zhang avant de croire un sort ; $c^* = \text{spread/turnover}$; $t(\alpha)$ Newey-West comme juge de paix. Ce nœud fournit trois objets que le reste de l'arbre consomme : φ (vers §4.3.3 et §5.3.3), le plancher placebo (étalon du moteur, §6.2), et l'IC transférables (entrée du pool, §3.4).

Renvois : §0.3–§0.4 (IC/ICIR, breadth) ; §0.7 (frontière relative au modèle) ; §1.1.5 (temps d'événement) ; §1.2.3–§1.2.4 (conditionnement, lags de données) ; §1.3.1, §1.3.3–§1.3.4 (queues, neutralisation, turnover) ; §1.4.1–§1.4.2 (funding dans la cible, chevauchement) ; §2.2.5 (placebo), §2.3.2 (inférence sur Sharpe) ; §3.1.3 (NW sur les IC), §3.4 (admission au pool), §3.4.5 (l'interface transporte φ) ; §4.1 (modèle de risque), §4.2.2 (contraintes), §4.3.2–§4.3.3 (bandes, GP), §4.4.4 (capacité) ; §5.3.3 (urgence) ; §6.1 (données d'emprunt), §6.2 (placebo étalonné) ; encadré D.

Chapter 7

§2.2 Backtest cross-sectionnel

État : relu (intégré s.4, harmonisé s.14 — renvois et notation vérifiés) — source : M116
; vérification des chiffres à venir.

Deuxième nœud de la branche 2 : la machinerie de simulation — mesurer proprement ce qu'on aurait gagné. Là où §2.1 mesure le signal, ce nœud construit l'expérience qui produit ces mesures : la régression qui est un portefeuille, la timeline contractuelle, l'univers point-in-time, les coûts simulés, et le nettoyage spécifique de l'univers crypto. Sa certification finale est un placebo : le protocole complet appliqué à un signal aléatoire doit rendre exactement le bruit.

2.2.1 Fama-MacBeth — la régression qui est un portefeuille

La procédure (Fama & MacBeth, « Risk, Return, and Equilibrium », JPE 1973), dans sa version caractéristiques (la nôtre — le signal *est* le régresseur, pas un beta estimé) : à chaque date, la régression cross-sectionnelle

$$r_{i,t \rightarrow t+h} = \gamma_{0,t} + \gamma_{1,t} \cdot s_{i,t} + \gamma'_{2,t} \cdot Z_{i,t} + e_{i,t}$$

avec Z les contrôles (taille, book-to-market, momentum, secteurs — tout ce dont on veut prouver qu'on n'est pas le déguisement). Puis l'inférence sur la série $\{\gamma_{1,t}\}$:

$$\bar{\gamma}_1 = (1/T) \cdot \Sigma \gamma_{1,t}, t = \bar{\gamma}_1 / (\sigma_{NW}(\gamma_{1,t})/\sqrt{T})$$

— Newey-West avec lag $\geq h$ dès que les horizons se chevauchent (quatrième face de l'encadré D). La beauté structurelle, à énoncer explicitement : $\gamma_{1,t}$ est le **rendement d'un portefeuille** — la solution $\gamma_t = (X'X)^{-1}X'rt$ fait de chaque coefficient le rendement du portefeuille long-short de coût nul, d'exposition unitaire au signal et *nulle aux contrôles* (le portefeuille miroir, factor-mimicking) ; Fama-MacBeth est donc un sort multivarié continu, et avec un signal standardisé (§1.3.1), $\bar{\gamma}_1 \approx \mathbf{IC} \times \sigma_{cs}(\mathbf{r})$ — le pont quantitatif exact avec §2.1.1. La mécanique gère d'office la corrélation *cross-sectionnelle* des erreurs (chaque date fournit une observation de γ) mais pas leur corrélation temporelle — c'est le partage établi par Petersen (« Estimating Standard Errors in Finance Panel Data Sets », RFS 2009) : FM + NW pour les effets de date, clustering bidirectionnel si les deux dimensions corrélaient. Deux raffinements praticiens : la version **WLS** (pondérer par $\sqrt{\text{cap}}$ ou $1/\sigma_i^2$ — la régression équipondérée est dominée par les micro-caps, le même mal que les sorts EW de §2.1.3) et la version **robuste** (régresser sur les rangs du signal, ou perte de Huber — §1.4.4 appliqué à l'inférence). Enfin, pour mémoire, la version originale à deux passes (betas estimés en première passe, primes en seconde) exige la correction d'**errors-in-variables** de Shanken (RFS 1992, facteur multiplicatif $(1 + \bar{\gamma}'\Sigma f^{-1}\bar{\gamma})$ sur les variances) — et le débat Daniel-Titman (JF 1997) — caractéristiques vs covariances — se tranche ici pragmatiquement : le desk prédit avec des caractéristiques, la question « est-ce une prime de risque ? » appartient à §0.7.

2.2.2 Protocole et lags — la timeline exacte

La chronologie contractuelle du backtest, à écrire noir sur blanc car chaque flèche est un piège :

features gelées à $\text{knowledge time} \leq \text{close}(t) \rightarrow \text{signal calculé sur close}(t) \rightarrow \text{ordre transmis} \rightarrow \text{exécution à open}(t+1)$ (ou $\text{close}(t+1)$, ou $\text{VWAP}(t+1)$) $\rightarrow$ rendement couru depuis le prix d'exécution $\rightarrow$ sortie selon la même convention

Les violations canoniques, par ordre de fréquence : l'exécution au $\text{close}(t)$ même (le look-ahead d'un jour — sur un reversal, il capture le bid-ask bounce de Roll §5.1.1 et fabrique plusieurs Sharpes fictifs : le test d'acide d'un backtest de reversal est sa survie au passage $\text{close}(t) \rightarrow \text{open}(t+1)$) ; les **prix stale** des illiquides (un close qui date de 14h30 rend le titre faussement prévisible par le marché de fin de journée — corrections à la Scholes-Williams, ou filtre d'ADV qui évacue le problème) ; et l'incohérence entrée/sortie (entrer au VWAP et sortir au close mélange deux benchmarks, §5.3.2). Le choix du prix d'exécution est lui-même une déclaration de stratégie : close-to-close simule un ordre MOC (§5.1.2 — avec son look-ahead d'auktion propre : le signal utilisant l'imbalance de clôture ne peut pas s'exécuter à cette clôture), open-to-open un ordre à l'ouverture, et l'écart entre les deux backtests *mesure* la composante overnight/intraday du signal (§1.2.2). Dernier étage : la **fréquence de rebalancement** est un paramètre distinct de h — rebalancer chaque jour un signal à $h = 21$ revient à détenir 21 tranches superposées (le portefeuille « overlapping » de Jegadeesh-Titman 1993, qui lisse et diversifie le point d'entrée) ; l'alternative — une seule tranche mensuelle — introduit une dépendance à la phase du calendrier qui doit être testée sur les 21 phases (et leur dispersion est un diagnostic de robustesse gratuit).

2.2.3 Univers point-in-time et delistings — qui a le droit d'être là

La construction : l'univers de la date t contient les titres *vivants et éligibles au knowledge time de t* — constituants historiques (pas la liste actuelle rétro-projetée : backtester sur le S&P 500 d'aujourd'hui, c'est conditionner sur la survie et le succès), filtres appliqués avec les données d'époque (prix > 5\$, ADV minimal, âge de cotation), et les **breakpoints NYSE** pour les tris (les quantiles calculés sur NYSE seul puis appliqués à tous — la convention Fama-French qui empêche les micro-caps Nasdaq de peupler les extrêmes, complémentaire du filtre Hou-Xue-Zhang de §2.1.3). Les sorties ensuite, avec leurs chiffres : Shumway (« The Delisting Bias in CRSP Data », JF 1997) — les rendements de radiation manquants pour cause de performance valent en moyenne $\approx -30\%$ sur NYSE/AMEX ; Shumway & Warther (JF 1999) : $\approx -55\%$ sur Nasdaq (où 5,6 % des titres sortent chaque année pour performance, contre 1,2 % sur NYSE/AMEX) ; les omettre transforme tout signal short-distress en machine à Sharpe fictif, et la règle d'imputation (rendement observé si disponible, forfait conservateur sinon, selon le code de radiation) fait partie du protocole écrit. En crypto : l'univers « top N par capitalisation » se reconstruit point-in-time (le top 100 de 2021 contient les morts — §1.2.4), les delistings d'échange sont l'événement terminal (souvent -50 à -90% *avant* la radiation effective : la date pertinente est l'annonce), et l'éligibilité inclut la venue (un token liquide seulement sur une venue douteuse n'est pas investissable au sens du backtest).

2.2.4 Coûts dans le backtest — la courbe, pas le chiffre

Le net se simule avec le modèle de §4.3.1 en version réduite — coût par trade = ci (spread/2 + frais) + terme d'impact si les tailles simulées le justifient — et le livrable honnête est la **courbe Sharpe(c)** : le Sharpe net en fonction du coût unitaire, de 0 à 50 bps, dont la pente est le turnover (§2.1.4, c^* en est l'intersection avec zéro) ; un signal se présente avec sa courbe, pas avec son point le plus flatteur. Le raffinement décisif, documenté par Novy-Marx & Velikov (RFS 2016) : les techniques d'atténuation — bandes d'hystérésis dans le tri (entrer au décile 10, ne sortir qu'au 7 — le §3.1.3 appliqué aux titres), rebalancement espacé, filtres de liquidité — se simulent **dans** le backtest, car elles changent le signal effectif (son turnover *et* son spread brut) ; comparer le signal brut à coûts nuls puis « promettre » l'atténuation en production est l'écart backtest/réalité le plus commun après le look-ahead. La cohérence transversale : les paramètres de coût du backtest et ceux de l'optimiseur (§4.3.1) sortent de la même TCA (§5.5.4) — un desk dont le backtest suppose 5 bps et dont la TCA mesure 15 a un pipeline qui se ment à lui-même.

2.2.5 Nettoyage crypto — l'univers hostile

Quatre opérations spécifiques, dans l'ordre. Le **wash trading** : Cong, Li, Tang & Yang (« Crypto Wash Trading », Management Science 2023) estiment que sur les venues non régulées **plus de 70**

% **en moyenne** du volume rapporté est fictif, détectable par les régularités statistiques du trading réel (Benford sur les premiers chiffres, sur-représentation des tailles rondes, distribution des tailles de trades) ; la conséquence en cascade est établie (§5.2.4, §4.4.4) : un ADV gonflé sous-estime Q/V donc les coûts donc surestime la capacité — le nettoyage (volumes des seules venues de confiance, ou ADV corrigé par les tests) précède *tout* filtre de liquidité et tout modèle de coût. La **continuité des instruments** : migrations de contrats, redénominations, changements de spécification des perps (§1.2.4) — la table de correspondance datée est un actif de §6.1. Les **cibles funding-incluses** (§1.4.1) : un backtest cross-sectionnel sur perps qui omet le funding fabrique de faux alphas exactement là où le positionnement est extrême — c'est-à-dire là où le signal semble le meilleur. Et les **conventions temporelles** : close UTC 00:00 arbitraire (§1.2.2 — la robustesse se teste en décalant la grille de quelques heures, le pendant crypto du test de phase de §2.2.2), timestamps hétérogènes entre venues, et la grille de funding comme frontière d'attribution des rendements.

Le placebo final, qui coiffe le nœud des deux côtés : faire tourner le protocole complet sur un signal aléatoire — l'IC doit être au plancher de §2.1.1, le Sharpe net négatif du coût ; tout écart mesure la fuite résiduelle du protocole lui-même. **Le placebo est la certification du protocole**, et sa version industrialisée — tournée quotidiennement comme test de non-régression du moteur — appartient à §6.2.

Le quintet à retenir : γ_t est un portefeuille (et $\tilde{\gamma}_1 \approx \bar{I}\bar{C} \cdot \sigma_{cs}(r)$) ; la timeline $close(t) \rightarrow open(t+1)$ comme contrat ; les -30%/-55% de Shumway ; la courbe Sharpe(c) ; le placebo comme certification du protocole. Ce nœud est la charnière entre la mesure (§2.1) et sa remise en cause (§2.3) : tout ce qu'il produit — spreads nets, t-stats corrigés — n'a de sens que si le protocole lui-même ne fuit pas, ce que seul le placebo établit.

Renvois : §0.6-§0.7 (conventions, prime vs caractéristique) ; §1.2.2 (overnight/intraday, grille UTC), §1.2.4 (PIT, continuité crypto) ; §1.3.1 (signal standardisé) ; §1.4.1 (funding dans la cible), §1.4.4 (Huber) ; §2.1.1 (pont $\tilde{\gamma}_1/IC$, plancher), §2.1.3 (VW, HXZ), §2.1.4 (c^*) ; §3.1.3 (hystérésis, NW sur IC) ; §4.3.1 (modèle de coût commun), §4.4.4 (capacité) ; §5.1.1 (Roll), §5.1.2 (auctions), §5.2.4 (volumes nettoyés), §5.3.2 (benchmarks), §5.5.4 (TCA — calibration commune) ; §6.1 (tables de correspondance), §6.2 (placebo quotidien) ; encadré D.

Chapter 8

§2.3 Anti-overfitting

État : relu (intégré s.5, harmonisé s.14 — renvois et notation vérifiés) — source : M112
; vérification des chiffres à venir.

Le cœur épistémologique de la branche 2 : ne pas se raconter d'histoires, quantitativement. Les nœuds §2.1 et §2.2 ont produit des mesures propres ; celui-ci demande ce qu'elles valent une fois comptés les essais qui les ont précédées. Ses cinq feuilles forment une gradation : couper les fuites de la validation (purge, embargo, CPCV), corriger la significativité pour la sélection (DSR), estimer la probabilité d'être un artefact (PBO), contrôler le multiple testing à l'échelle du pool et de la littérature (FDR, haircuts), et enfin *prévenir* plutôt que mesurer (pré-spécification, holdout). Le fil : presque tous ces outils exigent de connaître N, le nombre d'essais — ce que seul le registre de §6.2 fournit.

2.3.1 Purged k-fold, embargo, CPCV — couper les fuites, puis distribuer l'out-of-sample

Le mécanisme de fuite, énoncé proprement : le label y_t est fonction de l'intervalle $[t, t+h]$ (§1.4.2) ; dans un k-fold naïf, une observation de *train* dont l'intervalle de label **chevauche** l'intervalle du bloc de *test* partage de l'information avec lui — le modèle est évalué sur des rendements qu'il a partiellement vus. Le **purging** retire du train toute observation i telle que $[t_i, t_i+h] \cap [t_{\text{test}}, t_{\text{test}}+h] \neq \emptyset$. L'**embargo** ajoute une bande *après* le bloc de test (typiquement 1-5% de T) : les features étant sériellement corrélées (§1.2.2 — tout ce qui est EMA), une observation de train juste postérieure au test « connaît » l'état du marché pendant le test par ses features — la fuite inverse. Coût : quelques pourcents de données ; bénéfice : la CV cesse d'être un générateur de faux positifs systématique — sur données à $h = 21$, l'écart entre CV naïve et CV purgée atteint couramment plusieurs dixièmes de Sharpe (ordre de grandeur praticien, sans source chiffrée). C'est la version protocole du théorème du chevauchement (encadré D).

Le **CPCV** (combinatorial purged cross-validation) généralise : partitionner T en S blocs, tester sur toutes les combinaisons de k blocs — $C(S, k)$ configurations, chacune purgée — puis recoller les prédictions out-of-fold en **chemins de backtest complets** : chaque bloc étant testé dans $C(S-1, k-1)$ configurations, on assemble

$$\phi\text{CPCV} = k \cdot C(S, k) / S \text{ chemins OOS } (S = 6, k = 2 : 15 \text{ configurations, } 5 \text{ chemins complets})$$

— ϕCPCV désigne ici le nombre de chemins, à ne pas confondre avec le ϕ de decay de l'alpha (§0.5, §2.1.2). Le livrable change de nature : non plus *un* Sharpe OOS mais une **distribution** de Sharpes sur les chemins — moyenne, dispersion, pire chemin — ce qui transforme la question « le backtest est-il bon ? » en « la performance est-elle robuste au découpage ? ». Référence : López de Prado, *AFML* (2018), ch. 7 et 12.

2.3.2 Deflated Sharpe — la significativité sous sélection

Trois étapes. D'abord l'inférence sur *un* Sharpe : l'estimateur $\hat{S}R$ a une erreur type qui dépend des moments supérieurs (Lo, « The Statistics of Sharpe Ratios », FAJ 2002 ; Mertens 2002) :

$$\sigma(\hat{S}R) \approx \sqrt{[(1 - \gamma_3 \cdot \hat{S}R + ((\gamma_4 - 1)/4) \cdot \hat{S}R^2) / (T - 1)]}$$

— skew négatif ($\gamma_3 < 0$) et kurtosis élevé (le cas typique d'une stratégie de carry ou de liquidité) gonflent l'incertitude : un Sharpe de 1 sur trois ans de rendements à queues épaisses est bien moins significatif que le même sur du gaussien. Le **PSR** (probabilistic Sharpe ratio) en découle : $\text{PSR}(\text{SR}^*) = \Phi[(\hat{\text{SR}} - \text{SR}^*)/\sigma(\hat{\text{SR}})]$ — la probabilité que le vrai Sharpe dépasse un seuil SR^* .

Ensuite la sélection : si l'on retient le meilleur de N essais *sans aucun signal réel*, le maximum attendu n'est pas zéro. Sous l'hypothèse nulle (vrais Sharpes nuls, essais de variance V) :

$$E[\max_N \hat{\text{SR}}] \approx \sqrt{V} \cdot [(1-\gamma E) \cdot \Phi^{-1}(1 - 1/N) + \gamma E \cdot \Phi^{-1}(1 - 1/(N \cdot e))], \gamma E \approx 0,5772$$

— la croissance en $\sqrt{(2 \ln N)}$ déjà invoquée en §1.2.3 : 100 essais fabriquent un Sharpe attendu ≈ 1 annualisé sur cinq à sept ans de daily, à partir de rien ($E[\max_{100}] \approx 2,5 \cdot \sigma(\hat{\text{SR}})$, avec $\sigma(\hat{\text{SR}}) \approx 1/\sqrt{T}$ années — le calcul se fait de tête). Le **DSR** assemble les deux : $\text{DSR} = \text{PSR}$ calculé avec $\text{SR}^* = E[\max_N \hat{\text{SR}}]$ — la probabilité que le Sharpe observé batte ce que la chance seule aurait produit compte tenu du nombre d'essais (Bailey & López de Prado, « The Deflated Sharpe Ratio », JPM 2014). Le paramètre sensible est **N effectif** : les essais corrélés comptent moins — l'estimation praticienne passe par la variance des Sharpes entre essais et leur corrélation moyenne $\bar{\rho}$ ($N_{\text{eff}} \approx 1 + (N-1) \cdot (1-\bar{\rho})$ en approximation grossière, §6.2, ou par clustering des trajectoires d'essais en familles) — d'où l'exigence, encore elle, du registre : sans log des essais, N est inconnaissable et le DSR incalculable, ce qui est précisément la situation du chercheur qui ne veut pas savoir.

2.3.3 PBO & CSCV — la probabilité d'être un artefact

Le **PBO** (probability of backtest overfitting) répond à une question différente du DSR : non pas « ce Sharpe est-il significatif ? » mais « la *procédure de sélection* elle-même produit-elle des gagnants qui déçoivent ? ». Le protocole CSCV (Bailey, Borwein, López de Prado & Zhu, « The Probability of Backtest Overfitting », Journal of Computational Finance 2017) : soit une matrice $T \times M$ des rendements de M configurations testées ; partitionner T en S blocs ; pour chacune des $C(S, S/2)$ bipartitions train/test équilibrées, identifier la configuration n^* optimale *in-sample*, puis son rang relatif $\bar{\omega} \in (0,1)$ *out-of-sample*, et le logit

$$\lambda \text{PBO} = \ln[\bar{\omega} / (1 - \bar{\omega})], \text{PBO} = P(\lambda \text{PBO} < 0) = \text{fraction des bipartitions où le champion IS est sous-médian OOS}$$

Un PBO de 50% dit que la sélection est du bruit pur ; les seuils praticiens tolèrent $< 10\text{-}20\%$. La force du dispositif : il est **non paramétrique** (aucune hypothèse sur les distributions), symétrique en train/test, et il évalue la *famille* d'essais telle qu'elle a été réellement explorée — c'est l'outil qui juge le grid search assumé du bas de la hiérarchie de §1.2.3. Sa limite : il exige la matrice complète des essais — troisième fois que tout converge vers le registre de §6.2.

2.3.4 FDR & haircuts — le multiple testing à l'échelle du pool et de la littérature

Quand on évalue M signaux en parallèle (l'usine à alphas, ou une revue de littérature), contrôler la probabilité d'*un seul* faux positif (Bonferroni : seuil α/M) est stérilisant ; l'objet utile est le **FDR** — la proportion attendue de faux positifs *parmi les découvertes*. **Benjamini-Hochberg** (JRSS-B 1995) : trier les p -values $p_{(1)} \leq \dots \leq p_{(M)}$, trouver

$$k^* = \max\{ k : p_{(k)} \leq (k/M) \cdot q \}, \text{ rejeter } H_0 \text{ pour les } k^* \text{ premières} \implies \text{FDR} \leq q$$

— adaptatif (plus il y a de vrais signaux, plus le seuil effectif est généreux), valide sous dépendance positive (PRDS), variante Benjamini-Yekutieli sinon. L'application à la finance académique est **Harvey, Liu & Zhu** (« ...and the Cross-Section of Expected Returns », RFS 2016) : recensant ~ 300 facteurs publiés et l'historique implicite des essais de la profession, ils dérivent le **seuil de t-stat $\approx 3,0$** (et croissant) pour qu'une nouvelle anomalie soit crédible — le $t = 2$ des manuels est mort du multiple testing collectif. Harvey & Liu (« Backtesting », JPM 2015) en donnant la version opérationnelle : le *haircut* — le Sharpe rapporté se décote en fonction de N , sévèrement pour les Sharpes moyens (un 1,0 après 200 essais perd de l'ordre de la moitié [à vérifier — exemple chiffré à contrôler dans Harvey & Liu 2015]), peu pour les très élevés. Pour le desk, la déclinaison : q par *famille*

de signaux (§1.2.3 — le FDR se contrôle au niveau où les hypothèses se ressemblent), et les tests de White (« Reality Check », Econometrica 2000) / Hansen (SPA, JBES 2005) / Romano-Wolf (stepdown, Econometrica 2005) comme versions bootstrap comparant toute la famille au benchmark d'un coup.

2.3.5 Pré-spécification & holdout — le dispositif institutionnel

Les quatre outils précédents *mesurent* le data mining ; ce nœud le *prévient*. La hiérarchie de crédibilité de §1.2.3 devient ici un protocole : document d'hypothèse pré-daté (l'hypothèse, la cible §1.4, la forme, les paramètres par défaut — écrits *avant* le premier backtest, archivés dans le registre de §6.2), budget d'essais déclaré par famille (le N du DSR fixé ex ante plutôt que reconstruit ex post), et le **holdout intouchable** administré par le système — données scellées, ouverture unique et journalisée, sur la version finale seulement. Le fondement théorique de cette parcimonie est le résultat sur l'**analyse adaptative des données** (Dwork et al., « The reusable holdout », Science 2015) : chaque requête au holdout dont le résultat influence la suite *consomme* sa validité statistique — le regarder dix fois en ajustant entre-temps le transforme en train set, et les garanties se dégradent en $\sqrt{(\text{nombre de requêtes adaptatives})}$; leur mécanisme Thresholdout (ne répondre que par oui/non bruité au-delà d'un seuil) est la version implémentable du « ne regarde pas » — rendue matérielle par le holdout scellé par hash de §6.2. La clôture du dispositif est la **validation ultime par le live** (§6.3) : six mois de paper trading sont l'OOS que personne ne peut avoir contaminé — avec les bandes statistiques calculées là-bas (e.t. $\approx 0,013$ sur l'IC à six mois) pour ne pas enterrer les vivants.

Le quintet à retenir : purge $[t, t+h]$ + embargo ; $\phi\text{CPCV} = k \cdot C(S,k)/S$ chemins ; $\text{DSR} = \text{PSR}(E[\max N \hat{S}R])$; $\text{PBO} = P(\lambda \text{PBO} < 0)$; seuil $t \approx 3,0$. Le registre de §6.2 porte trois de ces cinq outils (N du DSR, matrice du PBO, budget du FDR) ; Dwork rejoint le holdout scellé de §6.2 ; les bandes du live (§6.3) ferment la boucle. Ce nœud est celui que le budget de degrés de liberté de §0.8 rembourse : tout ce que la branche 1 a dépensé se solde ici.

Renvois : §0.8 (budget de degrés de liberté) ; §1.2.2 (features EMA — fuite d'embargo), §1.2.3 (hiérarchie de crédibilité, familles d'essais), §1.4 (la cible pré-spécifiée), §1.4.2 (labels chevauchants) ; §2.1.1 (plancher — l'autre borne), §2.2 (le protocole que la CV distribue) ; §3.1.2 (valider prend des mois) ; §6.2 (registre, N_{eff} , holdout scellé), §6.3 (portes pré-enregistrées, bandes du live) ; encadré D (chevauchement).

Chapter 9

§2.4 Non-stationnarité & régimes

État : relu (intégré s.5, harmonisé s.14 — renvois et notation vérifiés) — source : M118
; vérification des chiffres à venir.

Dernier nœud de la branche 2 : la validité a une date de péremption, et ça se mesure. Un IC est daté — les trois nœuds précédents ont établi comment le mesurer, le simuler et le déflater ; celui-ci demande combien de temps il restera vrai, comment détecter qu'il ne l'est plus, et pourquoi il s'éteint. Quatre feuilles : la détection (rolling IC, ruptures, surveillance séquentielle), les causes (crowding et publication), la lecture par régime (carry vs revalorisation, taxonomie de persistance), et le cas limite des histoires courtes — le crypto, où la non-stationnarité est l'état normal.

2.4.1 Rolling IC et ruptures — détecter la mort d'un signal

L'outil de base est le rolling IC (fenêtre 1-2 ans) avec ses bandes : sous stabilité, $\tilde{IC}_{rolling}$ fluctue autour de sa moyenne avec un écart-type $\sigma(IC)/\sqrt{T_{fen}}$ — pour $\sigma(IC) = 0,15$ et 252 jours, $\pm 0,019$ par écart-type ; la moitié des « signaux morts » du folklore vivent à l'intérieur de ces bandes (§6.3, le même calcul qui protège les signaux en paper trading). Pour l'analyse *ex post*, les tests de rupture structurelle : **Bai-Perron** (Econometrica 1998 ; Journal of Applied Econometrics 2003) estime le nombre et les dates de ruptures multiples de moyenne dans la série $\{IC_t\}$ par programmation dynamique, avec les valeurs critiques du sup-F — l'outil qui répond à « le signal a-t-il changé de régime, et quand » ; l'ajustement paramétrique concurrent, plus doux, est la décroissance continue $IC(t) = IC_0 \cdot e^{-t/T_{decay}}$, et départager rupture vs décroissance est en soi informatif (une rupture pointe vers un événement — changement de microstructure, publication, arrivée d'un gros acteur ; une décroissance vers l'érosion par crowding, §2.4.2).

Pour la *surveillance en ligne* — le vrai besoin du desk — le cadre correct est le contrôle séquentiel : le **CUSUM de Page** (Biometrika 1954),

$$S_t = \max(0, S_{t-1} + (\mu_0 - IC_t - kc)), \text{ alerte si } S_t > hc$$

accumule les écarts sous la moyenne de référence μ_0 (moins une tolérance kc , typiquement $\delta/2$ pour une dégradation cible δ) et sonne au franchissement de hc ; le réglage (kc, hc) arbitre le délai de détection contre le taux de fausses alertes via l'**ARL** (average run length — l'espérance du temps entre fausses alertes sous H_0 , calculable par les approximations de Siegmund). La leçon quantitative est dégrisante et referme la boucle sur §3.1.2 : détecter *rapidement* qu'un IC est passé de 0,03 à 0 exige des mois même avec le test optimal — le bruit $\sigma(IC)$ est tel que la réponse rationnelle à la suspicion n'est pas binaire (couper/garder) mais graduelle : c'est exactement ce que le bucket avec hystérésis de §3.1.3 et la pondération bayésienne implémentent — la rétrogradation est le test séquentiel rendu décision (encadré E).

2.4.2 Crowding et publication — l'alpha comme ressource épuisable

Le résultat de référence est **McLean & Pontiff** (« Does Academic Research Destroy Stock Return Predictability? », JF 2016) : sur 97 anomalies publiées, les rendements baissent d'environ **26%** entre l'échantillon d'origine et le hors-échantillon pré-publication (la part attribuable au data

mining des auteurs — la mesure *empirique* du biais que §2.3 corrige a priori) et de **58% après publication** — soit 32 points imputables à la publication elle-même (les chiffres exacts du papier), avec les signatures de l'arbitrage : la baisse est plus forte sur les anomalies liquides et peu coûteuses à trader, et volumes/short interest montent dans les jambes concernées. L'alpha est une rente informationnelle : la révéler la fait consommer — la moitié environ survit, ce qui calibre le prior de long terme sur tout signal de la littérature (le m du modèle hiérarchique de §3.1.3, segmenté « publié vs propriétaire ») et la dynamique d'érosion des données alternatives (§1.1.4).

La mesure du crowding *en temps réel* ensuite. **Lou & Polk** (« Comomentum », JPE 2022) : la corrélation anormale des *résidus* des titres d'une même jambe (momentum entre eux, net des facteurs) mesure la densité de capital d'arbitrage sur la stratégie — le comomentum élevé prédit des rendements faibles puis des crashes de la stratégie : la corrélation intra-jambe est l'empreinte digitale des détenteurs communs. **Hanson & Sunderam** (« The Growth and Limits of Arbitrage », RFS 2014) utilisent le short interest agrégé des jambes short comme proxy du capital alloué, avec la même conclusion en coupe : plus de capital, moins de rendement. Et la dynamique de crise est celle de Khandani-Lo (§4.5.2 ; le cadre théorique : Stein, « Presidential Address: Sophisticated Investors and Market Efficiency », JF 2009 — l'arbitrage désancré devient déstabilisant sous contrainte de capital) : le crowding transforme le profil d'un signal — espérance érodée, corrélation conditionnelle accrue, queue gauche épaissie — c'est-à-dire exactement les trois quantités que $\sigma(\text{IC})$, le comomentum et les stress tests de §4.5 surveillent. Pour le desk : le monitoring de crowding par sleeve (corrélation résiduelle intra-jambe, coût d'emprunt des shorts, funding pour les jambes crypto) appartient au tableau de bord de §6.3 au même titre que l'IC.

2.4.3 Validation par régime — comprendre avant de moyennner

Le geste minimal : recalculer IC et spread par régime pré-spécifié (vol haute/basse, dispersion, liquidité — les conditionneurs de §1.2.3, *déclarés avant* : chaque découpage ex post est un essai de plus au compteur du DSR, §2.3.2). Le geste profond : la **décomposition carry/revalorisation** d'Arnott, Beck & Kalesnik (« How Can “Smart Beta” Go Horribly Wrong? », 2016) — le rendement historique d'une caractéristique se partage en

$$\text{rendement} = \text{carry structurel} + \text{Avalorisation}$$

(pour un facteur value : le rendement du portefeuille = l'écart de yield entre jambes + le resserrement/écartement du multiple relatif). La part *revalorisation* n'est pas répétable — un facteur dont le backtest vit du renchérissement de sa propre jambe longue a un rendement espéré prospectif bien moindre que son historique, et le test honnête est le rendement **net de revalorisation** (à écart de valorisation constant). C'est le pendant « niveau facteur » du changements-vs-niveaux de §1.2.1, et un filtre d'admission au pool à part entière (§3.4.1). La grille de lecture finale est la **taxonomie de persistance** (l'esprit d'Ilmanen, *Expected Returns*, et de la question de §1.2.3 — « qui perd, et pourquoi ça continue ») : *prime de risque* (le rendement paie un risque réel — persistant, mais avec ses crashes par construction), *friction structurelle* (contrainte réglementaire, flux mécaniques — persistant tant que la structure tient, et *datable* : la rupture de §2.4.1 correspond à un changement de structure identifiable), *inefficience comportementale* (persistante si les limites à l'arbitrage tiennent — la plus exposée au crowding de §2.4.2). Trois espérances de vie différentes, trois demi-vies d'estimation différentes (§3.2.4 : l'EMA des IC se paramètre *par famille de persistance*), et la réponse à « combien d'histoire utiliser » cesse d'être un chiffre unique.

2.4.4 Histoires courtes — le cas crypto

Le problème en chiffres : l'histoire investissable sérieuse commence vers 2017-2018, traversée de ruptures structurelles majeures — institutionnalisation post-2020, effondrements de venues (FTX, 2022), ère des ETF (2024) — soit, au sens de Bai-Perron, quatre ou cinq régimes de 1-2 ans chacun : la « longue histoire » crypto est une collection de courtes histoires non stationnaires. Les pseudo-saisonnalités populaires en sont le symptôme : le « cycle du halving » repose sur **N = 4 observations** — aucune inférence n'y survit (le σ d'une moyenne sur 4 tirages...), et le traiter comme un signal est le multiple testing de §2.3 à l'état chimiquement pur. Les réponses structurelles, par ordre

: **le breadth spatial remplace le temps** — 200 tokens $\times$ 5 ans portent plus d'information cross-sectionnelle que 2 actifs $\times$ 50 ans, à condition de valider en coupe (§2.1, §2.2) plutôt qu'en série ; **les priors transférés** — les caractéristiques validées sur un siècle d'equity (momentum, taille, liquidité, carry) arrivent avec leur m et τ hiérarchiques (§3.1.3) et l'histoire crypto ne fait que les mettre à jour, ce que la littérature confirme : Liu & Tsyvinski (« Risks and Returns of Cryptocurrency », RFS 2021) et Liu, Tsyvinski & Wu (« Common Risk Factors in Cryptocurrency », JF 2022) établissent que taille et momentum structurent le cross-section des tokens — les mêmes primes, sur un marché neuf ; **la pondération du récent** enfin, poussée plus loin qu'en equity (demi-vies d'IC de 1-2 ans, §1.4.4 côté entraînement), avec l'aveu épistémique que ce nœud impose de rendre explicite : en crypto, la part du jugement (priors, mécanismes, « qui perd ») dans la conviction est structurellement plus élevée que la part de la statistique — le nier en empilant les tests sur cinq ans de données, c'est fabriquer de la fausse précision.

La branche 2 se clôt ici. Le quatuor du nœud : CUSUM/ARL (la détection a un coût en délai incompressible) ; -26%/-58% de McLean-Pontiff (le data mining et le crowding, mesurés) ; le rendement net de revalorisation ; le $N = 4$ du halving comme memento. Trois coutures structurantes : la rétrogradation de bucket est le test séquentiel rendu décision (§3.1.3 $\leftrightarrow$ §2.4.1, encadré E) ; le comomentum rejoint le tableau de bord de §6.3 ; la taxonomie de persistance pilote les demi-vies d'estimation de §3.2.4.

Renvois : §1.1.4 (érosion des données), §1.2.1 (changements vs niveaux), §1.2.3 (conditionneurs pré-spécifiés, « qui perd ») ; §1.4.4 (poids de récence) ; §2.1 (validation en coupe), §2.2 (le protocole), §2.3 (DSR — chaque découpage compte), §2.3.2 (compteur d'essais) ; §3.1.2–§3.1.3 (classer prend des années, prior hiérarchique, buckets-hystérésis) ; §3.2.4 (demi-vies par persistance), §3.4.1 (filtre d'admission) ; §4.5 (stress, queues), §4.5.2 (Khandani-Lo) ; §6.3 (tableau de bord, bandes du live) ; encadré E (surveillance séquentielle).

Chapter 10

§3.1 Pondérations simples

État : relu (intégré s.6, harmonisé s.14 — renvois et notation vérifiés) — sources : M033 (nœud complet), M035 (forage niveau 5 : §3.1.3), M031 (cadrage de branche) ; vérification des chiffres à venir.

La branche 3 consomme tout ce que les deux premières ont construit : des signaux normalisés (§1.3), évalués, aux IC mesurés par bande et par régime (§2). Son cadre formel unifie les quatre nœuds : après normalisation, on dispose de K signaux $s_1 \dots s_K$, chacun de moyenne nulle et variance unitaire en cross-section, avec un vecteur d'IC $\rho = (\rho_1 \dots \rho_K)$ et une matrice de corrélation inter-signaux C . Le forecast combiné est w 's, et le poids optimal au sens de l'IC du combiné est $w \propto C^{-1}\rho$ — la transposition exacte de Markowitz à l'espace des *signaux* : les IC jouent le rôle des rendements espérés, la corrélation des signaux celui de la covariance des actifs. Toute la branche répond à une seule question : comment estimer $C^{-1}\rho$ sans se faire détruire par l'erreur d'estimation ? Ce premier nœud commence par le bas de l'échelle de complexité — et établit pourquoi ce bas de l'échelle est si difficile à dépasser. C'est le nœud le plus profondément foré de l'ouvrage : son §3.1.3 descend au niveau 5.

3.1.1 1/N et ses fondements — pourquoi le naïf est si dur à battre

Le résultat empirique de référence (DeMiguel-Garlappi-Uppal, RFS 2009) : sur un éventail de quatorze schémas d'optimisation de portefeuille, aucun ne bat systématiquement l'équipondération out-of-sample, et la fenêtre d'estimation nécessaire pour que Markowitz domine 1/N est de l'ordre de plusieurs *milliers* de mois pour quelques dizaines d'actifs — des historiques qui n'existent pas. La raison profonde est géométrique : au voisinage de l'optimum, le Sharpe est *plat* en fonction des poids (le gradient y est nul par définition), donc une erreur de pondération ε ne coûte que $O(\varepsilon^2)$; symétriquement, l'erreur d'estimation injecte dans les poids optimisés un bruit du premier ordre. On échange une perte quadratique certaine et petite (utiliser 1/N au lieu des vrais poids optimaux) contre un bruit linéaire et grand (utiliser des poids optimisés sur des paramètres faux). Le naïf gagne tant que la dispersion *vraie* des qualités est inférieure au bruit d'estimation.

Et la transposition aux signaux est encore plus favorable au naïf que pour des actifs : le pool d'alphas est *pré-filtré*. Les signaux qui y entrent ont passé l'évaluation — leurs vrais IC vivent dans une bande étroite (disons 0,02 à 0,06 ; un signal à 0,15 durable n'existe pas, un signal à 0,005 n'a pas passé le seuil, §0.3). La dispersion vraie que l'optimisation pourrait exploiter est donc structurellement faible, exactement le régime où 1/N est quasi optimal. Deux subtilités d'application : le *biais de peuplement* — un 1/N plat sur les signaux sur-pondère mécaniquement la famille la plus prolifique (dix variantes de momentum contre deux signaux de flux : le combiné est un momentum déguisé) ; la réponse est le 1/N *hiérarchique* — équipondérer les familles, puis dans chaque famille (§3.4.2, le clustering qui systématise ce geste). Et l'écart entre espace des forecasts et espace du P&L : les signaux sont tous à variance unitaire en cross-section, mais leurs P&L n'ont pas la même volatilité (un signal couvrant 200 titres diversifie moins qu'un signal couvrant 2 000, §2.1.4 ; un signal événementiel n'est actif que par intermittence) — le 1/N des forecasts n'est pas le 1/N des risques, et le choix entre les deux est déjà une décision de design.

3.1.2 Pondération par IC — la solution exacte du monde décorrélé

La dérivation tient en une ligne : l'IC du combiné w 's vaut $w'\rho/\sqrt{(w'Cw)}$; le maximiser donne $w \propto C^{-1}\rho$, et si $C = I$, $w \propto \rho$. Pondérer par l'IC est donc la solution *optimale* d'un monde où les signaux sont décorrélés — et l'erreur qu'elle commet dans le monde réel est de compter double : deux momentum corrélés à 0,9 reçoivent chacun leur plein poids, et la famille redondante écrase le signal orthogonal (§3.4.1). C'est le cadre de Grinold : l'alpha d'un titre se lit $IC \times \text{volatilité} \times \text{score}$, et la combinaison IC-pondérée est la superposition additive de ces alphas élémentaires — le formalisme qui sous-tend toute la tradition « active management » de Grinold-Kahn.

Le contenu opérationnel est dans l'estimation de ρ . L'erreur type de l'IC moyen est $\sigma(IC)/\sqrt{T}$, avec $\sigma(IC)$ typiquement 0,10-0,20 en cross-sectionnel equity (§0.3, §2.1.1). Les ordres de grandeur qui en découlent structurent tout : pour *valider* un IC de 0,03 ($t \approx 2$ avec $\sigma(IC) = 0,15$), il faut ~ 100 jours ; mais pour *classer* deux signaux dont les IC diffèrent de 0,01, il faut $\sim 1\,800$ jours — sept ans. Autrement dit : distinguer un bon signal du bruit est faisable en quelques mois ; distinguer deux bons signaux entre eux demande plus d'histoire qu'on n'en a de stationnaire (§2.4). C'est le fondement quantitatif de tout le nœud : la hiérarchie fine des poids que l'IC-weighting prétend établir repose sur des différences d'IC statistiquement indiscernables — d'où le nœud suivant, qui traite cette incertitude explicitement.

3.1.3 Pondération par ICIR — le shrinkage qui s'ignore (forage niveau 5)

Pondérer par $ICIR = \hat{IC}/\sigma(IC)$ admet deux lectures complémentaires, avant le forage. La lecture *décisionnelle* : dans l'espace des P&L, où chaque signal est un flux de rendements de moyenne $\propto IC$ et d'écart-type dominé par $\sigma(IC)$ (à grand breadth, le bruit cross-sectionnel se diversifie et c'est la variation temporelle de l'IC qui reste), pondérer par ICIR c'est pondérer par le Sharpe du signal. La famille complète s'écrit $w \propto IC/\sigma(IC)\gamma$: $\gamma = 0$ donne l'IC-weighting (aveugle au risque), $\gamma = 1$ le Sharpe/ICIR-weighting, $\gamma = 2$ le Kelly-Markowitz du monde indépendant (μ/σ^2). Le choix de γ est un curseur d'agressivité, et $\gamma = 1$ est le compromis d'usage — assez sensible au risque pour pénaliser les signaux erratiques, pas assez pour que les $\sigma(IC)$ mal estimés dominent les poids. La lecture *bayésienne*, plus profonde, est l'objet des quatre sous-nœuds qui suivent.

a) *Le modèle bayésien hiérarchique — le pool comme prior*. Écrivons-le complètement, car tout le nœud en découle. Le vrai IC du signal k est θ_k , tiré d'une population $\theta_k \sim N(m, \tau^2)$ — m est l'IC moyen du *type* de signaux qu'on admet au pool, τ leur dispersion vraie (§0.5). On observe $\hat{IC}_k = \theta_k + \text{bruit}$, avec un bruit d'écart-type $s_k = \sigma(IC)/\sqrt{T_k}$. Le posterior est alors

$$E[\theta_k | \hat{IC}_k] = m + (\hat{IC}_k - m) \cdot \tau^2 / (\tau^2 + s_k^2), B = s^2 / (\tau^2 + s^2)$$

— l'écart au prior est multiplié par un facteur de rétention $\tau^2/(\tau^2 + s^2)$, et le complément B est la fraction de l'écart mesuré qu'on *jette* comme bruit. Les ordres de grandeur rendent la formule mordante : avec une dispersion vraie $\tau \approx 0,01$ (un pool dont les vrais IC s'étalent de 0,02 à 0,06) et $\sigma(IC) = 0,15$, un an de données ($T = 250$) donne $s \approx 0,0095$, donc $B \approx 0,47$ — la moitié de ce qui distingue votre signal de la moyenne du pool est du bruit à jeter. Deux ans : $B \approx 0,31$. Quatre ans : $B \approx 0,18$. La hiérarchie fine des poids ne devient défendable qu'avec des historiques que la non-stationnarité rend suspects (§2.4.3). Le raffinement qui rend ça opérationnel : l'*empirical Bayes*. On n'a pas besoin de postuler m et τ — le pool les fournit : m est la moyenne des $\hat{IC}_k$ observés ; τ^2 s'estime par la variance observée des $\hat{IC}_k$ moins la moyenne des s_k^2 (dispersion observée = dispersion vraie + bruit d'estimation ; on soustrait le second, tronqué à zéro si négatif). C'est exactement l'estimateur de James-Stein, dont le théorème dit qu'en dimension $K \geq 3$ ce shrinkage vers la moyenne commune domine l'estimation naïve signal par signal *quel que soit* le vrai vecteur θ (encadré A). L'usine à alphas est donc littéralement un modèle hiérarchique : chaque nouveau signal est jugé à la lumière de la population des signaux passés du même type — et la version raffinée segmente le prior par famille (le m des signaux de microstructure n'est pas celui des signaux fondamentaux, leurs τ non plus ; le m « publié vs propriétaire » de §2.4.2), ce qui transforme l'expérience accumulée du desk en priors quantifiés.

b) *Le lien avec Kelly — la réconciliation par les sleeves vol-égalisés*. Le critère de Kelly, pour un flux de rendements de moyenne μ et variance σ^2 par période, donne le levier log-optimal $f^* = \mu/\sigma^2$.

Appliqué à K signaux indépendants, il alloue en relatif $w_k \propto \mu_k / \sigma_k^2$ — le point $\gamma = 2$ de la famille ci-dessus. Alors pourquoi l'usage consacre-t-il $\gamma = 1$, l'ICIR ? La réconciliation passe par une pratique quasi universelle : les sleeves sont *vol-égaillés*. Si chaque signal est d'abord scalé pour cibler la même volatilité de P&L σ_0 (le vol-targeting par sleeve, §4.4.1), alors sa moyenne par période devient $\mu_k = \text{Sharpek} \cdot \sigma_0$, sa variance σ_0^2 est commune, et Kelly en relatif donne $w_k \propto \text{Sharpek} \propto \text{ICIR}_k$. *L'ICIR-weighting est le Kelly exact d'un pool de sleeves vol-égaillés indépendants*. La divergence entre $\gamma = 1$ et $\gamma = 2$ n'est donc pas un désaccord théorique mais un ordre des opérations : qui, du scaling ou de la pondération, absorbe le σ . Reste la question du levier *total*, où Kelly plein est notoirement intenable — et les raisons s'emboîtent avec le sous-nœud (a). Kelly est log-optimal sous paramètres connus ; sous paramètres estimés, l'espérance de croissance en utilisant $\hat{\mu}$ est amputée par $\text{Var}(\hat{\mu})$, et la correction bayésienne cohérente est d'utiliser le posterior — c'est-à-dire le μ *shrinké* de (a) au numérateur. Le shrinkage des IC et le fractional Kelly sont le même geste vu de deux endroits : réduire l'exposition proportionnellement à l'incertitude (encadré B). S'y ajoutent les raisons hors modèle (queues épaisses, ruptures de régime, la variance de la variance) qui justifient le demi-Kelly conventionnel : la croissance espérée est plate au voisinage de f^* (perdre 25% de croissance pour diviser la variance du chemin par ~ 2 est l'arbitrage du demi-Kelly), et l'asymétrie est brutale — sur-lever au-delà de f^* détruit de la croissance *et* ajoute du risque, donc sous l'incertitude on se place systématiquement en dessous (§4.4.2).

c) *La quantification en buckets — la régularisation par la grille*. L'argument informationnel d'abord : quand $s \approx \tau$ — le régime démontré en (a) pour tout historique réaliste — la probabilité a posteriori que le signal classé 3^e du pool soit vraiment meilleur que le 5^e dépasse à peine 50%. Des poids continus au troisième chiffre prétendent transmettre une information de classement qui *n'existe pas dans les données* ; trois niveaux (fort/moyen/faible $\rightarrow 3/2/1$, ou $4/2/1$) capturent l'essentiel du gain atteignable, et la perte de la quantification — quadratique, comme toute erreur de poids près de l'optimum plat — est noyée sous le bruit d'estimation qu'elle élimine. C'est le même théorème d'optimum plat que le $1/N$, appliqué un cran plus finement. Le bénéfice dynamique est au moins aussi important : la *stabilité*. Des poids continus ré-estimés bougent à chaque rafraîchissement — du turnover de combinaison sans espérance. Des buckets ne bougent que lors d'un franchissement de frontière, et on protège les frontières par *hystérésis* : promotion si le t-stat posterior dépasse 2 de façon soutenue, rétrogradation seulement s'il tombe sous 1 — deux seuils distincts, exactement le mécanisme des buffers d'inclusion des indices ou des notations de crédit, qui empêche un signal oscillant autour du seuil de générer un va-et-vient coûteux. La rétrogradation est le test séquentiel de §2.4.1 rendu décision (encadré E). Enfin la dimension gouvernance, qui est la vraie raison de la persistance des buckets dans les grandes maisons : le bucket est une *décision reviewable* — attribuée en comité à cadence trimestrielle, motivée par un dossier (évidence statistique $\times$ solidité du prior économique $\times$ capacité restante), auditable ex post (§6.4). La conviction n'est pas réductible à l'ICIR mesuré, et le bucket est l'interface honnête entre la statistique et le jugement — un poids continu à cinq décimales maquille ce jugement en fausse précision.

d) *Estimer $\sigma(\text{IC})$ — le dénominateur est aussi une estimée*. Toute la construction repose sur $\sigma(\text{IC})$, et son estimation a trois chausse-trappes. La première est mécanique : dès que l'horizon $h > 1$ avec des IC calculés quotidiennement, les IC successifs partagent des rendements — la série des IC est autocorrélée (structure $\sim \text{MA}(h-1)$, §1.4.2), et l'erreur type naïve $\hat{\sigma}(\text{IC})/\sqrt{T}$ sous-estime la vraie d'un facteur $\approx \sqrt{h}$. Un signal à $h = 21$ voit son t-stat surestimé d'un facteur 4-5 par le calcul naïf — de quoi transformer du bruit en « signal validé ». Les corrections : Newey-West sur la série des IC, ou le block bootstrap avec des blocs plus longs que h — le strict pendant, côté combinaison, du purging côté évaluation (encadré D). La deuxième : $\sigma(\text{IC})$ est lui-même bruité (la variance d'une variance estimée...), et un $\sigma(\text{IC})$ sous-estimé par chance gonfle l'ICIR exactement comme un IC surestimé — le dénominateur mérite son propre shrinkage vers la valeur typique de sa famille, faute de quoi on a déplacé le problème sans le résoudre. La troisième est conceptuelle et referme la boucle sur §1.2.3 : $\sigma(\text{IC})$ mesuré confond le *bruit* et la *variation conditionnelle prédictible* — un signal dont l'IC est fort en haute vol et nul en basse vol a un gros $\sigma(\text{IC})$ inconditionnel, donc un ICIR médiocre, alors qu'exploité

avec son conditionnement il est excellent. Conditionner transfère de la variance du dénominateur vers le numérateur conditionnel — mais ce transfert doit être payé en degrés de liberté pré-spécifiés, sinon c'est le data mining de §1.2.3 sous un déguisement de plus. Et pour la mise en œuvre courante : IC et IC² s'estiment tous deux en EMA de demi-vie 2-4 ans — assez long pour la précision, assez court pour suivre la dérive (§2.4.3, §3.2.4) — les deux demi-vies étant elles-mêmes... des paramètres qu'on fixe par défaut raisonnable plutôt qu'on optimise, par cohérence avec tout ce que cet arbre a établi.

3.1.4 Erreur d'estimation — la maximisation d'erreur et ses garde-fous

Le mécanisme à comprendre, nommé par Michaud « error maximization » : l'optimiseur ne voit pas les vrais paramètres, il voit vrais + bruit, et il alloue *préférentiellement vers le bruit positif* — l'actif au rendement surestimé, le signal au backtest chanceux reçoivent les gros poids, systématiquement, parce que c'est la définition même de l'argmax sur des quantités bruitées. Dans l'espace des signaux, cet effet se *compose* avec le biais de sélection hérité de l'évaluation : les signaux entrent au pool parce que leur backtest était bon, c'est-à-dire en partie parce qu'ils ont eu de la chance (§2.3.2), et l'optimiseur re-récompense cette même chance une seconde fois. Le comptage des paramètres aggrave tout : C contient $K(K-1)/2$ corrélations, et l'historique nécessaire croît en gros comme K^2 — avec la contrainte assassine que l'historique *utile* est plafonné par la non-stationnarité (au-delà de la demi-vie de dérive des IC, les données anciennes décrivent un autre marché, §2.4). Il existe donc un K critique au-delà duquel l'optimisation complète ne peut mathématiquement jamais battre le naïf : les observations qu'il lui faudrait n'existent pas et n'existeront jamais.

Les défenses, par ordre de simplicité : les *caps* (aucun signal au-dessus de 2-3× son poids 1/N, aucun en dessous de zéro — la version dure du shrinkage, §3.2.3), le *lissage des poids eux-mêmes* (EMA sur w avec une demi-vie de plusieurs mois : les poids de combinaison sont une quantité estimée comme une autre, leur turnover a un coût et leur variation rapide est du bruit quasi certain, §3.2.4), et le *resampling de Michaud* (ré-optimiser sur des bootstraps de l'histoire et moyenner les poids obtenus — la moyenne d'optima bruités est plus proche du vrai optimum que l'optimum du bruité). Et le critère de décision final, qui referme la boucle sur l'évaluation : la question n'est jamais « l'optimisé bat-il 1/N in-sample » (réponse : toujours, par construction) mais « l'optimisé bat-il 1/N en validation purgée, d'un écart supérieur au coût du turnover supplémentaire qu'il génère » (§2.3.1, §3.2.4). Pour un pool de moins de ~30 signaux, la réponse honnête est presque toujours non — et c'est une conclusion libératrice : la sophistication de la combinaison n'est pas où se gagne la partie à petit K ; elle se gagne dans l'orthogonalité du pool (§3.4) et dans la qualité des signaux eux-mêmes. Une discipline transversale clôt le nœud : les signes ne se votent pas en backtest — un signal admis au pool avec un prior économique garde son signe (§0.6) ; si l'estimation veut le retourner, c'est une alerte sur le signal ou sur les données, pas une opportunité.

Le fil du nœud : à petit K et historique réaliste, presque toute l'information de pondération exploitable tient dans trois buckets et une équipondération hiérarchique — le reste est du bruit re-optimisé. Les trois objets construits ici — le posterior shrinké, les sleeves vol-égalisés, les buckets à hystérésis — reviennent dans les encadrés A, B et E ; le nœud suivant (§3.2) reprend la même question par l'algèbre, en réintroduisant C.

Renvois : §0.3 (bande d'IC), §0.5–§0.6 (notations, signes par prior) ; §1.2.3 (conditionnement, degrés de liberté) ; §1.4.2 (MA(h-1)) ; §2.1.1 ($\sigma(\text{IC})$), §2.1.4 (coverage/diversification), §2.3.1–§2.3.2 (validation purgée, biais de sélection), §2.4.1–§2.4.3 (test séquentiel, prior publié/propriétaire, demi-vies) ; §3.2.3–§3.2.4 (NNLS, fenêtres), §3.4 (orthogonalité, admission) ; §4.4.1–§4.4.2 (vol-targeting, fractional Kelly) ; §6.4 (comité, gouvernance des buckets) ; encadrés A (James-Stein), B (croissance & survie), D (chevauchement), E (hystérésis).

Chapter 11

§3.2 Régression régularisée

État : relu (intégré s.6, harmonisé s.14 — renvois et notation vérifiés) — source : M120
; vérification des chiffres à venir.

Deuxième nœud de la branche 3 : le continuum entre le naïf et l'optimal. §3.1 a établi que la hiérarchie fine des poids est statistiquement indéfendable à petit K ; ce nœud reprend la même question par l'algèbre — estimer $w \propto C^{-1}\rho$ sans se faire tuer par C^{-1} — et montre que toutes les défenses raisonnables (ridge, shrinkage de C , contraintes de signe, choix de fenêtres) sont des paramétrages d'un même geste : régulariser vers les solutions simples de §3.1, à un degré que les données choisissent.

3.2.1 Ridge — le continuum, rendu formel

Le cadre : régresser en panel la cible normalisée (vol-scalée, résidualisée — §1.4.1) sur les K signaux empilés, $y = S \cdot w + e$. Avec signaux et cible standardisés (§1.3), les moments empiriques s'identifient aux objets de la branche : $(1/n) \cdot S'S \approx C$ (la corrélation inter-sinaux) et $(1/n) \cdot S'y \approx \rho$ (le vecteur des IC). L'OLS donne donc $w \propto C^{-1}\rho$ — littéralement le Markowitz de l'espace des signaux — et la ridge :

$$w(\kappa) = (S'S + \kappa I)^{-1} \cdot S'y \propto (C + \tilde{\kappa} I)^{-1} \cdot \rho$$

Les deux limites, désormais démontrées et plus seulement énoncées : $\tilde{\kappa} \rightarrow 0$ rend $C^{-1}\rho$ (l'optimum théorique, §3.1.2) ; $\tilde{\kappa} \rightarrow \infty$ rend $w \propto \rho$ (l'IC-weighting, la solution du monde décorrélé). La lecture **spectrale** dit pourquoi l'interpolation est la bonne : en base propre $C = \sum_j \lambda_j \cdot u_j u_j'$, la ridge multiplie chaque direction propre par

$$\lambda_j / (\lambda_j + \tilde{\kappa})$$

— les directions à grande valeur propre (les contrastes entre familles, bien estimés) passent presque intactes ; les directions à petite λ_j (les différences fines *au sein* d'un banc de momentum corrélé à 0,9 — précisément ce que C^{-1} amplifiait en poids explosifs de signes alternés, §3.1.4) sont écrasées. La ridge est un filtre passe-haut sur le spectre de C — le pendant combinaison du clipping RMT de §4.1.2. (Les λ_j sont ici les valeurs propres de C , un usage local distinct de la décroissance EMA de §0.5.) La lecture **bayésienne** enrichit l'encadré A : la ridge est le MAP du modèle $w \sim N(0, \tau^2 I)$, avec $\kappa = \sigma^2 e / \tau^2$ — régulariser fort, c'est déclarer un prior serré sur les poids, et le κ optimal élevé qu'on trouve en pratique par CV purgée (§2.3.1) est la *mesure* de la domination du bruit d'estimation. Le degré de liberté effectif $df(\kappa) = \sum_j \lambda_j / (\lambda_j + \tilde{\kappa})$ quantifie la complexité réellement dépensée — typiquement une fraction de K , à logger comme tel au registre (§2.3, §6.2). Variante à éviter en général : le **lasso** — sa sparsité est séduisante mais sa sélection parmi des signaux corrélés est instable (il choisit *un* momentum du banc arbitrairement, et un autre au resample suivant) ; l'elastic net (Zou & Hastie, JRSS-B 2005) mitige, mais la structure correcte est ailleurs (§3.2.3). Référence de fond : Hastie, Tibshirani & Friedman, *The Elements of Statistical Learning*.

3.2.2 Shrinkage de C — la cible en blocs

L'autre moitié du problème : $\hat{C}$ elle-même est bruitée ($K(K-1)/2$ paramètres, §3.1.4). Le shrinkage linéaire de Ledoit-Wolf (§4.1.3, transposé aux signaux) :

$$\tilde{C} = \delta^* \cdot T_0 + (1 - \delta^*) \cdot \hat{C}, \quad \delta^* \approx \sum_{ij} \text{Var}(\hat{c}_{ij}) / \sum_{ij} (\hat{c}_{ij} - t_{0,ij})^2$$

— proportion de bruit sur distance à la cible. Le choix de T_0 est le vrai levier : l'identité est agnostique, la corrélation constante (le « Honey » de LW 2004) déjà meilleure, mais la cible **en blocs par famille** domine parce que la vraie C a cette topologie (§3.4.2 : les signaux naissent en familles)

$t_{0,ij} = \bar{\rho}$ intra si i, j même famille ; $\bar{\rho}$ inter sinon

— deux paramètres estimés sur toutes les paires, au lieu de $K^2/2$: le biais de la cible est faible là où le bruit de $\hat{C}$ est fort. Pour K grand, le shrinkage **non linéaire** (RIE, Ledoit-Péché ; Bun-Bouchaud-Potters, §4.1.2) corrige chaque valeur propre individuellement. Et la parenté avec §3.2.1 mérite d'être écrite : shrinker C vers l'identité puis inverser donne $(\delta I + (1-\delta)C)^{-1}\rho$ — la même famille de solutions que $(C + \kappa I)^{-1}\rho$ à reparamétrisation près ; ridge et shrinkage-de- C sont deux paramétrages du même estimateur, et on n'empile pas les deux à pleine dose (le κ de CV se choisit *après* avoir fixé la cible de C , sinon on double-régularise à l'aveugle). L'estimation de $\hat{C}$ elle-même suit les conventions du §1.2.2 : EWMA, demi-vie cohérente avec celle des IC.

3.2.3 Contraintes de signe et NNLS — le prior dur

La règle des signes (§3.1.4, §0.6 : un signal admis garde son signe économique) devient contrainte d'optimisation :

$$\mathbf{w}^* = \text{argmin} \|\mathbf{y} - \mathbf{S}\mathbf{w}\|^2 \text{ s.c. } \mathbf{w} \geq \mathbf{0} \text{ (NNLS, algorithme actif de Lawson-Hanson)}$$

Les conditions KKT en donnent la lecture : pour chaque k , soit $w_k > 0$ et le gradient s'annule, soit $w_k = 0$ et le gradient est ≥ 0 — un signal dont la corrélation *partielle* avec la cible, sachant les autres, est négative reçoit **exactement zéro, jamais un poids négatif**. C'est le comportement voulu : la régression qui « veut » retourner un carry signale un problème de données ou de redondance, pas une opportunité — le NNLS transforme l'alerte en plancher. La parenté avec Jagannathan-Ma (§4.2.2, encadré A) est exacte : les contraintes de signe équivalent à un shrinkage implicite des entrées de C qui justifiaient les poids négatifs — le même théorème, dans l'espace des signaux. La précaution d'emploi : sur un banc corrélé, le NNLS aussi concentre (il met à zéro la plupart des variantes d'une même famille — moins arbitrairement que le lasso, mais concentration quand même) ; la structure correcte est **hiérarchique**, héritée de §3.1.1 : agréger *d'abord* les familles en composites (1/ N intra-famille — le niveau où l'estimation n'a rien à dire), puis NNLS/ridge *entre* les composites (le niveau où les données discriminent). Deux étages, chacun réglé à la granularité que l'information supporte.

3.2.4 Fenêtres et disjonction — quand estimer, sur quoi

Les demi-vies d'estimation des IC et de C (2-4 ans, §3.1.3) se raffinent par la taxonomie de persistance de §2.4.3 : longues pour les primes de risque (le m et le τ du prior y sont stables), courtes pour les signaux comportementaux exposés au crowding (McLean-Pontiff impose de pondérer le post-publication, §2.4.2) — la réponse à « combien d'histoire » est *par famille*, pas globale. La **disjonction** ensuite, le piège central du nœud : les signaux du pool ont été *sélectionnés* sur leurs backtests (branche 2), donc $E[\hat{\rho}_k | k \text{ admis}] > \rho_k$ — le conditionnement à la sélection gonfle les IC mesurés sur l'échantillon de sélection, et une régression de combinaison ajustée sur ce même échantillon sur-pondère mécaniquement les plus chanceux : la chance est payée deux fois (§3.1.4, l'error maximization composée avec le biais de sélection). Les remèdes, par ordre de propreté : estimer w sur données strictement *postérieures* à l'admission de chaque signal ; ou utiliser comme $\hat{\rho}$ les prédictions **out-of-fold** de la CV purgée (§2.3.1 — la règle que le stacking de §3.3 érigerait en absolu) ; ou au minimum, shrinker les $\hat{\rho}$ post-sélection par le facteur bayésien de §3.1.3 avec un prior durci. La validation de la *procédure* entière — le choix de κ , de la cible T_0 , des demi-vies — relève de la **CV imbriquée** : boucle interne pour estimer (w, κ), boucle externe purgée pour juger la règle de

combinaison elle-même ; c'est la règle, pas les poids, qu'on valide — les poids changeront, la règle reste. Et la stabilité se mesure comme tout le reste : le turnover de w (EMA sur les poids, §3.1.4) est une ligne du tableau de bord de §6.3.

Le quatuor du nœud : $\lambda_j/(\lambda_j + \tilde{\kappa})$ (la ridge est un filtre spectral) ; la cible en blocs (deux paramètres contre $K^2/2$) ; les KKT du NNLS (zéro, jamais négatif — familles d'abord) ; la disjonction (la chance ne se paie qu'une fois). Ce nœud enrichit l'encadré A de deux habits supplémentaires (ridge spectrale, NNLS) et prépare §3.3 : si même les poids constants exigent cette discipline, les poids *conditionnels* devront la payer au carré.

Renvois : §0.5–§0.6 (κ , signes) ; §1.2.2 (EWMA), §1.3 (standardisation), §1.4.1 (cible normalisée) ; §2.3.1 (CV purgée, out-of-fold), §2.4.2–§2.4.3 (crowding, persistance) ; §3.1 (les limites du continuum, error maximization, prior bayésien), §3.3 (stacking), §3.4.2 (familles) ; §4.1.2–§4.1.3 (RMT, Ledoit-Wolf), §4.2.2 (Jagannathan-Ma) ; §6.2 (registre, $df(\kappa)$), §6.3 (turnover de w au tableau de bord) ; encadré A (shrinkage).

Chapter 12

§3.3 Stacking & méta-modèles

État : relu (intégré s.7, harmonisé s.14 — renvois et notation vérifiés) — source : M122
; vérification des chiffres à venir.

Troisième nœud de la branche 3 : les poids qui cessent d'être constants — apprendre à combiner, sans payer deux fois. §3.1 et §3.2 ont établi la colonne vertébrale (poids constants régularisés) ; ce nœud examine les étages supérieurs — méta-modèles, poids conditionnels, algorithmes d'experts — et se clôt sur la question qui les départage tous : chaque étage de complexité paie-t-il son loyer ?

3.3.1 Le stacking propre — la règle out-of-fold, démontrée

Le cadre (Wolpert, « Stacked Generalization », Neural Networks 1992) : un méta-modèle régresse la cible sur les *prédictions* des modèles de base, $y = \sum_k \beta_k \cdot \hat{s}_k + e$. Le danger se démontre en une ligne : si $\hat{s}_k$ est la prédiction **in-sample** d'un modèle de base, elle s'écrit $\hat{s}_k = \text{signal vrai} + \text{une part ajustée sur le bruit de ce même échantillon}$ — sa corrélation mesurée avec y contient donc le terme d'overfit, et elle est d'autant plus haute que le modèle k est plus surajusté ; le méta-modèle, qui alloue à la corrélation, **récompense l'overfitting en proportion exacte de sa gravité**. La règle absolue en découle : les méta-features sont les prédictions **out-of-fold** d'une CV purgée (§2.3.1) — chaque $\hat{s}_{k,t}$ produit par un modèle qui n'a jamais vu la période de t , purge et embargo compris ; le schéma à deux étages hérite du purging au carré (la fuite peut passer par l'un ou l'autre étage).

Deux résultats structurent la pratique. **Breiman** (« Stacked Regressions », Machine Learning 1996) : la contrainte de non-négativité sur les β est ce qui fait marcher le stacking — sans elle, la colinéarité des prédictions (nos signaux corrélés, §3.2.1) produit les poids explosifs habituels ; avec elle, on retombe sur le NNLS de §3.2.3, appliqué aux prédictions (encadré A). La version complète — poids convexes, $\beta \geq 0$ et $\sum \beta = 1$ — est le **super learner** (van der Laan, Polley & Hubbard, 2007), avec sa propriété d'oracle : la combinaison convexe sélectionnée par CV fait asymptotiquement aussi bien que le meilleur élément de la bibliothèque — la garantie qui justifie d'*empiler* les candidats plutôt que d'en élire un. La traduction pour nous : le stacking financier propre est un NNLS out-of-fold sur composites de familles — c'est-à-dire exactement la machinerie de §3.2, nourrie de prédictions décontaminées ; le « méta-modèle » n'est pas un objet nouveau, c'est la même régression avec la seule hygiène qui la rende honnête.

3.3.2 Poids conditionnels — une équivalence qui dégonfle le sujet

Le désir : $w(z)$ dépendant du régime, puisque les IC sont conditionnels (§1.2.3, §3.1.3). La formalisation minimale : modéliser $p_k(z) = a_k + b_k \cdot g(z)$, d'où $w(z) \propto C^{-1} \rho(z)$. Et l'équivalence qui remet le sujet à sa place :

$$w(z) \cdot s = \sum_k [a_k \cdot s_k + b_k \cdot (s_k \cdot g(z))]$$

— une combinaison à poids conditionnels est une combinaison à poids **constants sur le dictionnaire augmenté** $\{s_k, s_k \cdot g(z)\}$. Rien de nouveau sous le soleil : les « poids dynamiques » sont des signaux d'interaction (§1.2.3) versés au pool, toute la machinerie de §3.1-§3.2 s'applique telle quelle (ridge sur le dictionnaire augmenté, NNLS par familles, shrinkage), et surtout le **coût en degrés de**

liberté devient explicite : m conditionneurs multiplient le dictionnaire par (1+m) — c'est le N du DSR qui gonfle (§2.3.2), comptabilisé au registre, et non une sophistication gratuite. Les garde-fous hérités tiennent : 1-2 conditionneurs *pré-spécifiés* maximum, g lisse (sigmoïde de z-score — jamais de seuil dur, §1.2.3), et l'interaction admise seulement si l'IC conditionnel est démontré par double sorts sur données antérieures à la spécification. Le cas dégénéré utile : $g(z) = z$ -score de vol du *propre* P&L du sleeve — le conditionnement le plus défendable est souvent le vol-scaling par sleeve déjà imposé par §3.1.3, qui est un poids conditionnel qui ne dit pas son nom.

3.3.3 Algorithmes d'experts — la robustesse sans hypothèses

Le cadre adversarial : K experts (les sleeves), des gains $g_{k,t}$ révélés séquentiellement, aucune hypothèse — ni stationnarité, ni distribution. **Hedge** / poids exponentiels (Freund & Schapire, JCSS 1997 ; la tradition multiplicative weights) :

$$w_{k,t+1} \propto w_{k,t} \cdot \exp(\eta \cdot g_{k,t}) \iff w_{k,t} \propto \exp(\eta \cdot \sum_{s \leq t} g_{k,s})$$

avec la garantie de **regret** : contre le meilleur expert *rétrospectif*,

$$\text{Regret } T = \max_k \sum g_{k,t} - \sum \langle w_t, g_t \rangle \leq \sqrt{((T/2) \cdot \ln K)} \quad (\eta^* = \sqrt{(8 \ln K / T)})$$

— sous-linéaire en T : le regret *par période* tend vers zéro quoi que fassent les marchés. Les **universal portfolios** de Cover (Mathematical Finance 1991) donnent la version richesse : le portefeuille universel atteint la richesse du meilleur portefeuille constamment rebalancé à un facteur polynomial en T près — asymptotiquement, on ne perd rien face au meilleur mix fixe choisi *avec le recul*. La traduction praticienne dégonfle et éclaire à la fois : les poids exponentiels sur gains cumulés récents $\approx$ **pondérer par une EMA de performance** — l'ICIR-weighting de §3.1.3 avec η jouant le rôle de la demi-vie ; la nouveauté n'est pas la formule mais la *garantie* (elle tient sans stationnarité — précieux là où §2.4 a détruit l'hypothèse) et la variante **fixed share** (Herbster & Warmuth, Machine Learning 1998) : mélanger à chaque pas une fraction α vers l'uniforme, $w \leftarrow (1-\alpha) \cdot w + \alpha/K$, ce qui borne le regret contre le meilleur expert *par segments* — la version algorithmique du suivi de régimes, sans HMM ni détection (§2.4.1 : on ne détecte pas la rupture, on reste toujours prêt à en payer une — encadré E). Les limites, honnêtement : la garantie est contre le meilleur *expert*, pas la meilleure *combinaison* (Hedge ne diversifie pas, il traque) ; sur des gains aussi bruités que des P&L quotidiens, η^* est minuscule et la trajectoire des poids quasi constante — l'algorithme converge vers... l'équipondération lentement inclinée, ce qui est peut-être sa vraie leçon.

3.3.4 La hiérarchie de complexité — chaque étage paie son loyer

L'empilement rationnel, du bas vers le haut : **(i)** poids constants régularisés — composites de familles, ridge/NNLS, shrinkage bayésien (§3.1-§3.2) : la colonne vertébrale ; **(ii)** l'overlay adaptatif — fixed share à η petit sur les composites : le filet anti-régime, quasi gratuit en degrés de liberté (deux hyperparamètres, pré-spécifiables) ; **(iii)** le conditionnement explicite — 1-2 interactions démontrées, versées au dictionnaire (§3.3.2) ; **(iv)** le méta-ML complet — GBM peu profond sur méta-features out-of-fold — réservé aux contextes à grand K et longue histoire, avec un fait d'expérience pour calibrer les attentes : les gains du non-linéaire documentés par Gu-Kelly-Xiu vivent dans la relation *features* $\rightarrow$ *rendements* (§1.2.3), beaucoup moins dans la couche *prédictions* $\rightarrow$ *combinaison*, où la structure vraie (des experts positivement corrélés, aux qualités voisines — §3.1.1) est presque linéaire par nature. Le critère d'admission d'un étage est uniforme et non négociable : battre l'étage inférieur en **CV imbriquée purgée** (§3.2.4), *net du turnover des poids* qu'il ajoute (§3.1.4 — la complexité qui fait bouger w se paie en coûts avant de rapporter en IC), l'écart jugé au DSR avec le N de la couche compté au registre (§6.2). En pratique et pour clore : la plupart des books vivent aux étages (i)+(ii) ; l'étage (iv) est celui dont on parle dans les conférences et qu'on éteint discrètement l'année suivante.

Le quatuor du nœud : la démonstration out-of-fold (l'overfit se paie au carré sinon) ; $w(z) \cdot s =$ dictionnaire augmenté (le sujet dégonflé) ; $\text{Regret} \leq \sqrt{((T/2) \cdot \ln K)}$ et fixed share (la robustesse sans

détection) ; le loyer par étage en CV imbriquée nette de turnover. Trois coutures : le NNLS traverse (§3.2.3 ↔ Breiman, encadré A) ; fixed share est l'alternative au CUSUM (§2.4.1, encadré E) ; η joue le rôle de la demi-vie d'estimation (§3.1.3).

Renvois : §1.2.3 (interactions, double sorts, seuils lisses) ; §2.3.1–§2.3.2 (CV purgée, DSR/N) ; §2.4 (non-stationnarité), §2.4.1 (détection vs adaptation) ; §3.1.1 (structure du pool), §3.1.3 (ICIR/EMA, vol-scaling par sleeve), §3.1.4 (turnover des poids), §3.2 (la machinerie réutilisée), §3.2.4 (CV imbriquée) ; §6.2 (registre) ; encadrés A (NNLS-Breiman) et E (fixed share).

Chapter 13

§3.4 Orthogonalisation & gestion du pool

État : relu (intégré s.7, harmonisé s.14 — renvois et notation vérifiés) — source : M124 (+ M031 pour le cadrage) ; relecture et vérification à venir. §3.4.5 vit dans son propre fichier (3.4.5_combinaison_sous_couts.md). ; vérification des chiffres à venir.

Dernier nœud de la branche 3, et changement de perspective : au lieu de pondérer un pool donné, gérer le pool lui-même — l'alpha marginal comme monnaie. Quatre feuilles : le test d'admission quantifié ($\rho \perp$), les trois géométries de structuration (Gram-Schmidt, PCA, clustering/HRP), l'attribution par Shapley et ses conséquences incitatives, et la bifurcation organisationnelle usine vs pods — le même théorème de combinaison, à l'échelle humaine. Le nœud §3.4.5, l'interface sous coûts, clôt la branche dans un fichier séparé.

3.4.1 IC marginal et admission — le test du résidu, quantifié

Le candidat s_{new} face au pool $\{s_1 \dots s_K\}$: régresser le candidat sur le pool, $s_{new} = \sum b_k \cdot s_k + u$, et tester le pouvoir prédictif du **résidu** u . La quantité décisante en forme close : soit p_{new} l'IC standalone du candidat, ρ_{pool} le vecteur des IC du pool, c le vecteur de ses corrélations au pool ; l'IC du résidu normalisé vaut

$$\rho \perp = (p_{new} - c' C^{-1} \rho_{pool}) / \sqrt{(1 - c' C^{-1} c)}$$

— numérateur : ce que le candidat prédit *au-delà* de ce que le pool prédit déjà à travers lui ;
dénominateur : la part de variance du candidat que le pool n'explique pas. Le gain systémique s'écrit alors proprement : dans le monde décorrélé après orthogonalisation, l'ICIR² du combiné est additif,

$$ICIR^2_{\text{combiné}} = ICIR^2_{\text{pool}} + ICIR^2(u)$$

— la version signaux de la loi d'addition des ratios d'information sur composantes orthogonales (Grinold-Kahn), et la démonstration que le critère d'admission *est* $\rho \perp$, pas p_{new} : un candidat à $p_{new} = 0,05$, $c' C^{-1} c = 0,85$ apporte moins qu'un $p_{new} = 0,02$ orthogonal. C'est l'exposition résiduelle de §2.1.5, mesurée contre le pool lui-même plutôt que contre les facteurs. L'inférence sur $\rho \perp$ suit §2.1.1 et §3.1.2 (erreur type $\sigma(IC \perp) / \sqrt{T}$, Newey-West), avec le durcissement de sélection de §3.2.4 (le candidat arrive avec un $\hat{\rho}$ gonflé par sa propre admission en branche 2 — le prior hiérarchique s'applique au *résidu*). Le protocole d'admission complet empile donc : DSR du standalone (§2.3.2), $t(\rho \perp)$ contre le pool, corrélation maximale plafonnée ($c_{max} \approx 0,7-0,8$ — le garde-fou grossier qui évite de payer l'inférence fine sur des quasi-doublons), et les critères de viabilité (§2.1.4 : c^* , capacité ; §2.4.3 : rendement net de revalorisation).

3.4.2 Gram-Schmidt, PCA, clustering — trois géométries pour un pool

Gram-Schmidt séquentiel : $\tilde{s}_k$ = résidu de s_k sur $\{\tilde{s}_1 \dots \tilde{s}_{k-1}\}$ — chaque signal ne garde que sa nouveauté par rapport aux *précédents*. Vertu : les IC des $\tilde{s}$ sont additifs par construction (§3.4.1

itéré) ; vice : la dépendance à l'ordre — l'ancien capte tout le contenu commun, le récent est jugé sur ses miettes ; c'est une *hiérarchie déguisée en algèbre*, défendable seulement si l'ordre encode un vrai prior (ancienneté validée en live, §6.3). **PCA du pool** : diagonaliser C, combiner les portefeuilles propres — mathématiquement propre (directions décorréées, chacune pondérable par son ICIR propre), mais les vecteurs propres mélangent les familles en objets ininterprétables et *instables* (§4.1.2, les mêmes maux), et un pool piloté en composantes principales ne sait plus répondre à « pourquoi sommes-nous longs ce titre » — le coût de gouvernance excède le gain d'orthogonalité. **Clustering hiérarchique** : distance $d_{ij} = \sqrt{2(1-\rho_{ij})}$ (§4.1.4), linkage, coupe du dendrogramme en familles — puis l'allocation récursive du **HRP** de López de Prado (« Building Diversified Portfolios that Outperform Out-of-Sample », JPM 2016) : bissection descendante de l'arbre, variance inverse entre les deux sous-arbres à chaque nœud,

$$\alpha_{\text{gauche}} = 1 - \text{Var}(\text{gauche}) / (\text{Var}(\text{gauche}) + \text{Var}(\text{droite}))$$

— jamais d'inversion de C, seulement sa *topologie* : la robustesse vient de ce qu'on n'estime que ce que l'arbre supporte. Raffinements documentés : Raffinot (« Hierarchical Clustering-Based Asset Allocation », JPM 2017), et la sélection du nombre de clusters par gap statistic. Le verdict pratique, motivé : le clustering gagne parce qu'il épouse la topologie *vraie* du pool (les signaux naissent en familles, §3.1.1) tout en restant lisible — c'est la structure en deux étages de §3.2.3, avec l'arbre estimé plutôt que déclaré ; l'écart entre la taxonomie déclarée et le dendrogramme estimé est d'ailleurs un diagnostic en soi (une « famille » qui se disperse dans l'arbre est mal définie).

3.4.3 Attribution et incitations — Shapley, ou payer la marginalité

Le problème : attribuer l'ICIR² (ou le P&L) du combiné à des signaux corrélés — la contribution de k dépend de qui d'autre est dans le pool. L'axiomatique propre est la valeur de **Shapley** (1953) : la moyenne des contributions marginales sur tous les ordres d'arrivée,

$$\varphi_{\text{Sh}k} = \sum_{S \subseteq \text{Pool} \setminus \{k\}} \frac{|S|! \cdot (K - |S| - 1)!}{K!} \cdot [v(S \cup \{k\}) - v(S)]$$

avec $v(S) = \text{ICIR}^2(S)$ — le seul partage satisfaisant efficacité ($\sum \varphi_{\text{Sh}k} = v(\text{Pool})$), symétrie, et joueur nul ; pour v quadratique (notre cas, $\text{ICIR}^2 = \rho' C^{-1} \rho$), $\varphi_{\text{Sh}k}$ admet des formes semi-closes et l'approximation par échantillonnage d'ordres suffit en pratique — le même Shapley que §5.5.2 côté coûts, les deux faces de la même comptabilité. (On note φ_{Sh} la valeur de Shapley pour éviter toute confusion avec le φ de decay, §0.5.) La comparaison éclaire : payer au **standalone** rémunère la corrélation au pool (dix momentum se partagent dix fois le même mérite) ; au **Gram-Schmidt** rémunère l'ancienneté ; au **dernier entrant** ($v(\text{Pool}) - v(\text{Pool} \setminus k)$) sous-paie tout le monde dans un pool redondant (la somme des marginales < v total — le cœur du problème) ; **Shapley** est l'unique point fixe équitable entre ces extrêmes. La conséquence organisationnelle (Tulchinsky, *Finding Alphas*, pour le modèle WorldQuant) : rémunérer à la marginalité oriente la *recherche* — les chercheurs désertent les familles saturées pour les données vierges, l'orthogonalité du pool devient une propriété émergente des incitations ; avec l'effet pervers symétrique à surveiller : la sur-production de signaux exotiques faiblement validés, que le filtre DSR + différé-sur-live de §6.4 contient.

3.4.4 Centralisé vs pods — le même théorème, à l'échelle humaine

La bifurcation, formulée dans le langage de la branche : l'usine centralisée résout un Markowitz global (netting complet §4.3.4, diversification au niveau des forecasts, un passage de coûts) — c'est l'optimum du monde aux paramètres connus ; les pods résolvent K Markowitz locaux agrégés à la 1/N — le portefeuille de la robustesse (§3.1.1), avec en prime la propriété que l'usine n'a pas : l'**isolation des défaillances humaines** (un pod qui dérive est coupé à ses limites, §4.4.3, sans contaminer le book — le drawdown control appliqué aux personnes). Le coût du modèle pods se chiffre avec les outils de la branche : double comptage des expositions communes (les pods détiennent les mêmes crowded trades — le comomentum de §2.4.2 *intra-firme*, que le netting central partiel et les limites factorielles firm-wide de §4.5.3 viennent plafonner) et frottement de coûts (pas de crossing interne complet). Le critère de choix est celui de §3.1 transposé : l'usine domine si et seulement si

l'attribution marginale est *mesurable proprement* (registre §6.2, Shapley §3.4.3, IC marginal §3.4.1) — sans cette infrastructure de mesure, les incitations de l'usine s'effondrent et le 1/N organisationnel gagne, exactement comme le 1/N statistique gagne quand C est inestimable. La suite de cet argument — les contrats, le principal-agent — vit en §6.4.

La branche 3 se clôt avec §3.4.5 (fichier séparé — l'interface sous coûts). Le quatuor du nœud : $\rho \perp$ et l'additivité des ICIR² ; le HRP comme structure à deux étages estimée ; Shapley comme unique partage cohérent ; usine vs pods tranché par la *mesurabilité* de la chaîne registre $\rightarrow \rho \perp \rightarrow$ Shapley.

Renvois : §2.1.1 (inférence), §2.1.4–§2.1.5 (viabilité, exposition résiduelle), §2.3.2 (DSR), §2.4.2–§2.4.3 (comomentum, net de revalorisation) ; §3.1 (1/N, prior hiérarchique), §3.2.3–§3.2.4 (deux étages, durcissement), §3.4.5 (l'interface) ; §4.1.2 (instabilité PCA), §4.1.4 (distance de corrélation), §4.3.4 (netting), §4.4.3 (drawdown control), §4.5.3 (limites firm-wide) ; §5.5.2 (Shapley des coûts) ; §6.2 (registre), §6.3 (live), §6.4 (contrats, différé) ; encadré A (le résidu comme shrinkage).

Chapter 14

§3.4.5 Combinaison sous coûts — l'interface

État : relu (intégré s.7, harmonisé s.14 — renvois et notation vérifiés) — source : M124
(sous-section finale) ; vérification des chiffres à venir.

Ce nœud clôt la branche 3 et scelle l'interface entre les deux moitiés de l'arbre. Le contenu formel vit en §4.3.3 (Gârleanu-Pedersen) ; ce qui appartient à la branche 3 est sa conséquence sur *l'interface* : l'aim portfolio pondère chaque signal par $1/(1 + \varphi_k \cdot a/\gamma)$ — une fonction de la **liquidité du book** (a) — donc la pondération optimale du pool n'est pas séparable de l'implémentation : deux desks de tailles différentes doivent pondérer différemment le même pool, et la spécification complète d'un alpha transmise à l'aval comprend

(sk, ρk, σ(ICk), φk, τk)

— le signal, sa force, sa fiabilité, son decay (φk, mesuré en §2.1.2), son turnover (τk désigne ici le turnover du signal, §1.3.4 — à ne pas confondre avec le τ de dispersion du prior hiérarchique, §0.5, §3.1.3). Le contrat d'interface de §0.8 s'enrichit sans se rompre : un vecteur passe toujours de la recherche à la mise en œuvre, mais c'est un vecteur d'**objets datés et profilés, pas de nombres nus**. C'est cette fiche complète — et non le seul score du jour — que la documentation par signal de §6.4 archive, que l'optimiseur de §4.3.3 actualise, et que le ticket d'exécution de §5.3.3 transporte jusqu'au marché.

Renvois : §0.5, §0.8 (l'interface étroite) ; §1.3.4 (turnover du signal) ; §2.1.2 (mesure de φ) ; §3.1.3 (σ(IC), le τ du prior — homonymie signalée) ; §4.3.3 (Gârleanu-Pedersen — le contenu formel) ; §5.3.3 (l'urgence transporte φ) ; §6.4 (doc par signal).

Part III

Mise en œuvre

Chapter 15

§4.1 Modèles de risque

État : relu (intégré s.8, harmonisé s.14 — renvois et notation vérifiés) — sources : M078
(+ cadrage M072, références M076) ; vérification des chiffres à venir.

La branche 4 reçoit l'interface de §3.4.5 — un vecteur d'alphas datés et profilés — et le transforme en positions : $\max w' \alpha - (\gamma/2) \cdot w' \Sigma w - TC(\Delta w)$ sous contraintes. Son premier nœud construit l'objet que tout le reste consomme : Σ , la covariance des N actifs, rendue estimable par la structure factorielle

$$\Sigma = B \cdot F \cdot B' + D$$

— B les expositions, F la covariance des facteurs, D le risque spécifique diagonal. C'est aussi le modèle qui définit opérationnellement la frontière alpha/beta (§0.7) et la grille de neutralisation de §1.3.3 : le choix de B est une décision de recherche autant que de risque.

4.1.1 Factoriels fondamentaux — la lignée Barra

Le modèle postule, à chaque date, la décomposition cross-sectionnelle

$$r_t = B_t \cdot f_t + \varepsilon_t, \text{ avec } E[\varepsilon] = 0, \text{ cov}(\varepsilon) = D \text{ diagonale, cov}(f) = F$$

où $B_t \in \mathbb{R}^{N \times k}$ est *observée* : une colonne d'indicatrices par industrie, et des colonnes de « styles » (taille, value, momentum, volatilité, liquidité, leverage...) construites exactement comme des signaux — winsorisées puis standardisées en cross-section (§1.3.1), la convention Barra étant moyenne *cap-pondérée* nulle et écart-type équipondéré unitaire, pour que le portefeuille de marché soit neutre aux styles par construction. Les rendements factoriels s'estiment chaque jour par régression cross-sectionnelle pondérée (WLS/GLS) :

$$\hat{f}_t = (B_t' W B_t)^{-1} B_t' W r_t, W = D^{-1} \text{ en théorie, } \propto \sqrt{(\text{capitalisation})} \text{ en pratique Barra}$$

avec une contrainte d'identification (les indicatrices d'industrie somment à la colonne marché : on impose que les rendements d'industrie cap-pondérés somment à zéro). La série $\{\hat{f}_t\}$ alimente ensuite F par EWMA, et les résidus $\hat{\varepsilon}$ alimentent D — chacun avec sa demi-vie (§4.1.3). Les raffinements de production documentés dans les handbooks USE4/GEM (Menchero, Orr & Wang, 2011) : correction de Newey-West sur F pour l'autocorrélation des rendements factoriels lors du passage à des horizons multi-jours ; *eigenfactor risk adjustment* (les variances des portefeuilles propres de F sont systématiquement biaisées — sous-estimées pour les petites valeurs propres, exactement le mécanisme d'error maximization de §4.2.1, corrigé ici à la source) ; et *volatility regime adjustment*, un facteur multiplicatif calé sur le ratio vol réalisée / vol prédite récent.

La validation d'un modèle de risque a sa métrique propre, le **bias statistic** : pour un portefeuille test w , la série $z_t = (w' r_t) / \sigma_{\text{prédit}, t}$ doit avoir un écart-type de 1 ; $B_{\text{stat}} = \text{std}(z_t) > 1$ signale une sous-estimation systématique du risque. On la calcule sur des familles de portefeuilles (facteurs purs, portefeuilles optimisés, aléatoires) — les portefeuilles *optimisés* étant précisément ceux où

le biais statistique dérape le plus, puisque l'optimiseur charge les erreurs de Σ ; sa surveillance continue appartient au tableau de bord de §6.3. Références : Rosenberg (« Extra-Market Components of Covariance in Security Returns », JFQA 1974) ; Menchero-Orr-Wang, *The Barra US Equity Model (USE4)* ; et comme traité, Connor, Goldberg & Korajczyk, *Portfolio Risk Analysis* (Princeton, 2010) — le meilleur livre unique sur ce nœud.

4.1.2 Statistiques — PCA et nettoyage spectral

Ici B est *estimée* : diagonaliser la corrélation empirique $E = (1/T) \cdot X'X$ (X : rendements standardisés), garder les premiers vecteurs propres comme facteurs. Tout le problème est de savoir combien, et la random matrix theory donne la réponse nulle exacte : si les rendements étaient du bruit i.i.d. pur, les valeurs propres de E se distribueraient, pour $N, T \rightarrow \infty$ à $q = N/T$ fixé, selon la densité de **Marchenko-Pastur** (1967)

$$\rho_{MP}(\lambda) = (T/N) \cdot \sqrt{((\lambda_+ - \lambda)(\lambda - \lambda_-))} / (2\pi\lambda), \lambda_{\pm} = (1 \pm \sqrt{q})^2$$

(λ désigne ici les valeurs propres, usage local — §0.5). Toute valeur propre au-delà de λ_+ porte de la structure ; le « bulk » en dessous est indiscernable du bruit. Constat empirique fondateur (Laloux, Cizeau, Bouchaud & Potters, PRL 1999 ; Plerou et al., PRL 1999) : sur les actions US, ≈ 94 % des valeurs propres tombent dans le support MP (~ 6 % seulement en émergent — une vingtaine de facteurs sur 500 titres) — quelques dizaines de facteurs réels, le reste est du bruit que la covariance empirique prend pour de la structure. D'où le **clipping** : conserver les $\lambda_j > \lambda_+$ avec leurs vecteurs propres, remplacer toutes les autres par leur moyenne (en préservant la trace), reconstruire. Le raffinement d'état de l'art est le shrinkage *non linéaire* — chaque valeur propre reçoit sa propre correction, dérivée analytiquement — via l'estimateur invariant par rotation (RIE) : Ledoit & Pécché (2011), Ledoit & Wolf (« Nonlinear Shrinkage », Annals of Statistics 2012), et la revue complète Bun, Bouchaud & Potters, « Cleaning large correlation matrices » (Physics Reports, 2017). Pour le choix formel du nombre de facteurs hors cadre RMT : les critères d'information de Bai & Ng (Econometrica, 2002) et le test d'Onatski (2010).

Les avantages : aucun a priori taxonomique, capture des corrélations émergentes qu'aucune grille sectorielle ne prévoit. Les coûts : facteurs ininterprétables (on neutralise « PC3 » sans savoir ce que c'est), instabilité des vecteurs propres au-delà des 2-3 premiers (§3.4.2, les mêmes maux côté pool), et le piège point-in-time déjà établi en §1.2.1 : estimation en expanding/rolling window exclusivement — des facteurs extraits sur l'échantillon complet connaissent les crises futures. La pratique des grandes maisons est hybride : socle fondamental pour l'interprétabilité et la neutralisation, couche statistique résiduelle pour ce qui échappe à la grille.

4.1.3 Shrinkage et horizon — les paramètres du paramètre

Le shrinkage linéaire de **Ledoit-Wolf** (« Honey, I Shrunk the Sample Covariance Matrix », Journal of Portfolio Management 2004) combine la covariance empirique S et une cible structurée T_0 (identité scalée, ou corrélation constante) :

$$\tilde{\Sigma} = \delta^* \cdot T_0 + (1 - \delta^*) \cdot S$$

avec δ^* estimable en forme close — asymptotiquement, $\delta^* \approx (\sum_{ij} \text{var}(S_{ij})) / (\sum_{ij} (S_{ij} - T_{0,ij})^2)$: le numérateur mesure le bruit d'estimation, le dénominateur le biais de la cible ; on shrinke d'autant plus que S est bruitée et que la cible est proche. C'est exactement la logique bayésienne de §3.1.3, appliquée à une matrice (encadré A) — et elle s'applique à chaque étage : à Σ entière (petits univers), à F (toujours), aux betas individuels (Vasicek, §4.1.4).

La question de l'**horizon** a deux volets. Les demi-vies d'estimation d'abord : F et D n'ont aucune raison de partager la même — typiquement F en EWMA de demi-vie 90-250 jours (les corrélations entre facteurs dérivent lentement mais sûrement), D plus courte (60-90 jours, le risque spécifique bouge avec les événements d'entreprise), avec parfois une composante courte + longue combinées pour F (réactivité aux chocs sans amnésie, §1.2.2). Le passage à l'horizon de détention ensuite : la covariance à h jours n'est *pas* h fois la covariance quotidienne dès que les rendements factoriels sont autocorrélés — le momentum factoriel l'est positivement, la liquidité aussi — et la correction est l'estimateur de **Newey-West** appliqué à F :

$$F(h) \approx h \cdot [\Gamma_0 + \Sigma] = 1L (1 - 1/(L+1)) \cdot (\Gamma_l + \Gamma'_l), \Gamma_l = \text{cov}(f_t, f_{t-l})$$

C'est le même outil que pour l'inférence sur les IC (§2.2.1, §3.1.3) — troisième apparition dans l'arbre, à chaque fois pour le même péché : traiter comme indépendantes des observations qui se chevauchent (encadré D). Règle de cohérence transversale (l'argument de grille du §1.2.2) : un book qui tourne en trois jours n'a que faire d'un modèle mensuel — la demi-vie du modèle de risque, celle des signaux et l'horizon de détention doivent vivre dans le même ordre de grandeur.

4.1.4 Crypto — un facteur écrasant, des paramètres fuyants

La structure factorielle du crypto est dégénérée par rapport à l'equity : le modèle de marché

$$r_i = \alpha_i + \beta_i \cdot r_{\text{BTC}} (+ \beta_{i\text{ETH}} \cdot r_{\text{ETH}}) + \varepsilon_i$$

capture l'essentiel, avec un premier facteur expliquant régulièrement 50-70% de la variance moyenne des majors (contre ~30% pour le facteur marché equity — ordre de grandeur praticien) — et pourtant une part *spécifique* des alts paradoxalement énorme, car les queues idiosyncratiques (unlocks, exploits, listings, delistings) sont sans équivalent actions (§1.1.5). Le problème central est l'instabilité de β : les betas contre BTC changent de régime en quelques semaines (phases BTC vs phases alts, §1.2.3), ce qui impose des fenêtres courtes (30-90 jours) — donc des $\hat{\beta}$ très bruités — donc le **shrinkage de Vasicek** comme correction obligatoire :

$$\tilde{\beta}_i = w\beta \cdot \hat{\beta}_i + (1-w\beta) \cdot \bar{\beta}_{\text{groupe}}, w\beta = \tau^2\beta / (\tau^2\beta + s^2_i)$$

la mécanique exacte du posterior de §3.1.3 (s^2_i : variance d'estimation du beta individuel ; $\tau^2\beta$: dispersion vraie des betas dans le groupe), qui referme la boucle James-Stein une fois de plus (encadré A — c'est le shrinkage déjà rencontré dans la définition même du BAB, §1.1.1). Les « secteurs », faute de GICS, se construisent par clustering de corrélation : distance $d_{ij} = \sqrt{2(1-\rho_{ij})}$ (Mantegna, « Hierarchical structure in financial markets », Eur. Phys. J. B 1999), clustering hiérarchique, coupe du dendrogramme — la même machinerie que le HRP côté combinaison (§3.4.2), utilisée ici pour définir la grille de neutralisation, avec l'avantage de suivre les recompositions du marché (le cluster « L1 » de 2021 n'est pas celui de 2026) et l'inconvénient d'être lui-même une estimée instable. Dernier écart : les queues. Les rendements crypto ont un kurtosis qui rend les estimateurs de covariance L2 fragiles — winsorisation des rendements *avant* estimation de Σ , ou estimateurs robustes, et bascule du VaR vers l'ES (§4.5.1) plus impérative encore qu'en equity. Pas de référence canonique sur ce versant : la littérature praticienne et les papiers de factor investing crypto (§2.4.4, Liu-Tsyvinski) en tiennent lieu provisoirement.

Le quatuor du nœud : $\Sigma = \text{BFB}' + D$ et le bias statistic ; Marchenko-Pastur $\lambda_{\pm} = (1 \pm \sqrt{q})^2$ et le clipping/RIE ; Ledoit-Wolf δ^* ; Newey-West sur F. Trois coutures : le bias statistic appartient aussi au monitoring de §6.3 ; Newey-West fait sa troisième apparition (encadré D) ; la boucle Vasicek/James-Stein/Ledoit-Wolf est un seul théorème sous trois habits (encadré A).

Renvois : §0.7 (la frontière est relative à ce modèle) ; §1.1.1 (BAB), §1.2.1–§1.2.3 (PIT des facteurs statistiques, demi-vies, régimes BTC/alts) ; §1.3.1, §1.3.3 (standardisation des styles, neutralisation) ; §2.2.1 (NW), §2.4.4 (priors crypto) ; §3.1.3 (posterior), §3.2.2 (LW côté signaux), §3.4.2 (clustering/HRP, instabilité PCA) ; §4.2.1 (error maximization, Woodbury), §4.5.1 (ES) ; §6.3 (bias statistic au tableau de bord) ; encadrés A (shrinkage) et D (chevauchement).

Chapter 16

§4.2 Construction de portefeuille

État : relu (intégré s.8, harmonisé s.14 — renvois et notation vérifiés) — source : M080
(+ cadrage M072, références M076) ; vérification des chiffres à venir.

Deuxième nœud de la branche 4 : l'optimiseur et ses contraintes — transformer le vecteur d'alphas et le Σ de §4.1 en poids. La solution close est connue depuis Markowitz ; tout le nœud consiste à comprendre pourquoi on ne l'utilise jamais telle quelle : son venin (l'error maximization en dimension N), le prix de chaque interdit (les duals), ce qui survit de l'information (le transfer coefficient), et les trois familles de défenses — qui convergent toutes vers le même geste de régularisation.

4.2.1 MVO et error maximization — la solution close et son venin

Le programme sans friction, $\max w' \alpha - (\gamma/2) \cdot w' \Sigma w$, donne

$$w^* = (1/\gamma) \cdot \Sigma^{-1} \alpha$$

et la structure factorielle de §4.1 rend le calcul praticable via l'identité de Woodbury :

$$\Sigma^{-1} = D^{-1} - D^{-1} B \cdot (F^{-1} + B' D^{-1} B)^{-1} \cdot B' D^{-1}$$

soit $O(Nk^2)$ au lieu de $O(N^3)$, avec une lecture économique limpide : le premier terme est l'alpha divisé par le risque *spécifique* ($w_i \propto \alpha_i / D_{ii}$ — chaque titre pour lui-même), le second est la **correction de hedge factoriel** — l'optimiseur retranche la combinaison de titres qui annule les expositions factorielles induites par le premier terme. Un alpha déjà neutralisé (§1.3.3) rend ce second terme petit : c'est la traduction algébrique du contrat d'interface.

Le venin est dans Σ^{-1} . En base propre, $\Sigma^{-1} = \sum_j \lambda_j^{-1} \cdot u_j u_j'$: les directions de *petites* valeurs propres — les combinaisons long-short que le modèle croit quasi sans risque — reçoivent les poids les plus grands, or ce sont précisément les directions où $\hat{\lambda}_j$ et $\hat{u}_j$ sont les plus bruités (§4.1.2). L'optimiseur alloue vers ses propres erreurs : c'est l'**error maximization** de Michaud (« The Markowitz Optimization Enigma », FAJ 1989), déjà rencontrée en §3.1.4, ici en dimension N. Le résultat quantitatif de référence est Kan & Zhou (« Optimal Portfolio Choice with Parameter Uncertainty », JFQA 2007) : avec μ estimé sur T observations pour N actifs, la perte espérée d'utilité out-of-sample du plug-in croît comme N/T — utiliser $\hat{w} = (1/\gamma) \hat{\Sigma}^{-1} \hat{\mu}$ avec N/T proche de 1 peut produire une utilité espérée *négative*, c'est-à-dire pire que ne rien détenir — et la correction optimale est un portefeuille à trois fonds dont les poids shrinkent explicitement vers le minimum-variance. Le message chiffré rejoint DeMiguel et al. (§3.1.1) : l'optimisation ne bat le naïf que quand $T \gg N$, régime rare en pratique.

4.2.2 Contraintes et duals — le prix de chaque interdit

Avec contraintes d'égalité $Aw = b$ (neutralités beta, secteurs, facteurs ; $A \in \mathbb{R}^{m \times N}$), le lagrangien donne les conditions KKT et la solution

$$w^* = (1/\gamma) \cdot \Sigma^{-1} (\alpha - A' \lambda d), \lambda d = (A \Sigma^{-1} A')^{-1} \cdot (A \Sigma^{-1} \alpha - \gamma b)$$

(λd : le vecteur des multiplicateurs — usage local, §0.5). Lecture : tout se passe comme si on optimisait sans contrainte sur un **alpha amputé** $\tilde{\alpha} = \alpha - A'\lambda d$ — chaque contrainte active retranche de l'alpha sa projection sur la direction contrainte, et le vecteur des multiplicateurs donne, ligne par ligne, le prix en alpha de chaque neutralité. Lire les duals est le diagnostic de base : une contrainte au dual élevé et persistant signale soit un vrai désaccord entre l'alpha et le modèle de risque (à arbitrer en gouvernance, §4.5.3), soit un signal mal neutralisé en amont. Les inégalités (bornes $l \leq w \leq u$, contraintes de gross $\Sigma|w_i| \leq G$) s'ajoutent avec leurs duals $v \geq 0$ et les conditions de complémentarité — actives seulement là où elles mordent.

Le théorème de **Jagannathan-Ma** (« Risk Reduction in Large Portfolios: Why Imposing the Wrong Constraints Helps », JF 2003) donne aux contraintes leur seconde lecture : le portefeuille minimum-variance sous $w \geq 0$ (et bornes supérieures u) est *identique* au portefeuille minimum-variance non contraint calculé sur la covariance modifiée

$$\tilde{\Sigma} = \Sigma - (\delta \cdot 1' + 1 \cdot \delta') + (v \cdot 1' + 1 \cdot v')$$

où $\delta, v \geq 0$ sont les duals des bornes inférieures et supérieures actives. Les contraintes *sont* un shrinkage implicite : interdire une position extrême équivaut à réduire les covariances qui la justifiaient (encadré A ; le même théorème que le NNLS de §3.2.3, dans l'espace des titres). C'est la démonstration formelle du constat empirique que des contraintes « fausses » améliorent l'out-of-sample — elles régularisent $\hat{\Sigma}$ là où il est le plus bruité. DeMiguel, Garlappi, Nogales & Uppal (« A Generalized Approach to Portfolio Optimization », Management Science 2009) unifient le tableau : contraindre la norme de w ($\|w\|_1 \leq c$ ou $\|w\|_2 \leq c$) engendre une famille continue qui interpole entre $1/N$, minimum-variance contraint et non contraint — la ridge de §3.2, réapparue dans l'espace des titres.

4.2.3 Transfer coefficient — mesurer ce qui survit

La loi fondamentale généralisée (Clarke, de Silva & Thorley, « Portfolio Constraints and the Fundamental Law of Active Management », FAJ 2002) :

$$IR \approx TC \cdot IC \cdot \sqrt{BR}, \quad TC = \text{corr}(w^{\text{réel}}, w^*) \text{ dans la métrique du risque} = \langle w, w^* \rangle_{\Sigma} / (\|w\|_{\Sigma} \cdot \|w^*\|_{\Sigma})$$

Le TC est le cosinus de l'angle entre les positions effectivement prises et les positions idéales — la fraction de l'information fabriquée par les branches 1-3 qui atteint le P&L (§0.4). Ordres de grandeur documentés dans le papier et sa suite (Clarke-de Silva-Thorley 2006) : un mandat **long-only** vit avec $TC \approx 0,3-0,4$ (l'interdiction du short ampute plus de la moitié de l'information — l'essentiel des signaux cross-sectionnels vit dans la queue basse qu'on ne peut pas vendre, §2.1.3), un long-short contraint (neutralités + liquidité + concentration) atteint $0,7-0,9$, et chaque contrainte marginale se lit en points de TC. D'où la pratique de diagnostic standard : faire tourner en parallèle le **paper portfolio non contraint** — même alpha, même Σ , zéro contrainte, zéro coût — et décomposer l'écart de performance réel vs papier en une cascade contrainte par contrainte (puis coûts, branche 5 : c'est la naissance de la TCA du §5.5.2). Un TC qui dérive dans le temps est une alerte en soi : soit les contraintes se durcissent (capacité, §4.4.4), soit l'alpha migre vers des zones que le mandat interdit.

4.2.4 Robustesse — optimiser en sachant qu'on se trompe

Trois familles de réponses à l'error maximization, par ordre de sophistication. Le **resampling** de Michaud (*Efficient Asset Management*, 1998) : bootstrapper l'histoire, ré-optimiser sur chaque tirage, moyenner les portefeuilles obtenus — la moyenne d'optima bruités est plus stable que l'optimum du bruité (§3.1.4 ; controverse académique sur ses fondements, efficacité pratique reconnue). L'**optimisation robuste** formalise l'incertitude : maximiser le pire cas sur un ensemble d'incertitude ellipsoïdal $U = \{\alpha : (\alpha - \hat{\alpha})' \Omega^{-1} (\alpha - \hat{\alpha}) \leq \kappa r^2\}$,

$$\max_w \min_{\alpha \in U} w' \alpha - (\gamma/2) w' \Sigma w \iff \max_w w' \hat{\alpha} - \kappa r \sqrt{(w' \Omega w)} - (\gamma/2) w' \Sigma w$$

(Goldfarb & Iyengar, Mathematics of OR 2003 ; Ben-Tal & Nemirovski pour le cadre général ; Ceria & Stubbs 2006 pour la version praticienne) : le pire cas se résout en forme close et ajoute une

pénalité de risque d'estimation $\kappa \cdot \|w\|_\Omega$ — l'équivalence robuste $\Leftrightarrow$ régularisation, une fois encore (encadré A) : choisir κ , c'est choisir un shrinkage, et toute la panoplie (contraintes, normes, robust, resampling, bayésien) converge vers le même geste sous des habits différents. Troisième famille, l'assomption heuristique — « l'optimiseur du pauvre » du desk compact :

$w_i \propto (\alpha_i - \bar{\alpha}_{\text{groupe}(i)}) / \sigma_i^2$, puis caps $\pm w_{\max}$ et renormalisation au gross cible

démoyennage par groupe (la neutralisation sectorielle sans matrice A, §1.3.3), division par la variance spécifique (le premier terme de Woodbury — on saute le hedge factoriel, que la neutralisation amont a rendu petit), bornes (le Jagannathan-Ma du pauvre). Trois lignes de code qui capturent typiquement 80-90% du TC de l'optimiseur complet quand les alphas sont proprement neutralisés (ordre de grandeur praticien) — et qui explicitent le vrai théorème de ce nœud : **la sophistication de l'optimiseur est un substitut à la propreté de l'alpha, jamais un complément**. Un pipeline amont discipliné rend l'aval presque trivial ; un pipeline sale rend l'aval impossible à régler.

Le quintet du nœud : Woodbury (alpha/D – hedge factoriel) ; la perte en N/T de Kan-Zhou ; les KKT et les duals comme prix des contraintes ; Jagannathan-Ma (contraintes = shrinkage) ; TC $\approx 0,3-0,4$ en long-only et le paper portfolio comme instrument de mesure. Le nœud referme trois boucles : l'interface (un alpha neutralisé rend l'optimiseur presque trivial), l'encadré A (quatrième et cinquième habits du shrinkage), et la cascade d'attribution qui deviendra la TCA (§5.5).

Renvois : §0.4 (loi fondamentale), §0.7 (gouvernance du désaccord alpha/risque) ; §1.3.3 (neutralisation amont) ; §2.1.3 (le short porteur d'anomalies) ; §3.1.1, §3.1.4 (1/N, error maximization, resampling), §3.2 (ridge), §3.2.3 (NNLS — le même théorème) ; §4.1 (Σ , ses erreurs spectrales), §4.4.4 (capacité), §4.5.3 (limites et gouvernance) ; §5.5.2 (la cascade des paper portfolios) ; encadré A (contraintes et robust opt comme shrinkage).

Chapter 17

§4.3 Coûts dans l'optimisation

État : **relu** (intégré s.9, harmonisé s.14 — renvois et notation vérifiés) — source : M082
; vérification des chiffres à venir.

Troisième nœud de la branche 4 : la friction rendue explicite — $\max E \sum_t [x_t' \alpha_t - (\gamma/2) x_t' \Sigma_t - TC(\Delta x_t)]$. Les nœuds précédents optimisaient une photographie ; celui-ci optimise un film : la fonction de coût (§4.3.1), sa géométrie sous coûts proportionnels (§4.3.2), la solution multi-période complète de Gârleanu-Pedersen (§4.3.3 — le nœud que §2.1.2, §3.4.5 et §5.3.3 attendent), et l'implémentation par contrôle prédictif avec le netting (§4.3.4).

4.3.1 Modèles de coût — la fonction $TC(\delta)$

Pour un trade de taille δ (en fraction d'ADV ou en dollars), la forme standard à trois termes :

$$TC(\delta) = c \cdot |\delta| + Y \cdot \sigma \cdot \sqrt{(|\delta|/V)} \cdot |\delta| + (\lambda c/2) \cdot \delta^2$$

Le premier terme est le coût *proportionnel* : demi-spread + frais + taxes, payé quel que soit le rythme d'exécution. Le deuxième est l'**impact en racine carrée**, l'empirie la plus robuste de la microstructure : le coût moyen d'un métaordre de taille Q vaut $\approx Y \cdot \sigma_{\text{daily}} \cdot \sqrt{(Q/ADV)}$, avec $Y \approx 0,5$ –1, remarquablement stable entre actifs, marchés et époques — mesuré sur données propriétaires par Almgren, Thum, Hauptmann & Li (« Direct Estimation of Equity Market Impact », Risk 2005), théorisé par le modèle de liquidité latente de Tóth et al. (« Anomalous price impact and the critical nature of liquidity », PRX 2011), synthèse dans Bouchaud, Bonart, Donier & Gould, *Trades, Quotes and Prices* (2018). La décomposition temporaire/permanent appartient à §5.2.2 ; ce qui compte ici est que la racine carrée est *concave* — donc non convexe dans un optimiseur, d'où le troisième terme : l'approximation **quadratique** $(\lambda c/2) \cdot \delta^2$ (λc : coefficient de coût, usage local — §0.5), convexe, qui rend le problème soluble en forme close et sur-pénalise les petits trades / sous-pénalise les gros — un biais connu qu'on accepte pour la tractabilité, ou qu'on corrige par résolution numérique (§4.3.4). La calibration relie les deux : λc se cale pour que le coût quadratique coïncide avec la racine carrée à la taille de trade typique du book — et les paramètres (c , Y) sortent de la même TCA que ceux du backtest (§2.2.4, §5.5.4).

4.3.2 No-trade zones — la géométrie des coûts proportionnels

Avec le seul coût proportionnel c , la solution optimale n'est plus un point mais une **bande** : autour de la position cible w^* , une région $[w^* - \Delta b, w^* + \Delta b]$ dans laquelle le gradient d'utilité $|\partial U / \partial w| < c$ ne rembourse pas le spread — on ne trade que lorsque la position sort de la bande, et alors *jusqu'au bord* de la bande, jamais jusqu'à la cible (y aller coûterait du spread pour un gain marginal nul). Le résultat asymptotique classique (Constantinides, JPE 1986 ; Davis & Norman, Math. of OR 1990 ; asymptotiques de Shreve-Soner) : la demi-largeur optimale croît comme la **racine cubique** du coût,

$$\Delta b \propto c(1/3)$$

— une dépendance très douce, qui explique un fait d'expérience : même de petits coûts proportionnels justifient des bandes larges, et la perte d'utilité à utiliser une bande approximative est du

second ordre (l'optimum plat, §3.1.1, encore lui). C'est la formalisation de ce que le smoothing du §1.3.4 faisait heuristiquement, avec deux différences opérationnelles : la bande vit dans l'espace des *positions* (elle voit le netting entre sleeves, §4.3.4), et sa largeur peut se moduler par titre — étroite sur les large caps à 2 bps de spread, large sur les alts à 40 bps. Les bandes d'hystérésis simulées dans le backtest (§2.2.4) et les buckets de §3.1.3 sont deux instances du même principe.

4.3.3 Multi-période : Gârleanu-Pedersen — la formulation cross-factorielle

C'est ici que vit l'optimisation cross-factorielle multi-période — le papier est littéralement construit sur ce cahier des charges : K facteurs prédictifs de vitesses de décroissance hétérogènes, un modèle de risque, des coûts, et une politique dynamique en forme close (Gârleanu & Pedersen, « Dynamic Trading with Predictable Returns and Transaction Costs », Journal of Finance 2013). La formulation complète.

Dynamique des signaux. Les rendements sont pilotés par K facteurs (nos alphas combinés, ou les sleeves individuels) qui mean-revertent chacun à sa vitesse :

$$rt+1 = \mathbf{B} \cdot \mathbf{f}_t + u_{t+1}, \text{cov}(u) = \Sigma \Delta t + 1 = -\Phi \cdot \mathbf{f}_t + \varepsilon_{t+1}, \Phi = \text{diag}(\varphi_1, \dots, \varphi_K)$$

φ_k est la vitesse de décroissance du facteur k — le lien direct avec le profil de decay de §2.1.2 et la demi-vie du signal ($\varphi_k \approx \ln 2 / H_k$, §0.5). C'est le mot « cross-factoriel » rendu opérationnel : le problème traite *simultanément* des signaux rapides et lents.

Programme. Maximiser la valeur actualisée du P&L pénalisé du risque et des coûts quadratiques :

$$\max E \sum_t (1-\rho_a)^t [\mathbf{x}_t' \cdot \mathbf{B} \cdot \mathbf{f}_t - (\gamma/2) \cdot \mathbf{x}_t' \Sigma \mathbf{x}_t - (1/2) \cdot \Delta \mathbf{x}_t' \cdot \Lambda \cdot \Delta \mathbf{x}_t], \Lambda = \lambda_c \cdot \Sigma$$

Solution. Linéaire-quadratique gaussien → forme close en deux équations :

$$\mathbf{x}_t = \mathbf{x}_{t-1} + (\mathbf{a}/\lambda_c) \cdot (\mathbf{a}_{\text{imt}} - \mathbf{x}_{t-1}) \quad \mathbf{a}_{\text{imt}} = (\gamma \Sigma)^{-1} \cdot \Sigma_k \mathbf{B}_k \cdot \mathbf{f}_{k,t} \cdot 1/(1 + \varphi_k \cdot \mathbf{a}/\gamma)$$

La première dit : on ne saute jamais sur la cible, on trade une *fraction* $\mathbf{a}/\lambda_c$ du chemin — le taux de trading $\mathbf{a}$ résolvant une équation quadratique en $(\gamma, \lambda_c, \rho_a)$, croissant avec la liquidité. La seconde est le cœur cross-factoriel : l'aim portfolio est un **Markowitz sur alphas actualisés**, chaque facteur k entrant multiplié par $1/(1 + \varphi_k \cdot \mathbf{a}/\gamma)$ — les signaux rapides (φ grand) sont dépréciés, les lents quasi intacts. Un alpha qui meurt en trois jours ne rembourse jamais l'impact payé pour le charger ; un alpha qui persiste six mois l'amortit sur toute sa vie. Le théorème soude d'un coup trois nœuds de l'arbre — decay (§2.1.2), demi-vie/turnover (§1.3.4), coûts — et remplace par un calcul la règle de gouvernance du budget de turnover par sleeve (§0.8, §1.3.4). Sa conséquence sur l'interface — la pondération du pool n'est pas séparable de l'implémentation, les φ_k font partie de la spécification d'un alpha — est actée en §3.4.5. *Extensions documentées* : coûts non quadratiques et impact persistant (Gârleanu-Pedersen 2016, « Dynamic portfolio choice with frictions », JET) ; contraintes → plus de forme close, résolution numérique (§4.3.4).

4.3.4 Netting et implémentation — MPC et crossing interne

La pratique de production ne résout pas le programme infini : elle applique le **model predictive control** — à chaque rebalancement, résoudre le problème multi-période sur un horizon fini (avec les contraintes de §4.2, les vraies fonctions de coût, la racine carrée si le solveur le permet), exécuter le premier pas, ré-résoudre au pas suivant avec l'information nouvelle. Le cadre de référence praticien est Boyd et al., « Multi-Period Trading via Convex Optimization » (Foundations and Trends in Optimization, 2017) — qui traite aussi la version stochastique et les certificats de sous-optimalité. Le netting y est automatique et c'est son avantage décisif sur le lissage par sleeve (§1.3.4) : l'optimiseur voit le book agrégé, donc deux sleeves dont les cibles se croisent (le reversal vend ce que le momentum achète) ne génèrent *aucun* trade externe — un crossing interne à coût nul, qui peut représenter une fraction substantielle du turnover brut d'un book multi-s signaux. La comptabilité analytique doit suivre : le P&L par sleeve se calcule sur les positions *théoriques* de chaque sleeve, les coûts réels sur

les trades *nets* — et l'écart entre les deux (le « netting benefit ») est une ligne d'attribution à part entière, qui appartient à la TCA (§5.5.2) et complique l'attribution par chercheur (§3.4.3, §6.4) : dans un book intégré, le coût marginal d'un sleeve dépend des autres — le Shapley des coûts (§5.5.2) est la réponse propre.

Le quatuor du nœud : $TC(\delta)$ à trois termes ; la bande en $c^{1/3}$; l'aim de Gårleanu-Pedersen avec l'actualisation $1/(1+\phi k \cdot a/\gamma)$; le MPC et le netting benefit. C'est le nœud qui refferme l'arbitrage vitesse/coûts ouvert en §1.3.4 et qui donne son contenu formel à l'interface de §3.4.5.

Renvois : §0.5, §0.8 (ϕ , budget de turnover) ; §1.3.4 (smoothing — la version heuristique) ; §2.1.2 (ϕ mesuré), §2.2.4 (mêmes paramètres de coût) ; §3.1.1, §3.1.3 (optimum plat, buckets), §3.4.3, §3.4.5 (attribution, interface) ; §4.2 (contraintes) ; §5.2.1–§5.2.2 (la racine carrée, temporaire/permanent), §5.3.3 (l'urgence, l'autre versant de ϕ), §5.5.2, §5.5.4 (Shapley des coûts, calibration commune) ; §6.4 (attribution par chercheur).

Chapter 18

§4.4 Sizing & levier

État : relu (intégré s.9, harmonisé s.14 — renvois et notation vérifiés) — source : M084
; vérification des chiffres à venir.

Quatrième nœud de la branche 4 : quitter les poids relatifs pour l'échelle absolue du book — la stabilité du risque (vol targeting), son niveau (Kelly fractionnel), son plancher (contrôle de draw-down) et son plafond (capacité). Les trois premiers sous-nœuds forment le triptyque de l'encadré B — trois réponses au même problème d'incertitude : réduire l'exposition à l'estimé proportionnellement à son incertitude.

4.4.1 Vol targeting — le levier comme thermostat

La règle : viser une volatilité de book constante σ^* en appliquant le levier

$$L_t = \sigma^* / \hat{\sigma}_t$$

avec $\hat{\sigma}_t$ en EWMA courte (§1.2.2, demi-vie 10-30 jours). La justification est une asymétrie fondamentale : la volatilité est *prévisible* (le clustering, corrélation sérielle de σ^2 très élevée) alors que les rendements ne le sont presque pas — donc diviser par $\hat{\sigma}$ stabilise le dénominateur du Sharpe sans toucher au numérateur en espérance, et fait mieux que ça dès que rendement et vol sont liés. Le résultat académique : Moreira & Muir (« Volatility-Managed Portfolios », JF 2017) montrent qu'un scaling en $1/\hat{\sigma}^2$ sur le marché et les grands facteurs *augmente* les alphas réalisés — le rendement par unité de risque est plus faible en haute vol, donc réduire l'exposition quand la vol monte est en soi un signal de timing. Harvey et al. (« The Impact of Volatility Targeting », JPM 2018) documentent l'effet sur les moments supérieurs : réduction du kurtosis et de la queue gauche, maximale pour les actifs à effet de levier (actions — la vol monte quand le prix baisse), quasi nulle pour ceux qui n'en ont pas (obligations).

Trois précautions d'implémentation. Le levier est lui-même une position : ses variations sont des trades, et un $\hat{\sigma}$ trop réactif fabrique du turnover de levier sans espérance — même arbitrage que le smoothing (§1.3.4), résolu par une bande de non-trading sur L (§4.3.2 : on ne re-lève que si $|L_{\text{cible}}/L_{\text{actuel}} - 1|$ dépasse un seuil). Un plafond $L \leq L_{\text{max}}$ s'impose indépendamment de la formule : en régime de vol écrasée, $\sigma^*/\hat{\sigma}$ demande des leviers que le risque de saut (que $\hat{\sigma}$ ne voit pas) interdit — une borne *hors modèle*, §4.5.3. Et la procyclicité systémique : tous les books vol-targetés dé-lèvent ensemble quand la vol saute — le mécanisme amplificateur des épisodes de §2.4.2 et §4.5.2, à garder en tête quand on estime sa propre capacité à sortir. En crypto : $\sqrt{365}$ (§0.6), coût de funding du levier à intégrer dans le net, et un risque de liquidation discret (§4.5.4) qui impose L_{max} bien en dessous de ce que le vol target nu suggérerait.

4.4.2 Kelly fractionnel — le niveau du thermostat

Le vol targeting fixe la *stabilité* du risque ; Kelly fixe son *niveau*. En temps continu avec K actifs, le levier log-optimal est

$$f^* = \Sigma^{-1} \mu$$

— formellement le Markowitz de §4.2.1 avec $\gamma = 1$: le portefeuille growth-optimal est le tangent, levé à l'aversion logarithmique. Le taux de croissance sous fraction cK ($f = cK \cdot f^*$) :

$$g(cK) = r + (cK - cK^2/2) \cdot SR^2, \text{ avec au plein Kelly } g^* = r + SR^2/2$$

La parabole est le cœur pratique : à $cK = 1/2$, on capture 75% de la croissance excédentaire avec la moitié du risque — et l'asymétrie est brutale au-delà de $cK = 1$ (à $cK = 2$, croissance excédentaire nulle ; au-delà, négative avec un risque supérieur). La distribution des drawdowns rend le choix tangible : pour un book en Kelly fractionnel cK , la probabilité de jamais perdre une fraction x du capital vaut

$$P(DD \geq x) = (1 - x)(2/cK - 1)$$

— au plein Kelly, perdre 50% a probabilité $1/2$; à $cK = 1/2$, elle tombe à 12,5% ; à $cK = 1/3$, ~3%. Voilà pourquoi « demi-Kelly » est une convention et non une timidité. S'ajoute la couche d'incertitude paramétrique déjà construite en §3.1.3 : sous μ estimé, la croissance espérée du plug-in est amputée d'un terme en $\text{Var}(\hat{\mu})$, et la correction bayésienne — Kelly sur le posterior shrinké — équivaut à une fraction $cK < 1$ supplémentaire : le shrinkage des IC et le fractional Kelly sont, une fois encore, le même geste (encadré B). Références : Kelly (1956), Breiman (1961) pour les théorèmes de croissance, Thorp (« The Kelly Criterion in Blackjack, Sports Betting, and the Stock Market », 2006) pour la pratique, MacLean, Thorp & Ziemba (éds., 2011) pour la compilation des débats.

4.4.3 Contrôle de drawdown — le plancher explicite

La formalisation de référence est Grossman-Zhou (« Optimal Investment Strategies for Controlling Drawdowns », Mathematical Finance 1993) : maximiser la croissance sous la contrainte $W_t \geq \alpha f \cdot M_t$ (ne jamais perdre plus de $1 - \alpha f$ du plus haut historique M_t). La solution est un CPPI sur le coussin :

$$\text{exposition} \propto (W_t - \alpha f \cdot M_t) / W_t$$

— l'exposition est proportionnelle à la distance au plancher, et tend vers zéro quand on s'en approche. Les règles de production par paliers (réduction du gross de 25% à -5%, de 50% à -8%, etc.) en sont des discrétisations — et leur application aux *personnes* est le mécanisme d'isolation des pods (§3.4.4). Le coût est réel et double : de l'espérance abandonnée en régime normal, et l'effet cliquet — après un drawdown, le plancher relevé maintient l'exposition réduite alors que l'opportunité est souvent maximale ; les règles de ré-entrée (récupération partielle, délai, reset du high-water mark) comptent autant que les règles de coupe et sont systématiquement sous-spécifiées.

Le point analytique qui départage les convictions : **quand un stop-loss ajoute-t-il de l'espérance ?** Kaminski & Lo (« When Do Stop-Loss Rules Stop Losses? », Journal of Financial Markets 2014) donnent la réponse propre — sous rendements i.i.d., jamais (il ne fait que troquer de l'espérance contre du confort) ; sous autocorrélation *positive* (momentum), oui (la perte récente prédit une perte future qu'on évite) ; sous mean reversion, il détruit doublement (on coupe juste avant le rebond). La justification résiduelle est donc structurelle plutôt que statistique : la survie du desk, la clause de rachat de l'allocateur, la préservation de la capacité à opérer — un book qui perd son capital a une espérance nulle quelle que soit celle de ses signaux. Et l'articulation avec §4.4.1 : le vol targeting coupe déjà dans les crises *volatiles* ; le contrôle de drawdown est le filet pour le scénario qu'il rate — la glissade régulière à vol basse, le grind down où $\hat{\sigma}$ ne monte jamais.

4.4.4 Capacité — le Sharpe décroît en $\sqrt{\text{AUM}}$

Le mécanisme tient en une ligne : l'alpha brut est linéaire en AUM, les coûts sont super-linéaires à cause de l'impact en racine (§4.3.1). Avec un turnover annuel τ_{to} (le turnover, homonymie signalée en §3.4.5) et un book A :

$$P\&L(A) = \alpha \cdot A - Y \cdot \sigma \cdot \tau_{to} \cdot A \cdot \sqrt{(\tau_{to} \cdot A / (252 \cdot ADV))} = \alpha \cdot A - kc \cdot A^{3/2}$$

La condition marginale donne l'AUM optimal en forme close :

$$A^* = (4/9) \cdot 252 \cdot \text{ADV} \cdot \alpha^2 / (Y^2 \cdot \sigma^2 \cdot \tau \text{to}^3)$$

et deux enseignements structurants s'y lisent. La capacité croît avec le carré de l'alpha mais décroît avec le **cube du turnover** — les sleeves rapides saturent dramatiquement les premiers, et la frontière de capacité d'un book intégré est essentiellement celle de ses sleeves lents : troisième apparition du même arbitrage vitesse/coûts après le smoothing (§1.3.4) et l'actualisation Gârleanu-Pedersen (§4.3.3), ici en version « combien de capital ». Et au-delà de A^* , le Sharpe net décroît continûment (les coûts croissent en $\sqrt{A}$ par dollar) : la capacité n'est pas un mur mais une pente, et la décision de taille est un choix sur la courbe Sharpe(A) — que l'allocateur et le desk ne tranchent pas au même endroit, l'un maximisant le P&L total (A^*), l'autre souvent les frais sur encours (au-delà). Références : Perold & Salomon (« The Right Amount of Assets Under Management », FAJ 1991) pour le cadre ; Frazzini, Israel & Moskowitz (« Trading Costs of Asset Pricing Anomalies », 2015) pour les capacités empiriques des grands facteurs sur données de trading réelles ; Landier, Simon & Thesmar sur performance et taille ; Isichenko pour la dérivation pratique. En crypto, l'application numérique est dégringolante : hors BTC/ETH, les ADV réels (nettoyés du wash trading, §1.2.4, §2.2.5) donnent des A^* de quelques millions à quelques dizaines de millions pour les stratégies cross-sectionnelles sur alts (ordre de grandeur praticien, dépendant fortement des paramètres) — la raison structurelle pour laquelle l'edge y persiste : il ne vaut pas la peine d'être arbitré par les grands books.

Le quatuor du nœud : $L = \sigma^*/\hat{\sigma}$ et ses trois précautions ; la parabole $g(cK)$ et $P(DD \geq x) = (1-x)^{(2/c_K-1)}$; Grossman-Zhou/CPPI et le verdict de Kaminski-Lo ; $A^* \propto \text{ADV} \cdot \alpha^2 / \tau \text{to}^3$ — le cube du turnover. Le triptyque $\hat{\mu}$ shrinké / $cK < 1$ / plancher explicite est l'encadré B au complet : trois échelles (position, book, organisation — §6.4 fournira la troisième), une réponse.

Renvois : §0.6 ($\sqrt[3]{365}$) ; §1.2.2 (EWMA), §1.2.4 (ADV nettoyé), §1.3.4 (l'arbitrage vitesse/coûts) ; §2.2.5 (wash trading), §2.4.2 (procyclicité du crowding) ; §3.1.3 (posterior shrinké, sleeves vol-égalisés), §3.4.4 (pods = drawdown control humain) ; §4.2.1 (Markowitz $\gamma = 1$), §4.3.1–§4.3.3 (impact, bandes, GP), §4.5.2–§4.5.4 (stress, bornes hors modèle, liquidations) ; §5.2.1 (Y) ; §6.4 (le différé incitatif — troisième échelle) ; encadré B (croissance & survie).

Chapter 19

§4.5 Gestion des risques

État : **relu** (intégré s.9, harmonisé s.14 — renvois et notation vérifiés) — source : M086
; vérification des chiffres à venir.

Dernier nœud de la branche 4 : celui qui surveille les quatre autres, et surtout ce qu'ils ne voient pas — ce que Σ mesure mal (les queues, les corrélations conditionnelles) et ce qui n'y est pas du tout (la contrepartie, les cascades de liquidation). Quatre feuilles : les métriques de queue et leurs backtests, le stress et les corrélations conditionnelles, la gouvernance des limites et du risque de modèle, et le cas crypto où le risque dominant vit hors de Σ .

4.5.1 VaR et expected shortfall — les métriques et leurs tests

Les définitions, sur la perte L à horizon donné :

$$\text{VaR}_q = \inf\{x : P(L > x) \leq 1-q\}, \text{ES}_q = E[L \mid L \geq \text{VaR}_q] = (1/(1-q)) \cdot \int q^1 \text{VaRu du}$$

La VaR est un quantile — elle dit où commence la queue, rien sur ce qu'elle contient ; l'ES est la moyenne de la queue. Le cadre axiomatique qui les départage est Artzner, Delbaen, Eber & Heath (« Coherent Measures of Risk », Mathematical Finance 1999) : une mesure cohérente doit être monotone, invariante par translation, positivement homogène et **sous-additive** — $\rho(X+Y) \leq \rho(X) + \rho(Y)$, la diversification ne peut pas augmenter le risque. La VaR viole la sous-additivité (contre-exemples standard avec des positions à défaut discret : la VaR d'un portefeuille de deux obligations peut dépasser la somme des VaR), l'ES la satisfait — d'où la bascule réglementaire (FRTB) et pratique vers l'ES, renforcée par sa sensibilité à toute la queue.

L'estimation, trois familles : paramétrique gaussienne ($\text{VaR}_q = z_q \cdot \sqrt{w' \Sigma w}$ — hérite intégralement des défauts de Σ en queue), simulation historique (le quantile empirique des P&L rejoués — non paramétrique mais aveugle aux changements de régime), et le compromis dominant, la **simulation historique filtrée** (FHS, Barone-Adesi, Giannopoulos & Vosper 1999) : rejouer les rendements passés *rescalés* par le ratio de vol $\hat{\sigma}_t/\hat{\sigma}_s$ — la forme de la distribution vient de l'histoire, son échelle du présent. Le backtesting ferme la boucle : le test de couverture de **Kupiec** (POF, 1995) vérifie que la fréquence des exceptions x/T est compatible avec $1-q$ via $LR = -2 \cdot \ln[(1-p)(T-x) \cdot p^x / ((1-x/T)(T-x) \cdot (x/T)^x)] \sim \chi^2(1)$, et **Christoffersen** (1998) teste leur *indépendance* — des exceptions groupées signalent un modèle qui rate les régimes même si leur nombre total est correct, le défaut le plus commun. Pour l'ES, longtemps réputée non backtestable (non-elicitability), les tests d'**Acerbi & Székely** (2014) fournissent la réponse praticienne. Et la couture avec §4.1.1 : le bias statistic est exactement un backtest de Σ — VaR, ES et bias statistic sont trois contrôles du même objet à trois quantiles différents.

4.5.2 Stress et corrélations conditionnelles — là où Σ ment

Le fait empirique central : les corrélations ne sont pas constantes, et elles montent *précisément quand on en a besoin*. Deux formalisations. La dynamique : le **DCC** d'Engle (« Dynamic Conditional Correlation », JBES 2002) —

$$Q_t = (1-a-b) \cdot \bar{Q} + a \cdot \varepsilon_t - 1 \varepsilon_t - 1 + b \cdot Q_{t-1}$$

un GARCH sur la matrice de corrélation, qui capture la dérive mais reste un modèle L2. L'asymétrie de queue ensuite : les **corrélations d'excédance** de Longin & Solnik (« Extreme Correlation of International Equity Markets », JF 2001) — la corrélation conditionnelle aux mouvements extrêmes — montrent que les corrélations actions montent dans la queue *basse* et pas dans la haute : la diversification s'évapore à la baisse seulement. Le langage propre est celui des copules : le coefficient de dépendance de queue

$$\lambda_L = \lim_{q \rightarrow 0} P(U \leq q \mid V \leq q)$$

vaut **zéro pour la copule gaussienne** quelle que soit la corrélation — le théorème qui condamne toute la machinerie Σ en régime extrême : deux actifs gaussiens corrélés à 0,9 deviennent asymptotiquement indépendants dans la queue ; une copule t (paramètre ν) donne $\lambda_L > 0$. Traité de référence : McNeil, Frey & Embrechts, *Quantitative Risk Management* (Princeton, 2015).

D'où les stress tests, dont la version qui compte pour un book systématique n'est pas macro mais *positionnelle* : le scénario « les détenteurs de mes positions dé-lèvent ensemble ». Le document canonique est **Khandani & Lo** (« What Happened to the Quants in August 2007? », Journal of Investment Management 2007) : en trois jours, les books stat arb — décorrelés en régime normal — ont subi des pertes synchrones massives suivies d'un rebond, la signature d'une liquidation forcée d'un acteur commun se propageant par les positions partagées ; le crowding de §2.4.2 devenu mécanisme de contagion. La grille de stress complète mélange donc scénarios historiques rejoués (2008, mars 2020, août 2007 pour le style), chocs hypothétiques par facteur ($\pm 5\sigma$ sur chaque ligne de F), et **reverse stress tests** : partir de la perte inacceptable, chercher le scénario le plus *probable* qui la produit — l'exercice qui révèle les concentrations que la VaR moyenne masque.

4.5.3 Limites et risque de modèle — la gouvernance du doute

L'architecture de limites suit la hiérarchie du book : au sommet, vol cible et drawdown max (§4.4) ; puis les limites d'exposition par facteur ($|bk| \leq b_{\max}$, en unités de σ du facteur), par groupe de neutralisation, par titre (le cap de §4.2.4), par liquidité (jours d'ADV détenus) ; enfin les limites opérationnelles (turnover, gross, net). Deux principes de design : chaque limite doit avoir un *propriétaire* et une procédure d'escalade datée (une limite sans conséquence codifiée est une décoration), et les limites doivent être **mesurées dans le même système que l'optimisation** — une limite factorielle calculée sur un autre modèle de risque que celui de l'optimiseur crée des violations fantômes et des vraies expositions invisibles. Les duals de §4.2.2 et les limites sont les deux faces du même système de prix internes ; les kill switches gradués de §6.3 en sont l'automatisation.

Le risque de modèle est la couche réflexive : Σ , les modèles de coût, la VaR sont des estimées, et §3.1.4 s'applique à chacun. La discipline praticienne (l'esprit de Derman, « Model Risk », 1996, et Rebonato) : inventorier les hypothèses de chaque modèle et le scénario qui les casse ; faire tourner des modèles *concurrents* (un Σ fondamental et un statistique — leur désaccord est une mesure gratuite d'incertitude de modèle, la version matricielle de l'écart rank-IC/Pearson-IC de §2.1.1) ; et plafonner ce que le modèle peut demander (les caps de §4.2.4, le $L_{\max}$ de §4.4.1 : des bornes *hors modèle* qui restent quand le modèle déraile). La somme est une inversion du fardeau de la preuve : le modèle a raison par défaut en régime normal, tort par défaut en régime extrême.

4.5.4 Crypto — le risque hors de Σ

Le déplacement structurel : en crypto, les pertes maximales historiques des books market-neutral ne viennent pas de Σ mais de l'infrastructure. **Contrepartie et custody** d'abord : les fonds sur une venue centralisée sont une créance chirographaire sur elle (FTX, novembre 2022, en cas d'école) — la gestion est un problème de crédit, pas de marché : notation interne des venues (preuves de réserves — nécessaires, non suffisantes : elles montrent les actifs, pas les passifs —, régulation, historique), limites par contrepartie, sweep régulier vers custody, et le calcul explicite du rendement exigé pour chaque unité de risque venue. **Liquidations** ensuite, la mécanique qui transforme la microstructure en risque de book : positions margées $\rightarrow$ prix de liquidation ; la cascade — liquidations forcées $\rightarrow$ impact $\rightarrow$ nouveaux franchissements — est l'amplificateur non linéaire des queues crypto (§5.1.4), partiellement amorti par les conventions de *mark price*

(médiane multi-venues plutôt que dernier prix local, précisément pour éviter les liquidations sur mèche) et l'assurance/ADL des venues, qui ajoutent leur propre risque (l'auto-deleveraging ferme vos positions *gagnantes* quand le fonds d'assurance est vide — un risque de modèle de la venue, subi). La règle de sizing qui en découle : le levier se calcule contre le scénario de cascade (gap de 15-30% en minutes sur un alt), pas contre $\hat{\sigma}$ quotidien (§4.4.1). **Depegs** enfin : le collatéral et les jambes « cash » en stablecoins portent un risque de saut discret (USDC au plancher de 0,87 le 11 mars 2023, exposition SVB de Circle ; UST à zéro) corrélé précisément aux stress de venues — diversification des stables, jambes courtes en stables *différents* des jambes de collatéral, et inclusion du depeg dans la grille de reverse stress. Pas de traité canonique : post-mortems, documentation des moteurs de marge des venues, littérature praticienne.

La branche 4 se clôt ici. Le quintet du nœud : VaR/ES et la cohérence d'Artzner ; FHS + Kupiec/Christoffersen/Acerbi-Székely ; $\lambda L = 0$ gaussien (le théorème qui condamne Σ en queue) ; Khandani-Lo et le reverse stress positionnel ; limites et duals comme un seul système de prix internes. Le pipeline complet des branches 1-4 produit désormais des positions cibles — la branche 5 les transforme en trades.

Renvois : §2.1.1 (l'écart rank/Pearson, version matricielle), §2.4.2 (crowding $\rightarrow$ contagion) ; §3.1.4 (l'incertitude d'estimation, appliquée aux modèles eux-mêmes) ; §4.1.1 (bias statistic — troisième contrôle), §4.1.4 (queues crypto, winsorisation de Σ), §4.2.2, §4.2.4 (duals, caps), §4.4 (vol cible, drawdown, $L_{\max}$) ; §5.1.4 (mark price, mécanique des perps) ; §6.3 (kill switches gradués, tableau de bord) ; encadré E (la réponse graduelle).

Chapter 20

§5.1 Microstructure

État : relu (intégrés s.10, harmonisés s.14 — renvois et notation vérifiés) — source : M092
(+ cadrage M088) ; vérification des chiffres à venir.

La branche 5 est l'étage entre les positions cibles de la branche 4 et le P&L réel : transformer Δw en trades, au moindre coût total. Son premier nœud décrit le terrain avant la physique de l'impact — l'anatomie des lieux où les trades se forment : carnets et files, enchères, fragmentation, et les trois objets proprement crypto (perps, AMM, MEV). Le fil théorique du nœud est la sélection adverse : le spread comme prix d'assurance contre l'information, décliné du teneur de marché de Glosten-Milgrom au LP d'un AMM (encadré C).

5.1.1 Carnets d'ordres, priorité, tick size — la mécanique des files

Le carnet est un ensemble de files d'attente par niveau de prix, servi en priorité **prix-temps** (meilleur prix d'abord, puis premier arrivé — le pro-rata de certains futures étant l'exception qui change tout le jeu : on y sur-cote en taille au lieu de courir en temps). L'objet théorique central est le spread, et sa lecture moderne est informationnelle : dans **Glosten-Milgrom** (JFE 1985), le teneur de marché cote $\text{ask} = E[v \mid \text{le prochain trade est un achat}]$ et $\text{bid} = E[v \mid \text{vente}]$ — le spread est la prime de **sélection adverse**, ce qu'il perd contre les informés facturé aux non-informés ; il croît avec la probabilité d'information et s'effondre... en fermant le marché quand elle est trop haute (le no-trade de Milgrom-Stokey en toile de fond). La décomposition empirique standard (Huang & Stoll, RFS 1997) partage le spread réalisé en traitement / sélection adverse / inventaire ; et l'estimateur de **Roll** (JF 1984) mérite d'être connu pour son élégance : sous spread constant s et valeur fondamentale martingale, le bid-ask bounce crée une autocovariance négative des variations de prix, d'où

$$s = 2 \cdot \sqrt{(-\text{cov}(\Delta p_t, \Delta p_{t-1}))}$$

— la mesure du spread sans voir les quotes, encore utile sur données pauvres (et l'explication du biais haussier des vols estimées en tick, §1.2.2, comme du faux reversal de §2.2.2).

Le **tick size** structure tout le reste : c'est le pas de prix minimal, et son rapport au spread « naturel » de l'actif classe les marchés. Actif *large-tick* (le spread bute sur son plancher d'un tick) : files profondes, la ressource rare est la **position dans la queue** — la priorité temporelle a une valeur monétisable, le jeu est d'être en tête (§5.4.1). Actif *small-tick* : files minces, surenchère permanente au tick, le jeu se déplace vers le prix. La valeur d'une position de file se calcule d'ailleurs proprement : c'est une option d'exécution dont le sous-jacent est le flux, et les remplissages en tête sont mesurablement moins adverses (markouts, §5.4.3). Références d'ensemble : Harris, *Trading and Exchanges* (2003) ; Bouchaud et al., *Trades, Quotes and Prices* (2018) pour les régularités empiriques du carnet (profondeur en bosse, flux autocorrélé) ; Cont-Kukanov-Stoikov (2014) pour la sensibilité prix-flux au meilleur niveau (§5.4.2).

5.1.2 Auctions — la liquidité batchée

L'enchère d'appel (call auction) inverse la logique du continu : accumulation d'ordres sans exécution, diffusion d'un prix indicatif et d'un **imbalance**, puis croisement à l'instant T au prix unique qui

maximise le volume exécutable (avec règles de départage sur l'imbalance résiduel et la proximité du dernier prix). Trois vertus d'exécution : pas de spread (prix unique), pas de course de vitesse (le batching neutralise la latence — l'argument théorique de Budish, Cramton & Shim, QJE 2015, qui proposent d'en faire le mode *permanent* du marché), et une profondeur sans équivalent dans le continu. D'où leur rôle croissant : la clôture US concentre de l'ordre de 5 à 10 % du volume quotidien selon la période et l'univers — plus de 10 % sur les titres du S&P 500 (indexation, MOC/LOC) —, l'ouverture absorbe l'information overnight (§1.2.2 : la décomposition overnight/intraday commence ici), et les enchères de volatilité (reprises post-halt, LULD) gèrent les discontinuités. Pour le desk systématique, deux usages distincts : *canal d'exécution* — le rebalancement lent passe par la clôture, où l'impact par dollar est minimal, au prix d'un risque de prix jusqu'à 16h — et *source de signaux* — les imbalances publiés (Nasdaq dès 15h50) prédisent le mouvement vers la clôture et sa réversion le lendemain, la famille événementielle du §1.1.5. Le piège de backtest associé : un signal « exécuté à la clôture » qui se calcule *sur* la clôture est le look-ahead du §2.2.2 sous son déguisement le plus fréquent — l'entrée légitime est l'enchère du lendemain ou le prix indicatif à la coupure des MOC.

5.1.3 Fragmentation et routing — un marché en morceaux

L'equity US se négocie sur des dizaines de venues : bourses lit (16+), dark pools (~30 ATS), et l'internalisation par les wholesalers (la majorité du flux retail, via payment for order flow). Le ciment réglementaire est Reg NMS : le **NBBO** (meilleur bid/offer consolidé) et l'order protection rule (interdiction d'exécuter à travers un meilleur prix affiché ailleurs) — qui créent eux-mêmes la course : le NBBO officiel (SIP) est en retard sur les flux directs, et « connaître le vrai NBBO avant les autres » est un métier. Le **smart order router** résout, ordre par ordre, un problème d'allocation sous incertitude : répartir entre venues selon la profondeur affichée *et* cachée, les grilles de frais (maker-taker vs taker-maker inversé — le rebate change le signe du coût marginal), la probabilité de remplissage, et la **toxicité** mesurée de chaque venue — les markouts post-exécution par venue, qui révèlent où le flux adverse se concentre (§5.4.3). Les dark pools exécutent au midpoint sans pré-trade transparency : spread économisé, mais sélection adverse redistribuée — le résultat de référence est Zhu (« Do Dark Pools Harm Price Discovery? », RFS 2014) : les informés, pressés d'exécuter, migrent vers le lit ; le dark écrème le flux non informé, ce qui *améliore* le price discovery lit tout en dégradant la qualité moyenne du remplissage dark aux moments informés — exactement ce que les markouts par venue mesurent. Sur l'effet net de la fragmentation : O'Hara & Ye (JFE 2011) trouvent qu'elle n'a pas dégradé — plutôt amélioré — la qualité d'exécution consolidée. Version Europe : MiFID II, double volume caps sur le dark, essor des *periodic auctions* — le batching de §5.1.2 en format micro. Pour le desk : la fragmentation est d'abord un problème de **données** (consolider soi-même les feeds, horodater à la réception — le §1.2.4 appliqué au tick, §6.1) avant d'être un problème de trading.

5.1.4 Crypto — perps, AMM, MEV

Perpétuels. Le carnet est standard ; le produit ne l'est pas. Le **funding** arrime le perp au spot sans échéance :

$$\text{funding} = \text{clamp}(\text{TWAP}(\text{premium index}) + \text{taux d'intérêt}, \pm \text{cap}), \text{premium} = (\text{perp} - \text{index}) / \text{index}$$

réglé toutes les 8h (00/08/16 UTC) entre longs et shorts — d'où trois objets d'exécution : les instants de règlement comme grille (exécuter juste avant/après un funding extrême a un coût/gain explicite, §1.2.2), le **mark price** (médiane ou composite multi-venues) qui gouverne marges et liquidations en découplant le P&L du dernier prix local — la défense anti-mèche de §4.5.4 — et l'**index price** (panier de spots) dont la composition est un risque de modèle de la venue. Le basis trade (long spot / short perp, encaisser le funding) est l'arbitrage structurel qui maintient tout l'édifice — et le carry observé de §1.1.2.

AMM. La liquidité on-chain n'est pas un carnet mais une courbe. Pool à produit constant $\mathbf{x} \cdot \mathbf{y} = \mathbf{k}$: prix spot $p = y/x$, et l'exécution de Δx contre le pool rend

$$\Delta y = y \cdot \Delta x / (x + \Delta x), \text{prix moyen dégradé de } \approx \Delta x / x, \text{prix marginal de } \approx 2 \Delta x / x$$

— un impact **déterministe et lisible on-chain** avant de trader, transparence de coût sans équivalent tradfi. Uniswap v3 (Adams et al., 2021) concentre la liquidité par plages [pa, pb] via des réserves virtuelles — reconstituant de facto un carnet, avec des LP devenus market makers à inventaire. Le coût des LP a reçu sa formalisation propre : au-delà de l'« impermanent loss » ($IL = 2\sqrt{r}/(1+r) - 1$ pour un ratio de prix r), la mesure propre est le **LVR** — loss-versus-rebalancing (Milionis, Moallemi, Roughgarden & Zhang, 2022) : la perte du pool contre les arbitragistes qui le réalignent sur le prix externe, $\approx \sigma^2/8$ **par unité de temps** en produit constant — la sélection adverse de Glosten-Milgrom réécrite pour les courbes : le LP cote un prix figé contre un flux informé par construction (encadré C).

MEV. Dans la mempool publique, une transaction est visible avant inclusion : un ordre swap peut être **sandwiché** — achat inséré avant (front-run), revente après (back-run), la victime exécutant au pire de sa tolérance de slippage. Documenté par Daian et al. (« Flash Boys 2.0 », IEEE S&P 2020) avec les priority gas auctions ; l'architecture post-Merge (proposer-builder separation, blocs construits aux enchères par des builders spécialisés) a industrialisé l'ordonnancement. Les défenses font partie du coût d'exécution on-chain : routage privé (Flashbots Protect et équivalents), agrégateurs, limites de slippage serrées, découpage. S'ajoute, inter-venues, le **lead-lag** : le price discovery vit sur la venue dominante (mesurable par l'information share de Hasbrouck, JF 1995) et les autres suivent à quelques centaines de millisecondes — à la fois un signal tactique (§5.4.2) et une règle de mesure (la vol et les prix de référence se prennent sur la venue directrice, §1.2.2).

Le quintet du nœud : le spread comme assurance (Glosten-Milgrom), Roll $s = 2\sqrt{(-cov)}$, la file comme actif (large vs small tick), le batching des auctions (et son look-ahead), $LVR \approx \sigma^2/8$. Trois coutures : Glosten-Milgrom $\rightarrow$ LVR est le même théorème sous deux technologies de marché (encadré C) ; le look-ahead d'auktion rejoint la liste canonique de §2.2.2 ; la consolidation des feeds renvoie à §6.1.

Renvois : §1.1.2 (carry/funding), §1.1.5 (imbalances comme signaux) ; §1.2.2 (overnight/intraday, venue directrice, grille funding), §1.2.4 (capture propriétaire du tick) ; §2.2.2 (look-ahead, Roll $\rightarrow$ faux reversal) ; §4.5.4 (mark price, liquidations) ; §5.2 (la physique de l'impact), §5.4.1–§5.4.3 (file, microprice, markouts) ; §6.1 (consolidation des feeds) ; encadré C (sélection adverse).

Chapter 21

§5.2 Impact de marché

État : **relu** (intégré s.10, harmonisé s.14 — renvois et notation vérifiés) — source : M094
; vérification des chiffres à venir.

Deuxième nœud de la branche 5 : la physique du coût — le nœud le plus « lois d'échelle » de tout l'arbre, dont l'amont a déjà emprunté deux fois le résultat central (§4.3.1, §4.4.4). Quatre feuilles : la loi en racine carrée et sa théorie (liquidité latente), le partage temporaire/permanent, le modèle à propagateur qui unifie la dynamique, et la mesure empirique avec ses biais — tous du même côté. Le triplet d'exposants à retenir : $\delta \approx 1/2$, $\gamma \approx 1/2$, $\beta = (1-\gamma)/2 \approx 1/4$.

5.2.1 La loi en racine carrée — l'empirie et sa théorie

Le fait, énoncé maintenant avec ses conditions : pour un **métaordre** — une intention parente de taille Q , découpée en ordres enfants et exécutée sur une durée T de l'ordre de la fraction de journée — l'impact moyen au moment de la complétion vaut

$$I(Q) = Y \cdot \sigma_{\text{daily}} \cdot (Q/V_{\text{daily}})^{\delta}, \delta \approx 0,4-0,6, Y \approx 0,5-1$$

avec σ_{daily} la volatilité quotidienne et V_{daily} le volume quotidien. Trois propriétés remarquables. L'**universalité** : le même exposant et le même ordre de grandeur de Y sur les actions de toutes capitalisations, les futures, les options, le FX, et le bitcoin (Donier & Bonart, « A million metaorder analysis of market impact on the Bitcoin », Market Microstructure and Liquidity 2015 — même $\delta \approx 0,5$ sur un marché sans aucune institution commune avec l'equity) — la signature d'un mécanisme indépendant des détails institutionnels, et le pendant métaordre de l'inélasticité macro de Gabaix-Koijen (§1.1.3). La **quasi-indépendance en T** : à Q fixé, exécuter en 2h ou en 6h change peu l'impact au premier ordre (elle gouverne en revanche la part qui relaxe, §5.2.2). Et la **concavité**, qui est le scandale théorique : doubler la taille coûte $\sqrt{2}$, pas 2 — le millionième dollar impacte moins que le premier.

Le scandale, parce que le modèle canonique prédit du linéaire. **Kyle** (Econometrica 1985), version statique : un informé connaissant $v \sim N(p_0, \sigma v^2)$ trade x , noyé dans le flux bruité $u \sim N(0, \sigma u^2)$; le market maker efficient cote $p = E[v | x+u]$, et l'équilibre linéaire donne

$$p = p_0 + \lambda K \cdot (x + u), \lambda K = \sigma v / (2\sigma u)$$

— l'impact est linéaire en taille, de pente le ratio information/bruit ; le « Kyle's lambda » reste l'unité de mesure de l'illiquidité (λK : usage local, §0.5). La résolution de la contradiction est la théorie de la **liquidité latente** (Tóth et al., PRX 2011 ; formalisée en réaction-diffusion par Donier, Bonart, Mastromatteo & Bouchaud, « A fully consistent, minimal model for non-linear market impact », Quantitative Finance 2015) : la liquidité *affichée* au carnet est une fraction infime des intentions ; le carnet **latent** a une densité de volume $\rho v(p)$ qui s'annule *linéairement* au prix courant — $\rho v(p) \approx \rho' \cdot |p - p_t|$ — parce que les intentions proches du prix sont exécutées ou révélées en permanence. Absorber Q consomme alors l'aire sous la densité :

$$Q = \int_0^I \rho' \cdot x \, dx = (\rho'/2) \cdot I^2 \Rightarrow I = \sqrt{(2Q/\rho')}$$

— la racine carrée tombe de la géométrie, et l'impact mesure la *rareté locale de liquidité*, pas le contenu informationnel du trade. Le raccord des deux mondes : Kyle décrit la composante permanente/informationnelle agrégée, la racine carrée décrit le coût mécanique d'exécution — §5.2.2 fait le partage.

5.2.2 Temporaire vs permanent — ce qui relaxe et ce qui reste

Le profil temporel type d'un métaordre : pendant l'exécution, l'impact courant croît en racine de la fraction exécutée — $I(q) \approx Y \cdot \sigma \cdot \sqrt{(q/V)}$, trajectoire concave — culmine au pic $I_{\text{peak}} = I(Q)$ à la complétion, puis **relaxe** sur des heures vers un plateau

$$I_{\infty} \approx (1/2 \text{ à } 2/3) \cdot I_{\text{peak}}$$

L'ordre de grandeur du plateau n'est pas un hasard : sous la condition de *fair pricing* (le prix post-relaxation égale le prix moyen payé par le métaordre — l'équilibre où ni l'exécutant ni ses contreparties ne gagnent mécaniquement l'un sur l'autre ; Farmer, Gerig, Lillo & Waelbroeck, « How efficiency shapes market impact », Quantitative Finance 2013), le plateau vaut exactement le coût moyen, soit pour un impact courant en $\sqrt{q}$:

$$I_{\infty} = (1/Q) \cdot \int_0^Q Y \cdot \sigma \cdot \sqrt{(q/V)} \, dq = (2/3) \cdot I_{\text{peak}}$$

Le partage conceptuel s'ensuit : la composante **permanente** est informationnelle (le marché a appris quelque chose du flux — le λK de Kyle, agrégé), la composante **transitoire** est mécanique (la pression sur la liquidité latente, qui se reconstitue). Deux conséquences opérationnelles directes. Pour le *coût* : ce que paie le desk est l'impact moyen pendant l'exécution ($\sim 2/3$ du pic pour $\delta = 1/2$), pas le pic — c'est ce nombre que le modèle de §4.3.1 doit calibrer. Pour le *signal* : la relaxation post-métaordre est une prédiction de prix — l'écho du reversal court terme du §1.1.1, dont une part substantielle n'est que la relaxation de l'impact des flux d'autrui ; la frontière entre « alpha de reversal » et « fourniture de liquidité aux métaordres » est purement sémantique, et c'est l'articulation profonde entre les branches 1 et 5 (renvoi structurant du squelette).

5.2.3 Le modèle à propageur — la dynamique complète

Le cadre qui unifie (Bouchaud, Gefen, Potters & Wyart, « Fluctuations and response in financial markets », Quantitative Finance 2004) : le prix comme somme des empreintes de tous les trades passés,

$$p_t = p_{-\infty} + \sum_{s < t} G(t-s) \cdot \varepsilon_s \cdot f(v_s) + \sum_{s < t} \eta_s$$

avec $\varepsilon_s = \pm 1$ le signe du trade s , $f(v) \approx v^\theta$ ($\theta \approx 0,1-0,3$: l'impact d'un trade *individuel* dépend à peine de sa taille — l'information est dans le signe), et $G(l)$ le **propagateur** : l'empreinte résiduelle d'un trade l pas après. Le fait empirique qui contraint tout : le flux signé a une **mémoire longue** —

$$C(l) = \text{corr}(\varepsilon_t, \varepsilon_{t+l}) \sim c \cdot l^{-\gamma}, \gamma \approx 0,5$$

(Lillo & Farmer, « The long memory of the efficient market », Studies in Nonlinear Dynamics & Econometrics 2004) — l'autocorrélation des signes décroît si lentement que sa somme diverge, conséquence directe du découpage des métaordres (la distribution de leurs tailles en loi de puissance produit exactement ce γ). Le paradoxe : un flux aussi prévisible devrait rendre les prix prévisibles. La résolution est la **condition de diffusion** : pour que p_t reste une quasi-martingale malgré le flux persistant, le propageur doit décroître à la vitesse qui compense exactement,

$$\text{Var}(p_{t+l} - p_t) \propto l \Rightarrow G(l) \sim l^{-\beta}, \beta = (1-\gamma)/2 \approx 0,25$$

— l'impact *doit* être transitoire, et sa vitesse de relaxation n'est pas libre : elle est cousue à la mémoire du flux. C'est le théorème central du nœud : la forme de G , la persistance du flux et l'efficience des prix sont une seule contrainte à trois inconnues. Raffinements documentés : le modèle à propagateur unique sur-relaxe aux longs horizons — versions à deux composantes (transitoire + permanente, le HDIM de Lillo et al.), et le **cross-impact** : la généralisation matricielle $pt = \sum G_{ij}(t-s) \cdot \epsilon_{j,s}$ couple les actifs (trader l'un déplace l'autre via les arbitragistes et les facteurs communs — Benzaquen, Mastromatteo, Tóth & Bouchaud 2017) ; la matrice de cross-impact recoupe la structure factorielle de §4.1, et l'ignorer sous-estime le coût des trades *de facteur* (le rebalancement simultané de 500 titres du même secteur impacte le facteur, pas 500 idiosyncrasies). Synthèse de tout le nœud : Bouchaud, Bonart, Donier & Gould, *Trades, Quotes and Prices* (2018), chapitres impact.

5.2.4 Mesure empirique — les biais avant les chiffres

La mesure exige des **métaordres** reconstitués — des données propriétaires (les ordres parents d'un broker ou du desk), car le flux public ne montre que les enfants anonymes. Les jeux de référence : Almgren, Thum, Hauptmann & Li (2005, Citigroup — le papier fondateur, forme fonctionnelle : impact temporaire $\propto (Q/VT)^{3/5}$, permanent $\approx$ linéaire), Bacry, Iuga, Lasnier & Lehalle (2015), Zarinelli, Treccani, Farmer & Lillo (« Beyond the square root », 2015 — le plus grand échantillon public, confirmant $\delta \approx 0,5$ avec une dépendance logarithmique résiduelle en participation), et côté crypto Donier-Bonart 2015. Les biais de mesure sont le vrai sujet, car ils sont tous du même côté. Le **conditionnement à l'information** : les métaordres ne sont pas aléatoires — on achète parce qu'on prédit la hausse — donc le drift observé pendant l'exécution mélange impact et alpha ; la séparation exige soit des trades non informés identifiables (rebalancements mécaniques, rolls), soit le profil de *relaxation* (l'alpha ne relaxe pas, l'impact mécanique si). L'**endogénéité de la taille** : le desk trade gros quand la liquidité est bonne — la taille est choisie en fonction du coût anticipé, ce qui aplatit la courbe mesurée (les gros Q observés sont ceux des jours faciles). Et le **biais de survie des enfants passifs** hérité de §5.5.3 : les tranches limites non remplies manquent à l'appel côté coût. La conséquence de design, qui referme la boucle sur §6.2 : la calibration propre exige de **logger l'intention** (le parent, sa taille décidée, son heure de décision) et pas seulement les exécutions — le pendant exécution du registre d'hypothèses de la recherche ; et l'étalon-or, coûteux mais sans biais, est l'**expérience randomisée** (une fraction des métaordres tirée au sort en taille/rythme — la pratique des grands desks pour calibrer Y hors conditionnement, §5.5.4). En crypto, la mesure est paradoxalement plus facile (données tick publiques complètes, AMM à impact déterministe comme référence, §5.1.4) et plus piégée (wash trading dans Vdaily, §1.2.4, §2.2.5 : un ADV gonflé sous-estime Q/V donc sous-estime les coûts réels — l'erreur qui fabrique des capacités fictives en §4.4.4).

Le triplet du nœud : $\delta \approx 1/2$ (la racine, universelle jusqu'au bitcoin), $\gamma \approx 1/2$ (la mémoire du flux), $\beta = (1-\gamma)/2$ (la relaxation cousue à la mémoire). Trois coutures structurantes : reversal $\leftrightarrow$ relaxation (§1.1.1 — la frontière sémantique) ; cross-impact $\leftrightarrow$ modèle factoriel (§4.1) ; wash trading $\rightarrow V \rightarrow$ capacité (§1.2.4 $\rightarrow$ §4.4.4).

Renvois : §1.1.1 (reversal = relaxation), §1.1.3 (Gabaix-Koijen — la version macro) ; §1.2.4, §2.2.5 (ADV nettoyé) ; §4.1 (cross-impact et facteurs), §4.3.1 (le coût à calibrer $\approx 2/3$ du pic), §4.4.4 (capacité) ; §5.1.4 (AMM comme référence déterministe), §5.3 (le rythme, à impact donné), §5.5.3–§5.5.4 (biais des non-exécutés, randomisation) ; §6.2 (logger l'intention — le registre côté exécution).

Chapter 22

§5.3 Scheduling

État : **relu** (intégré s.11, harmonisé s.14 — renvois et notation vérifiés) — source : M096
; vérification des chiffres à venir.

Troisième nœud de la branche 5 : le rythme optimal d'exécution — répartir Q sur $[0, T]$ en arbitrant impact, risque et alpha ; le nœud le plus « contrôle optimal » de l'arbre. Quatre feuilles : la dérivation Almgren-Chriss complète, les benchmarks comme objectifs déguisés, le terme d'alpha qui borne l'urgence (le raccord avec Gârleanu-Pedersen), et les extensions (résilience, non-arbitrage, HJB, adaptatif). Convention locale : κ_{AC} désigne l'urgence d'Almgren-Chriss (distincte de la pénalité ridge κ de §0.5) et γ_p le coefficient d'impact permanent (distinct de l'aversion au risque γ).

5.3.1 Almgren-Chriss — la dérivation complète

Le programme (Almgren & Chriss, « Optimal Execution of Portfolio Transactions », Journal of Risk 2000) : liquider X unités sur $[0, T]$, découpé en pas τ_p , avec x_k la position résiduelle ($x_0 = X$, $x_N = 0$) et $v_k = (x_{k-1} - x_k)/\tau_p$ le rythme. Deux impacts, tous deux linéaires dans la version canonique : **permanent** — le prix dérive de $-\gamma_p \cdot v_k \cdot \tau_p$ à chaque pas — et **temporaire** — le prix d'exécution est dégradé de $h(v) = \varepsilon_s \cdot \text{sgn}(v) + \eta \cdot v$, subi seulement par la tranche courante. Le prix diffuse par ailleurs : $\sigma \sqrt{\tau_p} \cdot \xi_k$. Le coût total (l'implementation shortfall vs prix de décision, §5.5.1) a alors pour moments

$$E[C] = \frac{1}{2} \gamma_p X^2 + \varepsilon_s \cdot X + \tilde{\eta} \cdot \Sigma_k \tau_p \cdot v_k^2, \quad \tilde{\eta} = \eta - \gamma_p \tau_p / 2 \quad \text{Var}[C] = \sigma^2 \cdot \Sigma_k \tau_p \cdot x_k^2$$

Première leçon, lisible avant toute optimisation : le terme permanent $\frac{1}{2} \gamma_p X^2$ est **indépendant du chemin** — avec un impact permanent linéaire, seule compte la taille totale, et l'optimisation ne porte que sur l'arbitrage temporaire/risque (la linéarité du permanent n'est pas gratuite : c'est une condition de non-arbitrage, §5.3.4). Le programme moyenne-variance $\min E[C] + \lambda_r \cdot \text{Var}[C]$ donne par calcul des variations l'équation d'Euler $\tilde{\eta} \cdot \ddot{x} = \lambda_r \sigma^2 \cdot x$, d'où la trajectoire en forme close

$$x(t) = X \cdot \sinh(\kappa_{AC}(T-t)) / \sinh(\kappa_{AC}T), \quad \kappa_{AC} = \sqrt{(\lambda_r \sigma^2 / \tilde{\eta})}$$

— exponentielle décroissante de constante de temps $1/\kappa_{AC}$, l'**urgence** : elle croît avec l'aversion au risque et la vol (le risque de prix presse), décroît avec le coût d'impact (la friction freine). Cas limites éclairants : $\lambda_r = 0$ redonne la ligne droite (TWAP — c'est le résultat antérieur de Bertsimas & Lo 1998, coût espéré seul) ; $\lambda_r \rightarrow \infty$ donne l'exécution immédiate. Et la propriété la plus utile en pratique : quand $\kappa_{AC}T \gg 1$, la trajectoire devient $x(t) \approx X \cdot e^{-\kappa_{AC} \cdot t}$ — **indépendante de T** : le problème a une échelle de temps intrinsèque $1/\kappa_{AC}$, et fixer une deadline lointaine ne change rien au comportement effectif. En variant λ_r , on trace la **frontière efficiente d'exécution** ($E[C]$, $\text{Var}[C]$) — l'objet que le desk montre à l'allocateur pour transformer « exécutez bien » en un point choisi sur une courbe.

5.3.2 Benchmarks — le dilemme du trader

Chaque benchmark industriel est un objectif d'optimisation déguisé, et les nommer révèle ce qu'ils minimisent. **IS/arrival** : viser le prix de décision — l'objectif d'Almgren-Chriss lui-même, le seul benchmark aligné sur le coût économique vrai (Perold, §5.5.1). **TWAP** : rythme constant —

optimal à aversion nulle et impact linéaire. **VWAP** : suivre le profil de volume intra-journalier $u(t) = V(t)/V_{\text{total}}$ (le U de la journée equity) — sous l'hypothèse standard que la liquidité suit le volume, trader $v(t) \propto u(t)$ minimise l'impact à participation constante *effective* ; c'est l'objectif de *tracking* (minimiser $\text{Var}[\text{prix payé} - \text{VWAP}]$), pas de coût — un ordre à 20% du volume « bat son VWAP » en le fabriquant (§5.5.3). **POV** : participation fixe $v(t) = p \cdot V_{\text{marché}}(t)$ — le benchmark adaptatif minimal, sans deadline garantie. Le **dilemme du trader** structure le choix : exécuter vite minimise le risque vs arrival mais maximise l'impact ; lentement l'inverse — et chaque benchmark est une position sur ce spectre, IS assumant l'arbitrage explicitement, VWAP/POV le déléguant au profil de marché. La cohérence d'ensemble (Kissell, *The Science of Algorithmic Trading*, 2013 ; Guéant, *The Financial Mathematics of Market Liquidity*, 2016) : le benchmark de la TCA (§5.5) doit être celui de l'objectif — mesurer vs VWAP un ordre schedulé en IS fabrique du bruit d'attribution. Crypto : pas de clôture, un profil $u(t)$ par sessions (US/Asie) et par grille de funding (§1.2.2), et un $V_{\text{marché}}$ contaminé par le wash trading (§1.2.4, §2.2.5) qui rend le POV naïf dangereux — participer à 10% d'un volume à moitié fictif, c'est participer à 20% du vrai.

5.3.3 Alpha et urgence — le terme manquant

Le programme d'Almgren-Chriss suppose le prix martingale ; or le desk exécute *parce qu'il a un signal*. Ajouter un drift attendu $\mu(t)$ sur le prix (positif pour un achat motivé par un alpha) introduit le **coût d'opportunité** — chaque unité non encore exécutée manque le mouvement prédit — et l'équation d'Euler devient

$$\dot{\eta} \cdot \ddot{x}(t) = \lambda \sigma^2 \cdot x(t) + \mu(t)/2$$

Avec un alpha à décroissance exponentielle $\mu(t) = \mu_0 \cdot e^{-\varphi t}$ ($\varphi = \ln 2 / H\alpha$, mesuré en §2.1.2), la solution ajoute à la trajectoire $\sinh$ un terme particulier en $e^{-\varphi t}$: la trajectoire est **front-loadée**, d'autant plus que φ est grand — un signal qui meurt vite s'exécute vite, quitte à payer l'impact ; un signal lent s'étale. La règle d'ordre de grandeur qui en sort :

$$\text{urgence effective} = \max(\kappa AC, \sim \varphi)$$

— le scheduling est borné en dessous par la vitesse de péremption de l'information. Et le raccord annoncé : c'est le **même arbitrage que Gârleanu-Pedersen** (§4.3.3) aux deux échelles — GP décide *combien* charger d'un signal selon son φk (l'aim portfolio actualisé), Almgren-Chriss augmenté décide *à quel rythme* l'atteindre selon le même φ ; dans le cadre unifié, le facteur d'actualisation $1/(1+\varphi k \cdot a/\gamma)$ et le front-loading sont les deux projections d'une seule politique dynamique. Le point organisationnel qui en découle : l'interface portefeuille → exécution doit transporter l'**urgence du trade** — le φ du signal qui l'a causé (§3.4.5), pas seulement sa taille — un ticket d'exécution sans urgence force le scheduler à une aversion moyenne fausse pour tout le monde.

5.3.4 Extensions — résilience, non-arbitrage, HJB, adaptatif

Obizhaeva-Wang (« Optimal trading strategy and supply/demand dynamics », Journal of Financial Markets 2013) : remplacer l'impact temporaire instantané par un carnet qui se **reconstitue à vitesse ρw** (impact transitoire à décroissance exponentielle — la version exécutable du propagateur de §5.2.3). La solution optimale change de forme : deux **blocs** discrets aux extrémités et un rythme constant entre,

$$\text{bloc initial} = \text{bloc final} = X/(\rho w T + 2), \text{taux intermédiaire} = \rho w X/(\rho w T + 2)$$

— l'haltère : on consomme d'emblée la profondeur disponible, on trade ensuite exactement au rythme où elle se régénère, on finit en absorbant ce qui reste. *Gatheral* (« No-dynamic-arbitrage and market impact », Quantitative Finance 2010) fournit la police des modèles : impact instantané $f(v)$ et noyau de décroissance $G(l)$ ne sont pas librement combinables — un impact permanent **non linéaire** crée un arbitrage dynamique (acheter puis revendre en profitant de la convexité), et les paires admissibles sont contraintes (permanent $\Rightarrow$ linéaire ; racine carrée $\Rightarrow$ transitoire avec décroissance compatible — la cohérence exacte avec la condition de diffusion de §5.2.3).

Le traitement HJB complet (Cartea, Jaimungal & Penalva, *Algorithmic and High-Frequency Trading*, 2015 ; Guéant 2016) pose la fonction valeur $H(t, x, S, q)$ et l'équation d'Hamilton-Jacobi-Bellman associée ; l'apport n'est pas la re-dérivation d'AC (qu'on retrouve en cas particulier, avec l'ansatz exponentiel-quadratique des utilités CARA) mais l'ouverture du menu des contrôles : exécuter **aussi en ordres limites** — avec intensité de remplissage $\lambda(\delta) = A \cdot e^{-k\delta}$ à distance δ du mid, le contrôle optimal de la version liquidation donne des cotes du type $\delta^*(t, q) = 1/k + \text{composante d'inventaire}$ — le pont formel avec Avellaneda-Stoikov (§5.4.4) : liquidation et market making sont le même problème HJB avec des conditions terminales différentes. *L'adaptatif* enfin (Almgren & Lorenz, « Adaptive arrival price », 2007) : la trajectoire statique re-résolue à chaque pas n'est **pas** la politique dynamique optimale — la vraie solution est « aggressive in the money » : accélérer quand l'exécution est en avance sur son budget de coût (dépenser les gains de prix en réduction de risque), ce qui améliore strictement la frontière moyenne-variance ; le principe se retrouve dans tous les schedulers de production sous forme de bandes autour de la trajectoire cible — le MPC de §4.3.4, descendu à l'échelle intra-journalière.

Le triplet du nœud : $\kappa_{AC} = \sqrt{(\lambda r \sigma^2 / \eta)}$ (l'urgence) ; l'haltère $X/(\rho w T + 2)$ (la résilience) ; $\max(\kappa_{AC}, \varphi)$ (l'alpha borne le rythme). Coutures : $GP \leftrightarrow AC$, une politique à deux échelles (le renvoi structurant « φ traverse l'arbre ») ; Gatheral $\leftrightarrow$ condition de diffusion (§5.2.3) ; le ticket-avec-urgence rejoint l'interface (§3.4.5) et la production (§6.3).

Renvois : §1.2.2, §1.2.4 (grille funding, wash trading) ; §2.1.2 (φ mesuré), §2.2.5 (volumes nettoyés) ; §3.4.5 (l'interface transporte φ) ; §4.3.3–§4.3.4 (GP, MPC) ; §5.2.3 (propagateur), §5.4.4 (le même HJB), §5.5.1, §5.5.3 (IS, benchmark contaminé) ; §6.3 (le ticket en production).

Chapter 23

§5.4 Tactique & alphas d'exécution

État : **relu** (intégré s.11, harmonisé s.14 — renvois et notation vérifiés) — source : M098
; vérification des chiffres à venir.

Quatrième nœud de la branche 5 : la décision ordre par ordre, sous le scheduler — pour chaque tranche : où, comment, à quel prix. Quatre feuilles : l'arbitrage limit vs market et la file comme actif, les prédicteurs à horizon de secondes (microprice, OFI), la mesure et les défenses contre la sélection adverse (markouts), et le cadre du market making (Avellaneda-Stoikov et sa descendance). Le fil : le spread est un prix d'assurance contre l'information — mesuré, tarifé, défendu (encadré C).

5.4.1 Limit vs market — l'arbitrage fondamental et la file comme actif

La comparaison en espérance, pour une tranche d'achat au meilleur bid contre un ordre market à l'ask :

$$E[\text{coûtlimit}] = P\text{fill} \cdot (-s/2 + AS) + (1 - P\text{fill}) \cdot C\text{chase vs } E[\text{coûtmarket}] = +s/2 + \text{impact}$$

L'ordre limite *gagne* le demi-spread s'il est rempli, mais paie deux termes cachés : la **sélection adverse** AS — il n'est rempli que quand le marché le traverse, donc conditionnellement à une information défavorable — et le **coût de chasse** Cchase en cas de non-remplissage (re-coter plus haut, ou finir en market à un prix dégradé — le biais de sélection des non-remplis de §5.5.3). L'arbitrage bascule avec le régime de tick (§5.1.1) : sur un actif large-tick, $s/2$ est gros et la file profonde — le passif domine *si* on obtient une bonne position de file ; sur un actif small-tick, $s/2$ est mince et l'AS relative énorme — l'agressif raisonné reprend l'avantage.

La file est donc un actif, et sa valeur se calcule : **Moallemi & Yuan** (« The Value of Queue Position in a Limit Order Book », 2016) modélisent la position q dans la file comme une option d'exécution dont la valeur *décroît* avec q — les remplissages de tête de file arrivent sur le flux « normal » (peu informé), ceux de fond de file n'arrivent que dans les balayages (très informés) ; l'écart de markout entre tête et queue de file atteint une fraction significative du spread, et il justifie toute la tactique d'acquisition de priorité : coter tôt, ne jamais annuler-recoter sans raison (on repart en fond de file), viser les instants où la file se reconstruit (post-trade, post-tick-change). La quantité de contrôle est $P\text{fill}$, estimable par first-passage sur la dynamique de file (arrivées, annulations, exécutions devant soi — le cadre de files d'attente de Cont-de Larrard 2013).

5.4.2 Signaux de microstructure — les prédicteurs à horizon de secondes

Le prix de référence d'abord : le mid ignore les tailles, or un bid de 10 000 contre un ask de 500 n'est pas un marché symétrique. Le **microprice** pondère en croix :

$$P\text{micro} = (Q_b \cdot P_a + Q_a \cdot P_b) / (Q_a + Q_b)$$

— proche de l'ask quand le bid est lourd (la pression acheteuse pousse vers le haut), et démontrablement meilleur prédicteur du mid futur que le mid ; Stoikov (« The Micro-Price », Quantitative Finance 2018) en donne la version propre — l'espérance martingale du mid à l'équilibre de la chaîne imbalance/spread — dont la forme croisée est l'approximation au premier ordre. Le signal de flux

ensuite : l'**order flow imbalance** de Cont, Kukanov & Stoikov (« The Price Impact of Order Book Events », Journal of Financial Econometrics 2014) agrège les événements au meilleur niveau —

$$\text{OFIt} = \Sigma (\Delta Qb \cdot 1\{\text{contribution bid}\} - \Delta Qa \cdot 1\{\text{contribution ask}\}), \Delta P \approx \beta \text{OFI} \cdot \text{OFI}, \beta \text{OFI} \propto 1/\text{profondeur}$$

— la relation prix-flux la plus robuste de la microstructure : *linéaire* en OFI (contrairement à l'impact des volumes tradés seuls), de pente inverse de la profondeur, stable intra-jour. S'y ajoutent la classification des trades (**Lee & Ready** 1991 : signer par rapport au mid, tick test en cas d'égalité — trivial en crypto où l'agresseur est dans le flux), l'autocorrélation des signes (§5.2.3, exploitable à ces horizons), la détection de *sweeps* (un ordre qui traverse plusieurs niveaux signe un métaordre pressé — son suiveur immédiat est rentable, sa relaxation ensuite), et la déplétion de file (une file qui fond sans trades annonce le tick). Ces prédicteurs à IC élevé et decay en secondes ne sont pas des « signaux » au sens des branches 1-3 — leur capacité est absorbée par leur propre exploitation tactique — mais ils gouvernent chaque décision de placement : c'est l'*alpha d'exécution*, dont la monnaie est le coût évité, pas le P&L directionnel.

5.4.3 Anti-sélection adverse — mesurer, puis se défendre

La mesure universelle est le **markout** : pour une exécution de signe ε au prix p ,

$$M(\tau_m) = \varepsilon \cdot (\text{midt} + \tau_m - p), \tau_m \in \{100 \text{ ms}, 1 \text{ s}, 10 \text{ s}, 1 \text{ min}\}$$

— le P&L marked-to-mid de l'exécution après τ_m . La décomposition canonique en découle : le *spread effectif* $2\varepsilon(p - \text{midt})$ se partage en **spread réalisé** $2\varepsilon(p - \text{midt} + \tau_m)$ — ce que le passif gagne vraiment — et **sélection adverse** $2\varepsilon(\text{midt} + \tau_m - \text{midt})$ — ce que le mouvement post-trade lui reprend (Glosten 1987 pour le cadre ; c'est la version mesurable du spread de Glosten-Milgrom de §5.1.1, et la métrique par laquelle §5.1.3 note la toxicité des venues). Un profil $M(\tau_m)$ systématiquement négatif et croissant en $|\tau_m|$ signe un flux contre lequel on ne devrait pas coter.

Les défenses, par ordre de coût : les **filtres de fair value** — ne pas laisser reposer un ordre quand le microprice ou l'OFI lui sont contraires (l'essentiel de l'AS se concentre dans des fenêtres identifiables : la cote « stale » après un mouvement de la venue directrice est le repas gratuit des arbitragistes de latence) ; les **annulations conditionnelles** (retirer sur déplétion de file, sur sweep adjacent, sur signal de la venue leader — le lead-lag de §5.1.4 utilisé en bouclier) ; l'évitement des **fenêtres toxiques** programmées — annonces macro (§1.2.4), instants de funding crypto, ouvertures — où l'AS explose ; et les protections de structure de marché quand elles existent (speed bumps, last look en FX — avec leur propre coût de rejet). La limite de l'exercice est un théorème d'équilibre : l'AS ne s'élimine pas, elle se *tarife* — un passif parfaitement défendu ne remplit plus rien ($P_{\text{fill}} \rightarrow 0$ dans l'équation de §5.4.1) ; l'optimum est un niveau d'AS assumé et payé en connaissance, pas zéro.

5.4.4 Making vs taking — le cadre d'Avellaneda-Stoikov et sa descendance

La frontière tactique ultime : à chaque instant, l'edge espéré de *faire* le marché vaut $\text{spread}/2 + \text{rebat} - \text{AS} - \text{coût d'inventaire}$, celui de le *prendre* vaut $\text{signal} - \text{spread}/2 - \text{frais} - \text{impact}$ — et le desk systématique vit des deux côtés selon le titre, l'heure et le signal. Le cadre d'optimisation du côté maker est **Avellaneda-Stoikov** (« High-frequency trading in a limit order book », Quantitative Finance 2008) : un agent CARA(γ) cote autour d'un **prix de réservation** décalé par son inventaire q ,

$$r_t = s_t - q \cdot \gamma \cdot \sigma^2 \cdot (T - t)$$

(détenir q unités rend vendeur : on décale les deux cotes contre son propre stock), avec des intensités de remplissage exponentielles $\lambda(\delta) = A \cdot e^{-k\delta}$ à distance δ de r , et le spread total optimal en forme close

$$\delta a + \delta b = \gamma \sigma^2 (T - t) + (2/\gamma) \cdot \ln(1 + \gamma/k)$$

— premier terme : la prime de risque d'inventaire ; second : l'arbitrage fréquence/marge dicté par l'élasticité k du flux. La descendance opérationnelle est **Guéant-Lehalle-Fernandez-Tapia** (« Dealing with the inventory risk », Mathematics and Financial Economics 2013) : bornes d'inventaire dures $|q| \leq Q$, horizon infini, et le système se réduit à des équations linéaires donnant des cotes stationnaires $\delta^*(q)$ par niveau d'inventaire — la forme sous laquelle le market making se code réellement ; Cartea-Jaimungal-Penalva (2015) ajoutent l'ambiguïté de modèle et les signaux (coter avec l'OFI de §5.4.2 dans la dérive : le pont formel entre making et alpha court terme). Et le raccord de §5.3.4 tient : liquidation (AC augmenté d'ordres limites) et market making (AS/GLFT) sont **le même problème HJB** à conditions terminales près — un scheduler qui exécute en passif *est* un market maker à cible d'inventaire mobile.

Côté crypto, trois déplacements matériels. La grille **maker/taker** : les rebates maker des venues majeures (jusqu'à rendre le making net-positif hors AS) déplacent structurellement l'optimum vers le passif — le paramètre « rebate » entre dans l'équation de §5.4.1 au même titre que $s/2$. Le **lead-lag inter-venues** comme signal tactique premier : coter sur la venue retardataire avec la dérive de la directrice (l'information share de Hasbrouck, §5.1.4, transformée en fair-value filter) — la source d'AS dominante y étant précisément les cotes stables cross-venues. Et la **grille de funding** : autour de 00/08/16 UTC, flux de rebalancement prévisibles (§5.1.4) — fenêtre toxique pour le maker naïf, opportunité pour le maker informé du signe du funding. Le tout sur des carnets dont la profondeur affichée est moins fiable qu'en equity (spoofing moins policé, §1.2.4 côté données) : les filtres de §5.4.3 s'y règlent plus paranoïaques.

Le fil conducteur, désormais complet sur ses quatre faces (encadré C) : **le spread est un prix d'assurance contre l'information** — Glosten-Milgrom le théorise (§5.1.1), le markout le mesure (§5.4.3), Avellaneda-Stoikov le tarife dynamiquement (§5.4.4), et le LVR le réécrit pour les AMM (§5.1.4). Le quatuor du nœud : $E[\text{coût limit vs market}]$ complet ; le microprice et $\Delta P \approx \beta \cdot \text{OFI}$; $M(\tau)$ et le partage spread réalisé / AS ; $r = s - q\gamma\sigma^2(T-t)$.

Renvois : §1.2.4 (fenêtres macro, fiabilité des carnets crypto) ; §5.1.1 (tick, files, Glosten-Milgrom), §5.1.3 (toxicité des venues), §5.1.4 (lead-lag, funding, rebates) ; §5.2.3 (signes autocorrélés) ; §5.3.4 (le même HJB) ; §5.5.3 (biais des non-remplis), §5.5.4 (scorecards, alphas d'exécution depuis les résidus TCA) ; encadré C (sélection adverse).

Chapter 24

§5.5 Transaction cost analysis

État : **relu** (intégré s.11, harmonisé s.14 — renvois et notation vérifiés) — source : M100
; vérification des chiffres à venir.

Dernier nœud de la branche 5 : la comptabilité qui referme la boucle exécution → recherche — mesurer ce que coûte vraiment l'implémentation. Quatre feuilles : la décomposition de Perold (quatre termes, quatre propriétaires), la cascade des paper portfolios emboîtés, les pièges de mesure (tous du même côté), et la boucle de retour qui fait de la TCA un organe du système plutôt qu'un rapport.

5.5.1 Implementation shortfall — la décomposition de Perold

Le cadre (Perold, « The Implementation Shortfall: Paper Versus Reality », JPM 1988) : comparer le P&L du **portefeuille papier** — la décision exécutée instantanément, intégralement, sans frais, au prix de décision p_d — au P&L réel. Pour un ordre d'achat de Q titres décidé en p_d , dont les tranches q_j s'exécutent aux prix p_j et dont $Q_u = Q - \sum q_j$ reste non exécuté à l'horizon de mesure (prix p_T), en insérant le prix d'arrivée p_a (premier instant où l'ordre atteint le marché) :

$$\text{IS} = Q_{\text{exec}} \cdot (p_a - p_d) [\text{délai}] + \sum q_j \cdot (p_j - p_a) [\text{trading}] + Q_u \cdot (p_T - p_d) [\text{opportunité}] + \text{frais}$$

Quatre termes, quatre propriétaires : le *délai* appartient à l'infra et au circuit de décision (le lag signal→ordre du §2.2.2, mesuré en production) ; le *trading* au scheduler et à la tactique (c'est lui que §5.2-§5.4 optimisent) ; l'*opportunité* au dimensionnement des tranches et à la politique de complétion — le terme que les mesures naïves omettent et qui porte l'essentiel du fameux « iceberg des coûts » de Wagner : sur un signal vrai, ne pas exécuter coûte en espérance, et une tactique ultra-passive au trading flatteur se paie intégralement ici. La somme est le seul chiffre économiquement honnête : c'est l'écart exact entre le backtest (qui vit en papier) et le compte en banque — l'IS est la définition opérationnelle du terme de coûts que toutes les branches amont pénalisent.

5.5.2 La cascade d'attribution — les paper portfolios emboîtés

Le desk systématique généralise Perold en empilant les portefeuilles fictifs, chaque étage isolant une décision :

$$\text{P\&L}(\text{idéal non contraint}) \rightarrow \text{P\&L}(\text{contraint}) \rightarrow \text{P\&L}(\text{schedulé}) \rightarrow \text{P\&L}(\text{exécuté}) \rightarrow \text{P\&L net}$$

Écart 1 : le **coût des contraintes** — la mesure en euros du transfert coefficient de §4.2.3, ventilable contrainte par contrainte via les duals (§4.2.2). Écart 2 : le délai et le rythme (la trajectoire d'AC vs l'exécution instantanée fictive, §5.3). Écart 3 : la tactique (limit/market, venues — les mark-outs de §5.4.3 agrégés). Écart 4 : frais, financement, emprunt de titres. La télescopie est la même que le monitoring live-vs-attendu de §6.3 — c'est un seul système de mesure à deux fréquences. Deux lignes exigent un traitement explicite. Le **netting benefit** (§4.3.4) : les coûts réels sont encourus sur les trades *nets*, les P&L de sleeves calculés sur les positions *théoriques* — l'écart est un gain

d'architecture à afficher comme tel, sinon il gonfle silencieusement la performance apparente du dernier sleeve ajouté. Et l'**allocation des coûts entre sleeves** : le coût marginal d'un sleeve dépend des autres (impact concave : le deuxième acheteur du même titre paie plus cher le même trade) — l'allocation propre est la valeur de **Shapley** (moyenne des contributions marginales sur tous les ordres d'arrivée — le même partage que §3.4.3 côté ICIR², les deux faces de la même comptabilité), en pratique approximée par une répartition proportionnelle aux trades bruts avec correction de signe pour les sleeves qui nettoient ; l'enjeu n'est pas cosmétique, c'est l'assiette de l'attribution par chercheur de §3.4.3 et §6.4.

5.5.3 Pièges de mesure — les biais sont tous du même côté

Quatre pathologies dominent, et elles embellissent toutes. Le **biais de sélection des non-exécutés** : les ordres limites non remplis sont précisément ceux dont le prix est parti dans le bon sens — les ignorer, c'est mesurer la tactique passive sur ses seuls succès ; le terme d'opportunité de Perold est la correction, à condition de le *charger* au prix pT réel et pas au dernier prix touché. La **contamination du benchmark** : mesurer vs VWAP un ordre qui fait 20% du volume, c'est se comparer à un prix qu'on a soi-même fabriqué (§5.3.2) — le benchmark doit être exogène (arrival) ou corrigé de sa propre participation. Le **conditionnement à l'alpha** (§5.2.4) : le drift pendant l'exécution mélange coût et signal — la séparation passe par le profil de réversion post-complétion, ou mieux, par la normalisation **pré-trade** : mesurer non pas le coût brut mais la *surprise de coût*, réalisé – prédit par le modèle de §4.3.1 à participation et vol données — ce qui contrôle le conditionnement et transforme chaque ordre en test du modèle. Et le **bruit** : l'écart-type du coût par ordre vaut typiquement 5-10× sa moyenne (le prix diffuse de $\sigma\sqrt{T}$ pendant l'exécution, ordres de grandeur au-dessus de l'impact) ; pour estimer un coût moyen de 10 bps à ± 2 bps avec $\sigma_c \approx 100$ bps, il faut $n \approx (2 \cdot 100/2)^2 = 10\,000$ ordres — la TCA est une discipline de grands échantillons, où trois mois de trades ne prouvent rien et où un outlier (un ordre pendant un flash move) domine la moyenne s'il n'est pas winsorisé (§1.3.1, appliqué à soi-même). S'ajoute le paradoxe de **Simpson** version TCA : agréger des ordres d'urgences différentes fabrique des conclusions inversées (le broker A paraît moins cher parce qu'on lui envoie les ordres faciles) — toute comparaison se fait à buckets de participation, taille relative et urgence appariés, ou via la surprise de coût qui les normalise d'office.

5.5.4 La boucle de retour — la TCA comme organe, pas comme rapport

La sortie de la mesure alimente quatre consommateurs. La **calibration** : Y, δ, c par titre et par régime — les paramètres de §4.3.1 qui fixent bandes, aim portfolio et capacité (§4.4.4) viennent d'ici, et le papier fondateur (Almgren et al. 2005) est littéralement une TCA devenue modèle ; un desk dont l'optimiseur tourne sur des coûts d'il y a deux ans optimise un marché disparu. L'**expérimentation** : l'étalon-or contre tous les biais de §5.5.3 est la **randomisation** — tirer au sort une fraction des ordres entre deux schedulers, deux niveaux d'urgence, deux venues, et mesurer la différence appariée (§5.2.4 ; c'est le seul dispositif qui coupe le conditionnement à la racine, et son coût — trader parfois sous-optimalement — est la prime d'assurance contre des années de calibration fausse). Les **scorecards** : venues et brokers notés aux markouts et aux surprises de coût, à buckets appariés — la matérialisation de la toxicité de §5.1.3, qui pilote le routeur. Et la **recherche** : les résidus de la TCA sont un vivier d'alphas d'exécution (§5.4.2) — un coût systématiquement bas dans une configuration est un signal tactique non exploité. L'unification finale : pré-trade (prédire le coût), intra-trade (pi-loter contre la prédiction, l'adaptatif de §5.3.4) et post-trade (mesurer la surprise) doivent partager **le même modèle** — trois lectures du même objet, et le pipeline de production de §6.3 en fait trois étapes du même flux. Références : Perold 1988 ; Wagner & Edwards (1993) pour l'iceberg ; Kissell, *The Science of Algorithmic Trading and Portfolio Management* (2013) ; Almgren, Thum, Hauptmann & Li (2005) ; Rashkovich & Verma (JPM 2012) sur le bruit et les tailles d'échantillon.

La branche 5 se clôt ici. Le fil à retenir : la TCA n'est pas le dernier maillon mais le *premier du tour suivant* — elle fabrique les paramètres de §4.3, note les venues de §5.1.3, teste les modèles de

§5.2, et arbitre les tactiques de §5.4 ; un desk sans TCA propre pilote à l'estime. Le quintet : Perold (délai + trading + opportunité + frais — quatre propriétaires) ; la cascade des paper portfolios ; le netting benefit et le Shapley des coûts ; $n \approx 10^4$ ordres ; un seul modèle pré/intra/post.

Renvois : §1.3.1 (winsoriser ses propres coûts) ; §2.2.2, §2.2.4 (lag signal→ordre, calibration commune avec le backtest) ; §3.4.3 (Shapley — l'autre face), §4.2.2–§4.2.3 (duals, TC en euros), §4.3.1, §4.3.4 (modèle de coût, netting), §4.4.4 (capacité) ; §5.1.3 (toxicité), §5.2.4 (randomisation, conditionnement), §5.3.2, §5.3.4 (benchmarks, adaptatif), §5.4.2–§5.4.3 (alphas d'exécution, mark-outs) ; §6.3 (un seul flux pré/intra/post), §6.4 (assiette de l'attribution).

Chapter 25

§6.1 Données

État : relu (intégré s.12, harmonisé s.14 — renvois et notation vérifiés) — sources : M130 (référence ✓✓) fusionné avec M104 (première passe détaillée) ; vérification des chiffres à venir.

La branche 6 porte les cinq autres, et c'est là que se prennent les décisions les plus irréversibles — §1.2.4 l'avait annoncé : certaines erreurs d'infrastructure du jour 1 rendent la recherche des années suivantes définitivement impossible à assainir. Son fil : l'infrastructure est *l'épistémologie rendue exécutable*. Ce premier nœud construit le socle — le bitemporel qui implémente Ft, la capture propriétaire, la qualité quantifiée, le build vs buy.

6.1.1 Le bitemporel, avec sa sémantique exacte. Le principe architectural unique, dont tout découle : chaque enregistrement porte **deux axes de temps** — l'*event time* (quand la chose s'est produite) et le *knowledge time* (quand la base l'a su). Le schéma (Snodgrass, *Developing Time-Oriented Database Applications in SQL*, 1999) : chaque ligne porte (event_time **e**, knowledge_time **k**, kfin) — kfin étant le knowledge_time de la version qui la remplace ($+\infty$ pour la version courante). La requête « telle que la base était en t », qui *implémente* la filtration Ft du §0.2 :

AS-OF(t) : { lignes | e ≤ t, k ≤ t < kfin }

— la colonne « connaissable à partir de » du §1.2.4 est knowledge_time. Le test de cohérence fondamental du système : AS-OF(t) exécutée aujourd'hui doit être *invariante* dans le temps — une base **append-only** la garantit par construction (l'architecture en log immuable de Kleppmann, *Designing Data-Intensive Applications*, 2017) : on n'écrase jamais, on ajoute des versions ; une correction de vendeur, un restatement, une republication de chandelle deviennent des lignes nouvelles, et les vintages du §1.2.4 sont gratuits par construction — toute mutation en place casse l'invariance silencieusement.

6.1.2 La capture propriétaire. Pour tout flux que le fournisseur réécrit (chandelles crypto, consensus d'analystes, on-chain re-clusterisé — le catalogue de §1.2.4), enregistrer soi-même à la réception, horodaté à la réception — le coût est du stockage trivial, le bénéfice est l'impossibilité du look-ahead de révision. C'est la seule défense contre les vintages perdus, qui ne se reconstituent pas.

6.1.3 La qualité, quantifiée. La qualité est un système de production, pas une vertu — et elle se mesure avec les outils qu'on possède déjà, retournés vers les données elles-mêmes. **Fraîcheur** : pour chaque flux f, le retard $df, t = \text{now} - \max(k)$ comparé à sa distribution historique, alerte si $z(d) > 3$. **Cohérence** : prix cross-venues dans une bande $|pv/pmédian - 1| < \text{seuil}(\sigma)$, volumes en z-score contre leur EWMA (§1.2.2), complétude par comptages attendus par univers. **Intégrité statistique** : les tests anti-wash-trading de §2.2.5 (Benford sur premiers chiffres — fréquence attendue $\log_{10}(1+1/d)$ —, sur-représentation des tailles rondes) appliqués en *continu* comme contrôle qualité, pas seulement en nettoyage initial. Et la **quarantaine** est un état du pipeline, pas une opinion : une ligne qui échoue un contrôle porte un flag qui la rend invisible aux AS-OF de production jusqu'à arbitrage — car un faux prix qui traverse le pipeline devient un faux signal devient un vrai trade.

6.1.4 Build vs buy. Le critère : acheter ce qui est commodité vérifiable (prix equity consolidés, référentiels), construire ce qui est soit l'edge (les features), soit non-vérifiable chez le vendeur — tout ce qui exige le point-in-time. Vérifier les prétentions PIT d'un vendeur est en soi un projet, avec son test : comparer ses « vintages » livrés à vos propres captures archivées — l'écart est son **taux de réécriture**, et il se chiffre avant de signer.

Le fil du nœud : $AS-OF(t) = Ft$ exécutable, invariance testable, qualité en z-scores, quarantaine comme état. Ce socle rend possibles la reproduction à date (§1.2.4, §6.2) et la parité backtest/production (§6.2) ; sans lui, le reste de la branche est de la décoration.

Renvois : §0.2 (Ft) ; §1.2.2 (EWMA), §1.2.4 (PIT, vintages, capture — le catalogue des pièges), §1.3.1 (les z-scores retournés vers les données) ; §2.2.5 (Benford, wash trading) ; §5.1.3 (consolidation des feeds fragmentés) ; §6.2 (reproduction à date, parité).

Chapter 26

§6.2 Moteur de backtest

État : relu (intégré s.12, harmonisé s.14 — renvois et notation vérifiés) — sources : M130 (référence ✓✓) fusionné avec M104 ; vérification des chiffres à venir.

Le moteur de backtest est l'instrument de mesure du desk — et ce nœud établit ce qui le certifie : la parité avec la production (un seul artefact), le replay quotidien, le placebo étalonné comme test de non-régression, et le registre qui rend calculables les statistiques de la branche 2 (N effectif, holdout scellé).

6.2.1 Deux architectures, deux usages. Le moteur **vectorisé** opère sur le panel entier en algèbre matricielle — positions = $f(\text{signaux décalés})$, P&L = $\Sigma \text{positions} \cdot \text{rendements} - \text{coûts}$ — rapide de plusieurs ordres de grandeur, l'outil de l'itération de recherche (§2.2), mais aveugle à tout ce qui est intra-période : remplissages partiels, ordres limites, latence, marges. Le moteur **event-driven** rejoue le temps événement par événement à travers la *même* machine à états que la production (ordre → routage → fill → position) — lent, fidèle, obligatoire dès que la stratégie dépend du chemin (branche 5, tout ce qui touche l'exécution). La règle de partage : vectorisé pour chercher, event-driven pour valider avant promotion — et les deux doivent coïncider sur leur intersection, ce qui est un test en soi.

6.2.2 La parité, certifiée par le replay. Le théorème central du nœud : le calcul du signal doit être **le même code** dans les deux mondes — une seule implémentation, appelée par le backtest sur données historiques et par la production sur données du jour. Toute réimplémentation (« le chercheur prototype en notebook, l'ingénieur réécrit pour la prod ») fabrique des divergences silencieuses que seul le P&L révélera, trop tard. La propriété testable : $\text{signal_backtest}(t, \text{AS-OF}(t)) \equiv \text{signal_prod}(t)$ au bit près, vérifiée en continu sur la fenêtre récente — le **replay quotidien** : rejouer hier avec le snapshot d'hier, comparer à ce que la prod a réellement calculé ; l'écart est un bug *ou* une donnée réécrite, et §6.1 dit lequel. C'est la reproduction à date de §1.2.4, rendue exécutable par le bitemporel.

6.2.3 Le placebo étalonné. Le placebo de §2.2.5, promu en certification chiffrée du protocole : sur M signaux aléatoires passés dans le pipeline complet,

$$\text{IC}_{\text{placebo}} \approx 0 \pm 1/\sqrt{(\text{Neff}-1)} \text{ (§2.1.1), } \text{Sharpenet, placebo} \approx -\text{coûts} \times \text{turnover}$$

— tout excès mesure la fuite résiduelle du protocole *en unités d'IC* ; c'est l'étalonnage empirique du plancher de §2.1.1 et le test de non-régression qu'on relance à chaque modification du moteur. Un moteur dont le placebo dérive est un moteur qui vient de gagner un look-ahead.

6.2.4 Le registre et le holdout administré. Chaque essai lancé est loggé — hypothèse pré-datée (§2.3.5), config, hash des données AS-OF, résultat, succès *et* échecs — car N est un paramètre du deflated Sharpe (§2.3.2) et le N effectif se calcule sur les trajectoires archivées :

$$\text{Neff} \approx 1 + (\text{N}-1) \cdot (1-\bar{\rho}), \bar{\rho} = \text{corrélation moyenne des trajectoires de P\&L des essais de la famille}$$

— incalculable sans le registre, ce qui fait de lui la pièce maîtresse de l'appareil anti-overfitting (le PBO exige la matrice complète des essais, §2.3.3 ; le FDR par famille exige le comptage, §2.3.4). L'archive des *negatifs* est la moitié de la valeur : ne pas re-tester ce qui a échoué, et pouvoir calculer le N de famille (§1.2.3). Et le **holdout administré** : données scellées par hash, ouverture unique et journalisée, sur la version finale seulement — la traduction système du théorème de Dwork (§2.3.5 : chaque requête adaptative consomme la validité en $\sqrt{(\text{nombre de requêtes})}$; l'administration rend le compteur *matériel*). L'honnêteté statistique est déléguée à l'infrastructure plutôt qu'à la volonté. Références : López de Prado (AFML — « backtesting is not a research tool », les chapitres protocole) ; Bailey et al. sur le DSR ; Carver, *Systematic Trading* (2015) pour l'architecture praticienne à l'échelle d'un desk compact.

Le quatuor du nœud : un seul artefact + replay quotidien ; le placebo étalonné ($I\bar{C} \approx 0 \pm \text{plancher}$, Sharpe = -coûts) ; registre → trajectoires → Neff ; holdout scellé par hash. Trois des cinq outils de §2.3 vivent matériellement ici — la branche 2 sans ce nœud est une intention.

Renvois : §1.2.3 (N de famille), §1.2.4 (reproduction à date) ; §2.1.1 (plancher), §2.2 (le protocole exécuté), §2.2.5 (placebo), §2.3.2–§2.3.5 (DSR/N, PBO, FDR, Dwork) ; §5.2.4 (logger l'intention — le registre côté exécution) ; §6.1 (AS-OF, l'arbitre du replay), §6.3 (les portes consomment ces certifications), §6.4 (le registre opposable).

Chapter 27

§6.3 Production

État : relu (intégré s.12, harmonisé s.14 — renvois et notation vérifiés) — sources : M130 (référence ✓✓) fusionné avec M104 ; vérification des chiffres à venir.

Le système de production : la promotion et la surveillance — la branche 2 exécutée en continu sur le présent. Quatre étages : le pipeline à portes pré-enregistrées, la surveillance séquentielle aux bons seuils (SPRT, PSI), les kill switches gradués, et la réconciliation qui vérifie le lien au réel.

6.3.1 La promotion à portes. Le passage recherche → production est un pipeline : paper trading (le signal tourne sur données live, ordres fictifs — le test de parité de §6.2 en conditions réelles), puis capital limité, puis taille cible — chaque porte ayant des critères **pré-enregistrés** (durée minimale, IC live dans la bande attendue, coûts dans la bande du modèle de §4.3.1) : décider les seuils *avant* de voir les résultats, sinon la promotion devient le multiple testing de §2.3 rejoué en production. La calibration statistique des attentes est le point technique : avec $\sigma(\text{IC}) \approx 0,15$ (§0.3), six mois de live donnent une erreur type de $0,15/\sqrt{126} \approx 0,013$ sur l'IC — **un signal à IC vrai de 0,03 peut légitimement afficher zéro sur six mois** ; les bandes d'alerte se calculent, elles ne s'improvisent pas, et l'essentiel des « signaux morts » enterrés à trois mois étaient statistiquement indistinguables de vivants (§2.4.1).

6.3.2 La surveillance séquentielle — SPRT et PSI. L'outil propre pour l'IC live est le **SPRT de Wald** (1945) : tester $H_0 : \text{IC} = \text{IC}_{\text{backtest}}$ contre $H_1 : \text{IC} = 0$ par le log-rapport de vraisemblance cumulé,

$$\Delta T = \Sigma t \ln[f_1(\text{IC}_t)/f_0(\text{IC}_t)] = (T/\sigma^2(\text{IC})) \cdot [(\text{IC}_0^2/2) - \text{IC}_0 \cdot \bar{\text{IC}}_T] \text{ (cas gaussien), continuer tant que } \ln(\beta/(1-\alpha)) < \Delta T < \ln((1-\beta)/\alpha)$$

— le test qui *minimise le temps de décision espéré* à erreurs (α, β) données, et dont les bornes disent l'essentiel : avec $\text{IC}_0 = 0,03$ et $\sigma(\text{IC}) = 0,15$, le drift du log-rapport vaut $\pm \text{IC}_0^2/(2\sigma^2) = 0,02$ par jour, et distinguer « vivant » de « mort » à $\alpha = \beta = 10\%$ demande **$E[T] \approx 90\text{-}110$ jours de bourse — quatre à cinq mois** (et ~ 130 jours à 5% d'erreurs ; l'approximation de Wald $E[T] \approx |\ln(\beta/(1-\alpha))|/0,02$) — la quantification du « quelques mois ne prouvent rien », et distinguer deux IC *voisins* plutôt que vivant/mort repousse l'attente au-delà de l'année, et la justification du bucket-avec-hystérésis (§3.1.3) comme décision rationnelle sous test inachevé (encadré E : CUSUM en recherche, SPRT en production, hystérésis en combinaison — trois instances de la même surveillance séquentielle). La dérive de population se mesure au **PSI** (population stability index, l'outil des credit scorers) : pour chaque feature, distribution live q vs référence p sur B buckets,

$$\text{PSI} = \Sigma b (q_b - p_b) \cdot \ln(q_b/p_b) \text{ — seuils praticiens : } < 0,1 \text{ stable, } 0,1\text{-}0,25 \text{ à surveiller, } > 0,25 \text{ drift majeur}$$

— la divergence de Jeffreys entre hier et aujourd'hui, feature par feature : **le signal peut mourir par ses entrées avant de mourir par son IC**, et le PSI le voit des mois plus tôt. La surveillance continue est la cascade de §5.5.2 tournée vers l'avant : live vs attendu à chaque étage — positions

réelles vs théoriques (écart = bug ou contrainte nouvelle), P&L réel vs simulé (écart = implémentation), coûts réalisés vs prédits (écart = recalibrer §4.3.1), distributions des features (le PSI) — chaque écart ayant son seuil et son propriétaire (§4.5.3).

6.3.3 Les kill switches gradués. Trois étages par gravité : sanity checks par ordre (taille, prix, notionnel max — la défense contre le fat finger et le bug de boucle), limites par stratégie (drawdown, §4.4.3, en automatique), et book-level avec modes de **dégradation contrôlée** — réduire le gross, geler les ouvertures, aplatir — car « tout couper » est lui-même un trade énorme (§4.4.1 : la sortie coûte de l'impact, et la procyclicité de §4.5.2 fait que tout le monde sort en même temps) : la bonne panique est graduée, comme tout ce que l'encadré E enseigne.

6.3.4 Réconciliation et tableau de bord. La réconciliation clôt la journée : positions et cash vs broker/custodian, **ligne à ligne, tous les jours** — l'identité comptable vérifiée contre le monde extérieur : $\text{Position}_{\text{t}} = \text{Position}_{\text{t-1}} + \text{fill}_{\text{t}}$ (vs broker), $\text{P\&Lt} = \sum w \cdot r - \text{coûts}$ (vs custodian). En crypto, multipliée par venue, avec les soldes on-chain comme arbitre et les procédures de retrait testées *avant* d'en avoir besoin (§4.5.4 : la gestion du risque de contrepartie est un runbook, pas une opinion). Et le tableau de bord agrège tout ce que l'arbre a produit comme instruments : **IC live avec bandes SPRT, PSI par feature, comomentum par sleeve (§2.4.2), bias statistic du modèle de risque (§4.1.1), surprises de coût (§5.5.3), turnover des poids (§3.2.4)**. La surveillance n'est pas une liste de chiffres : c'est la branche 2 en continu.

Le quatuor du nœud : portes pré-enregistrées (e.t. $\approx 0,013$ à six mois) ; SPRT ($E[T]$ en centaines de jours — détecter coûte du délai) ; PSI (le signal meurt par ses entrées d'abord) ; dégradation contrôlée et réconciliation ligne à ligne. Le tableau de bord est le point de convergence de six nœuds de l'arbre — la mesure de santé du système entier.

Renvois : §0.3 ($\sigma(\text{IC})$) ; §2.3 (le multiple testing qu'on ne rejoue pas), §2.3.5 (bandes du live — l'OOS incontaminable), §2.4.1–§2.4.2 (CUSUM, comomentum) ; §3.1.3 (hystérésis), §3.2.4 (turnover de w), §3.4.2 (ancienneté validée en live) ; §4.1.1 (bias statistic), §4.3.1 (coûts prédits), §4.4.1, §4.4.3 (sortie coûteuse, paliers), §4.5.2–§4.5.4 (procyclicité, propriétaires, runbook crypto) ; §5.3.3 (le ticket avec urgence), §5.5.2–§5.5.4 (cascade, surprises de coût, un seul flux) ; §6.2 (parité, certifications) ; encadré E (surveillance séquentielle).

Chapter 28

§6.4 Organisation

État : relu (intégré s.12, harmonisé s.14 — renvois et notation vérifiés) — sources : M130 (référence ✓✓) fusionné avec M104 ; vérification des chiffres à venir.

Dernier nœud de l'arbre : le problème de combinaison, à l'échelle humaine — les incitations écrites comme des contrats. Quatre étages : le problème principal-agent et ses exploits, le contrat robuste (Shapley déflaté, différé sur le live), l'arbitrage usine vs pods rendu opérationnel, et la mémoire du desk qui referme l'arbre sur lui-même.

6.4.1 Le principal-agent — chaque f naïve a son exploit. Le problème, formalisé a minima : un chercheur rémunéré $R = f(\text{performance mesurée})$ optimise f , pas la performance vraie — et chaque f naïve a son exploit documenté par l'arbre lui-même. **f(Sharpe backtest)** $\Rightarrow$ maximiser N jusqu'au Sharpe demandé ($E[\max_N \hat{S}R] \approx \sqrt{(2 \ln N)}$, §2.3.2 — l'overfitting est la *réponse rationnelle* au contrat, pas une faute morale). **f(Sharpe standalone live)** $\Rightarrow$ répliquer le pool (le mérite corrélé compté K fois, §3.4.3). **f(P&L attribué)** $\Rightarrow$ importer tous les biais d'attribution de §5.5.2 (benchmark contaminé, netting invisible, Simpson).

6.4.2 Le contrat robuste. Il combine les correctifs déjà construits par l'arbre. **L'assiette** : la contribution marginale — Shapley (§3.4.3), ou $p \perp$ (§3.4.1) en approximation — avec les coûts alloués au Shapley également (§5.5.2), pas le standalone. La **déflation** : l'assiette est déflatée du N du registre (§6.2) — le DSR *dans* la formule de bonus : le chercheur paie ses propres essais, ce qui rend le registre opposable et l'exploration budgétée (§2.3.5). Le **différé** : $R_t = \text{part immédiate} + \text{part indexée sur les années live suivantes}$ — l'alignement de l'horizon du chercheur sur la demi-vie réelle de ses signaux (§2.1.2), qui rend l'overfitting non rentable *en espérance* : c'est la version incitative du fractional Kelly — réduire la part payée sur l'estimé, proportionnellement à son incertitude (encadré B, troisième échelle : après la position et le book, l'organisation). Les contre-mesures institutionnelles complètent : le holdout administré centralement et ouvert une fois (§6.2), et le **comité de revue** (§3.1.3, les buckets) comme organe — cadence trimestrielle, dossier pré-daté (hypothèse, essais, DSR, IC marginal, capacité), décision d'admission/bucket/retrait motivée et archivée : la jurisprudence du desk.

6.4.3 Usine vs pods, le critère opérationnel. La bifurcation de §3.4.4 revient avec son vrai visage : l'**usine centralisée** (un book, un modèle de risque, des chercheurs qui soumettent au pool commun — la tradition stat arb) est l'optimum théorique — netting complet (§4.3.4), diversification au niveau des forecasts, un seul passage de coûts — qui paie en attribution floue et en incitations diluées ; les **pods** sont le $1/N$ organisationnel (§3.1.1) — sous-optimal sur le papier, robuste à l'erreur d'estimation *sur les humains* : un pod toxique est isolé et coupé à ses limites (§4.4.3 appliqué aux personnes), ses positions ne contaminent pas le book. Le critère rendu opérationnel : l'usine exige que la chaîne de mesure — **registre** $\rightarrow$ **Neff** $\rightarrow$ $p \perp$ $\rightarrow$ **Shapley** $\rightarrow$ **différé** — soit *auditable de bout en bout* ; c'est une exigence d'infrastructure, pas de culture. Les pods sont ce qu'on choisit quand on ne peut pas la construire — exactement comme le $1/N$ statistique gagne quand C est inestimable. Les coûts du modèle pods se surveillent avec les outils de l'arbre : crowding intra-firme (le comomentum de §2.4.2 entre pods), limites factorielles firm-wide (§4.5.3), netting central partiel.

6.4.4 La mémoire du desk. Le dernier actif, qui referme l'arbre sur lui-même. L'archive des résultats **négatifs** — la moitié de la valeur du registre : ne pas re-tester ce qui a échoué, et pouvoir calculer le N de famille (§1.2.3, §2.3.4). La **documentation par signal vivant** : le quintuple de l'interface $(s, \rho, \sigma(\text{IC}), \varphi, \tau)$ — §3.4.5 *plus* le mécanisme de persistance (§1.1, §2.4.3) et le comportement attendu par régime — c'est-à-dire exactement ce qu'il faut pour qu'un autre que l'auteur décide en crise, et pour que le comité juge sur pièces. Et la **revue de code** comme contrôle de parité (§6.2) autant que de qualité. Références : Tulchinsky (éd.), *Finding Alphas* (2015) pour le modèle usine vu de l'intérieur ; Isichenko, chapitres organisationnels ; Grinold & Kahn sur la structure du processus actif ; pour la couche incitations, la littérature principal-agent appliquée — l'essentiel de ce nœud est du savoir praticien dont les références sont les post-mortems.

L'arbre se ferme ici. Le fil de la branche 6, et de l'ouvrage : l'infrastructure est l'épistémologie rendue exécutable — le bitemporel implémente Ft (§6.1), le registre implémente le N du DSR (§6.2), la parité implémente la validité du backtest (§6.2), le SPRT et le PSI implémentent la surveillance (§6.3), le contrat implémente l'honnêteté (§6.4) ; un desk n'est honnête que si ses systèmes le sont à sa place. Le quatuor du nœud : $f(\text{backtest}) \Rightarrow \max N$ (l'exploit rationnel) ; le contrat Shapley-déflaté-différé (le fractional Kelly incitatif) ; usine $\Leftrightarrow$ chaîne de mesure auditable ; la doc par signal comme condition de décision en crise.

Renvois : §1.1 (mécanismes), §1.2.3 (N de famille) ; §2.1.2 (demi-vie des signaux — l'horizon du différé), §2.3.2, §2.3.4–§2.3.5 ($E[\max N]$, FDR, holdout), §2.4.2–§2.4.3 (comomentum intra-firme, persistance) ; §3.1.1 ($1/N$), §3.1.3 (comité, buckets), §3.4.1, §3.4.3–§3.4.5 ($\rho \perp$, Shapley, pods, interface) ; §4.3.4 (netting), §4.4.3 (limites), §4.5.3 (limites firm-wide) ; §5.5.2 (biais d'attribution, Shapley des coûts) ; §6.2 (registre, holdout, parité), §6.3 (le live qui paie le différé) ; encadré B (troisième échelle).

Part IV

Encadrés transversaux

Chapter 29

Encadré A — Le shrinkage, un théorème sous huit habits

État : relu (intégré s.13, harmonisé s.14 — renvois et notation vérifiés) — synthèse transversale ; sources dans les sections citées ; vérification des chiffres à venir.

Un seul théorème traverse cet ouvrage plus souvent qu'aucun autre, et il mérite d'être énoncé une fois pour toutes : **quand on estime simultanément plusieurs quantités bruitées, l'estimateur qui tire chaque estimée vers une cible commune domine l'estimateur naïf composante par composante** — et l'ampleur du tirage optimal est proportionnelle au rapport bruit d'estimation / dispersion vraie. C'est le résultat de James-Stein (1961) : en dimension $K \geq 3$, le shrinkage vers la moyenne commune domine le MLE *quel que soit* le vrai vecteur de paramètres. Ce qui rend le théorème structurant pour la recherche d'alphas, c'est que le régime de travail du praticien — beaucoup de quantités voisines, peu d'historique stationnaire, bruit dominant (§0.3, §3.1.2) — est précisément celui où la domination est la plus large. L'ouvrage le rencontre sous huit habits.

Premier habit — James-Stein sur les IC (§3.1.3a). Le pool d'alphas est un modèle hiérarchique : $\theta_k \sim N(m, \tau^2)$, observé avec bruit sk^2 , posterior $E[\theta_k | \hat{I}Ck] = m + (\hat{I}Ck - m) \cdot \tau^2 / (\tau^2 + sk^2)$. Le facteur $B = s^2 / (\tau^2 + s^2)$ — la fraction de l'écart mesuré qu'on jette — vaut $\approx 0,5$ pour un an de données : la moitié de ce qui distingue un signal de la moyenne du pool est du bruit. L'empirical Bayes rend le geste opérationnel : le pool fournit m et τ .

Deuxième habit — Vasecek sur les betas (§4.1.4 ; déjà dans la définition du BAB, §1.1.1). $\beta_i = w\beta \cdot \hat{\beta}_i + (1-w\beta) \cdot \bar{\beta}_{\text{groupe}}$, $w\beta = \tau^2\beta / (\tau^2\beta + s^2i)$ — la même formule exactement, appliquée aux expositions ; obligatoire en crypto où les fenêtres courtes rendent les $\hat{\beta}$ très bruités, et présente jusque dans la construction du facteur betting-against-beta ($\beta = 0,6\hat{\beta} + 0,4$).

Troisième habit — Ledoit-Wolf sur les matrices (§4.1.3, transposé aux signaux en §3.2.2). $\tilde{\Sigma} = \delta^* \cdot T_0 + (1-\delta^*) \cdot S$, avec $\delta^* = \text{bruit/distance-à-la-cible en forme close}$ — le posterior hiérarchique devenu matriciel ; et le choix de la cible (identité, corrélation constante, blocs par famille) est le choix du prior.

Quatrième habit — la ridge spectrale (§3.2.1). $w(\kappa) \propto (C + \tilde{\kappa}I)^{-1}\rho$ multiplie chaque direction propre par $\lambda_j / (\lambda_j + \tilde{\kappa})$: les contrastes bien estimés passent, les directions bruitées sont écrasées — le MAP du prior $w \sim N(0, \tau^2I)$, avec $\kappa = \sigma^2e / \tau^2$. Le κ élevé qu'on trouve par CV est la *mesure* de la domination du bruit ; et le clipping RMT de §4.1.2 en est le cousin par seuillage.

Cinquième habit — NNLS-Breiman (§3.2.3, §3.3.1). Les contraintes de non-négativité sur les poids de combinaison (et de stacking) sont un prior dur : un signal dont la contribution partielle est négative reçoit zéro, jamais un poids inversé — c'est ce qui fait « marcher » le stacking (Breiman 1996), et c'est un shrinkage implicite des corrélations qui justifiaient les poids négatifs.

Sixième habit — les contraintes de Jagannathan-Ma (§4.2.2). Le théorème rend le lien exact : le minimum-variance sous bornes équivaut au minimum-variance non contraint sur $\tilde{\Sigma} = \Sigma - (\delta 1' + 1\delta') + (v1' + 1v')$ — interdire une position extrême, c'est réduire les covariances qui la justifiaient. Les

contraintes « fausses » améliorent l'out-of-sample parce qu'elles régularisent $\hat{\Sigma}$ là où il est le plus bruité.

Septième habit — l'optimisation robuste (§4.2.4). $\max_w \min_{\alpha \in U} w' \hat{\alpha} - \kappa r \cdot \|w\|_{\Omega} - (\gamma/2) w' \Sigma w$: le pire cas sur un ellipsoïde d'incertitude *est* une pénalité de régularisation — choisir la taille de l'ensemble d'incertitude, c'est choisir un shrinkage.

Huitième habit — le différenciel incitatif (§6.4). Le contrat qui paie le chercheur sur une assiette déflatée du N et différée sur le live réduit la part payée sur l'estimé proportionnellement à son incertitude — le shrinkage appliqué non plus aux paramètres mais aux *personnes* ; le fractional Kelly incitatif (encadré B).

La leçon commune, qui explique pourquoi l'arbre y revient sans cesse : dans un monde où le bruit d'estimation domine la dispersion vraie, presque toutes les « sophistications » qui fonctionnent — bayésien, régularisation, contraintes, robustesse, quantification en buckets (§3.1.3c), gouvernance — sont des paramétrages différents du même geste. Savoir le reconnaître évite de l'empiler en double (§3.2.2 : on ne cumule pas ridge et shrinkage-de-C à pleine dose) et donne le bon réflexe face à toute méthode nouvelle : demander d'abord *vers quoi elle shrinke, et à quel taux*.

Renvois : §1.1.1 ; §3.1.2–§3.1.4 ; §3.2.1–§3.2.3 ; §3.3.1 ; §4.1.2–§4.1.4 ; §4.2.2, §4.2.4 ; §6.4 ; encadré B.

Chapter 30

Encadré B — Croissance & survie

État : relu (intégré s.13, harmonisé s.14 — renvois et notation vérifiés) — synthèse transversale ; sources dans les sections citées ; vérification des chiffres à venir.

Trois échelles — la position, le book, l'organisation — et une seule réponse : **réduire l'exposition à l'estimé proportionnellement à son incertitude**. Cet encadré rassemble les résultats de croissance et de ruine que l'ouvrage mobilise, et montre qu'ils forment un seul argument.

Le socle : la parabole de Kelly (§4.4.2). Pour un flux de Sharpe SR, le taux de croissance sous fraction cK du levier log-optimal $f^* = \Sigma^{-1}\mu$ vaut $g(cK) = r + (cK - cK^2/2) \cdot SR^2$. La parabole dit trois choses. À $cK = 1/2$, on capture 75% de la croissance excédentaire avec la moitié du risque — l'optimum est *plat* à gauche. Au-delà de $cK = 1$, l'asymétrie est brutale : à $cK = 2$ la croissance excédentaire est nulle avec un risque doublé. Et la distribution des drawdowns rend le choix tangible : **$P(DD \geq x) = (1-x)(2/c_K-1)$** — perdre la moitié du capital a probabilité $1/2$ au plein Kelly, 12,5% au demi, $\sim 3\%$ au tiers. « Demi-Kelly » n'est pas une timidité : c'est la lecture conjointe de la platitude à gauche et de la falaise à droite.

Pourquoi encore moins que le demi : l'incertitude paramétrique (§3.1.3, §4.4.2). Kelly est log-optimal sous paramètres *connus* ; sous μ estimé, la croissance espérée du plug-in est amputée d'un terme en $\text{Var}(\hat{\mu})$, et la correction cohérente — Kelly sur le posterior shrinké — équivaut à une fraction supplémentaire. Le shrinkage des IC (encadré A) et le fractional Kelly sont le même geste vu de deux endroits : l'un réduit l'estimée, l'autre réduit l'exposition à l'estimée. S'ajoutent les raisons hors modèle — queues épaisses, ruptures de régime (§2.4), la variance de la variance — qui poussent toutes dans la même direction : sous l'incertitude, on se place systématiquement *en dessous* de l'optimum calculé, parce que l'erreur par excès coûte plus que l'erreur par défaut.

Le plancher explicite : Grossman-Zhou (§4.4.3). Maximiser la croissance sous la contrainte $W_t \geq \alpha \cdot M_t$ donne un CPPI sur le coussin : exposition $\propto (W_t - \alpha \cdot M_t)/W_t$ — l'exposition tend vers zéro à l'approche du plancher. C'est la réponse au scénario que le vol targeting (§4.4.1) rate : la glissade régulière à vol basse. Le verdict de Kaminski-Lo sur les stop-loss complète : sous i.i.d. ils détruisent de l'espérance, sous momentum ils en ajoutent — mais leur justification résiduelle est *structurelle* : un book qui perd son capital a une espérance nulle quelle que soit celle de ses signaux. La survie n'est pas un raffinement de l'optimisation : elle en est la condition de possibilité — le taux de croissance ne se compose que pour ceux qui restent à la table.

La troisième échelle : le contrat différé (§6.4). Le desk lui-même est une position sur des estimées — les Sharpe backtestés de ses chercheurs — et le contrat robuste applique la même logique : assiette marginale (Shapley, §3.4.3), **déflatée du N** du registre, **différée sur le live**. La part payée immédiatement sur l'estimé est réduite proportionnellement à son incertitude ; le solde n'est versé que quand le live a transformé l'estimé en réalisé. C'est le fractional Kelly incitatif — et il ferme la boucle : l'organisation qui sur-paie ses backtests fait faillite par le même mécanisme que le book qui sur-lève ses estimées, la sur-exposition à des paramètres bruités.

La leçon commune : position (posterior shrinké, fraction de Kelly), book (vol target plafonné,

plancher de drawdown), organisation (différé) — trois étages du même théorème. Et son corollaire pratique, qui traverse l'ouvrage : face à un chiffre estimé, la question n'est jamais seulement « combien » mais « avec quelle incertitude » — et la taille de la position, du book ou du bonus doit décroître avec la seconde, pas seulement croître avec le premier.

Renvois : §2.4 (ruptures) ; §3.1.3 (posterior, sleeves vol-égalisés) ; §3.4.3 (Shapley) ; §4.4.1–§4.4.3 (vol targeting, Kelly, Grossman-Zhou, Kaminski-Lo) ; §6.4 (le contrat) ; encadré A (le shrinkage).

Chapter 31

Encadré C — La sélection adverse, quatre technologies

État : relu (intégré s.13, harmonisé s.14 — renvois et notation vérifiés) — synthèse transversale ; sources dans les sections citées ; vérification des chiffres à venir.

Le spread est un prix d'assurance contre l'information. Quiconque affiche un prix ferme — teneur de marché, ordre limite au repos, pool de liquidité — vend une option gratuite à quiconque en sait plus que lui : la contrepartie ne l'exerce que quand le prix affiché est faux. Le spread est la prime que le vendeur d'immédiateté facture à tous pour couvrir ce qu'il perd contre les informés. Cet encadré suit le théorème à travers quatre technologies de marché — il se théorise, se mesure, se tarife, et se réécrit pour les courbes.

Théorisé : Glosten-Milgrom (§5.1.1). Le teneur de marché efficient cote $\text{ask} = E[v \mid \text{le prochain trade est un achat}]$, $\text{bid} = E[v \mid \text{vente}]$: le spread *est* la révision bayésienne conditionnelle au sens du trade — la prime de sélection adverse en forme pure. Il croît avec la probabilité d'information dans le flux, et le marché ferme quand elle est trop haute. La décomposition empirique de Huang-Stoll (traitement / sélection adverse / inventaire) en donne la comptabilité ; le λ de Kyle (§5.2.1) en est la version en pente d'impact — l'information par unité de flux.

Mesuré : les markouts (§5.4.3). $M(\tau_m) = \varepsilon \cdot (\text{mid} + \tau_m - p)$ — le P&L marked-to-mid d'une exécution après τ_m . La décomposition opérationnelle en découle : spread effectif = spread réalisé (ce que le passif gagne vraiment) + sélection adverse (ce que le mouvement post-trade lui reprend). C'est l'instrument universel : il note la toxicité des venues (§5.1.3), la qualité des positions de file (§5.4.1 — tête de file remplie sur flux normal, fond de file sur balayages), et l'écart entre deux tactiques. Un profil $M(\tau_m)$ négatif et croissant en $|\tau_m|$ signe un flux contre lequel on ne devrait pas coter.

Tarifié : Avellaneda-Stoikov (§5.4.4). Le maker rationnel ne subit pas l'AS, il la met en équation : prix de réservation $r_t = s_t - \gamma \sigma^2 (T - t)$ décalé contre son inventaire, spread optimal $\gamma \sigma^2 (T - t) + (2/\gamma) \cdot \ln(1 + \gamma/k)$ — la prime de risque d'inventaire plus l'arbitrage fréquence/marge. La descendance GLFT en donne la forme codable (cotes stationnaires par niveau d'inventaire), et l'ajout des signaux (coter *avec* l'OFI dans la dérive) referme la boucle : la meilleure défense contre l'information est d'en avoir. La limite est un théorème d'équilibre (§5.4.3) : l'AS ne s'élimine pas, elle se tarife — un passif parfaitement défendu ne remplit plus rien ; l'optimum est un niveau d'AS assumé et payé en connaissance.

Réécrit pour les courbes : le LVR (§5.1.4). Le LP d'un AMM à produit constant cote une courbe de prix *figée* entre deux mises à jour du monde : les arbitragistes qui le réalignent sur le prix externe ne tradent contre lui que quand sa courbe est fausse — un flux informé par construction. Le loss-versus-rebalancing $\approx \sigma^2/8$ par unité de temps est la sélection adverse de Glosten-Milgrom réécrite pour la liquidité algorithmique : même théorème, sans teneur de marché humain, sans carnet, sans même un spread apparent — la preuve que l'objet est structurel et non institutionnel.

La leçon commune : partout où un prix ferme rencontre un flux, l'information se fait payer — et les quatre technologies ne diffèrent que par *qui* mesure et *comment* on se défend. Pour le desk

systématique, la conséquence est double : côté coûts, toute exécution passive doit être évaluée nette d'AS (le spread « gagné » est brut, §5.4.1) ; côté signaux, la rémunération de la fourniture de liquidité est elle-même un alpha (le reversal de §1.1.1, la loi de Nagel — proportionnelle au prix du risque de la porter) — les deux faces du même flux, selon le côté du carnet où l'on se trouve.

Renvois : §1.1.1 (Nagel — la version alpha) ; §5.1.1 (Glosten-Milgrom, Huang-Stoll), §5.1.3–§5.1.4 (toxicité, LVR) ; §5.2.1 (Kyle) ; §5.4.1, §5.4.3–§5.4.4 (file, markouts, Avellaneda-Stoikov).

Chapter 32

Encadré D — Le chevauchement & Newey-West

État : relu (intégré s.13, harmonisé s.14 — renvois et notation vérifiés) — synthèse transversale ; sources dans les sections citées ; vérification des chiffres à venir.

Un péché, cinq pénitences. Le péché est toujours le même : traiter comme indépendantes des observations qui partagent de l'information. Dès que l'horizon de prédiction h dépasse la fréquence d'échantillonnage, les labels consécutifs se recouvrent — yt et $yt+1$ partagent $h-1$ périodes, la série a une structure **MA(h-1)** — et toute statistique qui divise par $\sqrt{T}$ ment : elle compte T observations là où il n'y en a effectivement que $\approx T/h$. Dix ans de labels mensuels chevauchants échantillonnés quotidiennement font ~ 120 points indépendants, pas 2 500 — le chiffre qui calibre toutes les ambitions de la branche 2. L'ouvrage rencontre le péché cinq fois, et le corrige cinq fois avec le même outil ou son équivalent.

La correction canonique est l'estimateur de **Newey-West** (1987) : remplacer la variance naïve de la moyenne par la variance de long terme, en sommant les autocovariances pondérées par le noyau de Bartlett,

$$\text{VarNW} = \Gamma_0 + \sum_{l=1}^L (1 - l/(L+1)) \cdot (\Gamma_l + \Gamma'_l), \text{ avec } L \geq h$$

— consistante sous hétéroscédasticité et autocorrélation (HAC). L'alternative non paramétrique est le block bootstrap à blocs plus longs que h . Les cinq apparitions :

1. Les labels d'entraînement (§1.4.2, §1.4.4). La structure **MA(h-1)** du y impose l'inférence corrigée — et côté ML, la pondération d'*unicité* (chaque observation pèse $1/\text{nombre de labels vivants qui la partagent}$) : sans elle, un modèle sur labels chevauchants sur-apprend les épisodes longs, qui votent h fois.

2. Fama-MacBeth (§2.2.1). La régression par date gère la corrélation *cross-sectionnelle* des erreurs (chaque date fournit une observation de yt) mais pas leur corrélation temporelle : dès que $h > 1$, le t -stat de $\bar{y}_1$ exige NW avec $\text{lag} \geq h$ — le partage établi par Petersen (2009).

3. La série des IC (§2.1.1, §3.1.3d). Les IC quotidiens à horizon h partagent des rendements : l'erreur type naïve $\hat{\sigma}(\text{IC})/\sqrt{T}$ sous-estime la vraie d'un facteur $\approx \sqrt{h}$ — un signal à $h = 21$ voit son t -stat surestimé d'un facteur 4-5, de quoi transformer du bruit en « signal validé ». NW sur la série des IC, ou blocs $> h$ — et le dénominateur de l'ICIR hérite du même soin.

4. Le modèle de risque (§4.1.3). La covariance à h jours n'est pas h fois la covariance quotidienne dès que les rendements factoriels sont autocorrélés (momentum factoriel, liquidité) : $F(h) \approx h \cdot [\Gamma_0 + \sum_{l=1}^L (1 - l/(L+1)) \cdot (\Gamma_l + \Gamma'_l)]$ — NW appliqué à une matrice, documenté dans les handbooks Barra/USE4.

5. Le protocole de validation (§2.3.1). Le purging — retirer du train toute observation dont l'intervalle de label chevauche le bloc de test — et l'embargo — la bande qui suit le test, contre la fuite par les features sériellement corrélées — sont la traduction du même théorème en *protocole* :

là où NW corrige l'inférence après coup, le purging empêche la contamination avant. C'est la version chirurgicale ; NW est la version comptable.

La leçon commune, et le réflexe qu'elle fonde : devant tout t-stat, toute erreur type, toute « significativité » calculée sur des données à horizon $h > 1$, la première question est *le chevauchement a-t-il été payé ?* — par NW, par blocs, par unicité, par purge, ou par sous-échantillonnage assumé. Un pipeline qui le paie partout sauf à un étage a un étage qui fabrique des faux positifs — et c'est typiquement celui qu'on n'a pas listé ici.

Renvois : §1.4.2, §1.4.4 (labels, unicité) ; §2.1.1 (IC), §2.2.1 (Fama-MacBeth, Petersen), §2.3.1 (purge/embargo) ; §3.1.3 ($\sigma(\text{IC})$) ; §4.1.3 (F du modèle de risque).

Chapter 33

Encadré E — La surveillance séquentielle

État : relu (intégré s.13, harmonisé s.14 — renvois et notation vérifiés) — synthèse transversale ; sources dans les sections citées ; vérification des chiffres à venir.

Détecter coûte du délai ; la réponse rationnelle est graduelle, jamais binaire. Le problème que cet encadré traverse est celui de tout système qui surveille des quantités bruitées en temps réel : décider *au fil de l'eau* si un paramètre a changé — un IC qui meurt, un régime qui bascule, une feature qui dérive — sans le luxe de l'échantillon complet. La statistique séquentielle donne les outils optimaux, et une leçon quantitative uniforme : avec le bruit des marchés ($\sigma(\text{IC}) \approx 0,15$ pour un IC de 0,03, §0.3), même le test *optimal* met des mois à conclure. Toute architecture qui prétend décider vite décide au hasard ; toute architecture qui attend la certitude décide trop tard — d'où la gradualité, partout.

La détection : le CUSUM de Page (§2.4.1). $St = \max(0, St-1 + (\mu_0 - \text{IC}_t - kc))$, alerte si $St > hc$ — l'accumulateur d'écarts sous la référence, dont le réglage (kc, hc) arbitre explicitement le délai de détection contre le taux de fausses alertes via l'ARL (average run length). C'est l'outil de la *recherche* qui surveille ses signaux : il dit « quelque chose a probablement changé », des mois avant qu'un test à fenêtre fixe ne le confirme — et des mois après le changement lui-même.

La décision : le SPRT de Wald (§6.3.2). Le test séquentiel du rapport de vraisemblance — continuer tant que $\ln(\beta/(1-\alpha)) < \Delta T < \ln((1-\beta)/\alpha)$ — minimise le temps de décision espéré à erreurs données ; c'est l'outil de la *production* qui doit trancher vivant/mort. Ses bornes chiffrent l'incompressible : distinguer IC = 0,03 de IC = 0 à 10% d'erreurs demande $E[T] \approx 90-110$ jours de bourse — quatre à cinq mois, et l'attente croît vite avec la sévérité exigée ou la finesse de la distinction (§6.3.2). Le corollaire pratique : les portes de promotion (§6.3.1) et les enterrements de signaux se calculent avec ces bandes — l'essentiel des « signaux morts » à trois mois étaient statistiquement indistinguables de vivants.

La décision sous test inachevé : les buckets à hystérésis (§3.1.3c). Puisque le test met des mois, le système de pondération doit *vivre avec l'incertitude* plutôt que l'attendre : trois niveaux de conviction, promotion si le t-stat posterior dépasse 2 de façon soutenue, rétrogradation seulement sous 1 — deux seuils distincts qui empêchent le va-et-vient coûteux d'un signal oscillant autour d'une frontière unique. La rétrogradation de bucket *est* le test séquentiel rendu décision : graduelle, réversible, auditable — et le même mécanisme d'hystérésis protège les tris du backtest (§2.2.4), les bandes de levier (§4.4.1) et les no-trade zones (§4.3.2).

L'adaptation sans détection : le fixed share (§3.3.3). L'alternative radicale : ne pas détecter du tout. $w \leftarrow (1-\alpha fs) \cdot w + \alpha fs/K$ — mélanger en permanence une fraction vers l'uniforme borne le regret contre le meilleur expert *par segments* : le suivi de régimes sans HMM, sans estimation de date de rupture, sans lag de détection. On paie une prime constante (la fraction diluée) pour ne jamais payer le coût d'une détection tardive — l'assurance contre les régimes, souscrite d'avance.

La leçon commune, en trois temps. *Le délai est une loi, pas un défaut* : il découle du ratio signal/bruit, et aucune sophistication ne le comprime en dessous de la borne de Wald. *La binarité est une erreur de design* : couper/garder, promouvoir/enterrer, lever/dé-lever — toute décision à deux états force à choisir entre trop tôt et trop tard ; la gradualité (buckets, paliers de kill switch §6.3.3, dégradation contrôlée) convertit l'incertitude résiduelle en exposition partielle, ce qui est exactement la réponse de l'encadré B à l'incertitude paramétrique. *Et la surveillance est un système, pas une vigilance* : CUSUM en recherche, SPRT en production, hystérésis en combinaison, fixed share en allocation — quatre instruments du même tableau de bord (§6.3.4), chacun réglé sur sa constante de temps.

Renvois : §0.3 (le bruit qui fonde tout) ; §2.4.1 (CUSUM, ARL) ; §3.1.3 (buckets-hystérésis), §3.3.3 (fixed share) ; §4.3.2, §4.4.1 (bandes) ; §6.3 (SPRT, PSI, kill switches gradués, tableau de bord) ; encadré B (l'exposition partielle comme réponse à l'incertitude).

Part V

Annexes

Chapter 34

Annexe — Table des notations

Source : §0.5 de `section_0_cadre_et_conventions.md` (complétée par l'en-tête du squelette v3). Cette table fait foi dans TOUTES les sections. Toute collision détectée pendant l'intégration se résout en faveur de cette table et se logge dans `AVANCEMENT.md`.

34.1 Symboles

Symbole	Signification
i, N	indice d'actif ; taille de l'univers à une date
t, T	indice de date ; longueur de l'historique
h	horizon de prédiction (en périodes)
H	demi-vie d'une pondération exponentielle (§1.2.2)
$\mathbf{F}_t$	filtration : information connaissable en t
$r_{i,t \rightarrow t+h}$	rendement de l'actif i entre t et $t+h$
$\alpha_{i,t}$	prévision (alpha) pour l'actif i en t
s_k	signal k après normalisation (moyenne 0, variance 1)
K	nombre de signaux dans le pool
ρ_k	IC du signal k
$\mathbf{C}$	matrice de corrélation entre signaux (§3)
$\mathbf{w}$	vecteur des poids de combinaison (§3)
$\beta_i, \mathbf{F}_{\text{fac}}$	expositions factorielles ; rendements des facteurs (§4.1)
$\varepsilon_{i,t}$	rendement résiduel (idiosyncratique)
σ	volatilité (contexte précisé localement)
λ	facteur de décroissance d'une EMA, $\lambda = \exp(-\ln 2 / H)$
κ	pénalité de régularisation (ridge, §3.2)
τ	dispersion vraie des IC dans le prior hiérarchique (§3.1.3)
B	facteur de shrinkage bayésien, $B = s^2 / (\tau^2 + s^2)$
φ	vitesse de decay de l'alpha , $\varphi = \ln 2 / H\alpha$ (mesurée en §2.1.2, transportée par l'interface §3.4.5)
IC, ICIR, IR, TC	cf. §0.3 et §0.4 (rank IC par date ; ICIR = $\text{moy}(\text{IC}) / \sigma(\text{IC})$; $\text{IR} \approx \text{TC} \cdot \text{IC} \cdot \sqrt{\text{BR}}$)

34.2 Collisions interdites (règles dures)

1. h désigne l'horizon et **jamais** une demi-vie (notée H).
2. λ désigne la décroissance exponentielle d'une EMA et **jamais** la pénalité ridge (notée κ).
3. φ désigne la vitesse de decay de l'alpha ($\varphi = \ln 2 / H\alpha$) ; ne pas le confondre avec le φ de la CPCV (§2.3, nombre de chemins $\varphi = kC(S,k)/S$) — préciser « φ (chemins CPCV) » à chaque occurrence de ce dernier.
4. C est la corrélation entre signaux (branche 3) ; Σ est la covariance entre actifs (branche 4). Ne jamais employer l'un pour l'autre.
5. σ est surchargé (vol d'actif, $\sigma(IC)$, σ_{cs} ...) : chaque occurrence précise son objet en indice ou dans le texte immédiat.

34.3 Conventions de calcul associées (rappel §0.6)

- Log-rendements pour l'agrégation temporelle, rendements simples en cross-section ; equity = rendements totaux ; crypto = **funding inclus**.
- Annualisation : $\sqrt{252}$ en equity, $\sqrt{365}$ en crypto — ne jamais mélanger.
- Knowledge time : jointures uniquement sur « connaissable à partir de » ; $close(t) \rightarrow$ exécution au plus tôt $open(t+1)$; horodatages crypto en UTC (grille funding 00/08/16).
- Univers point-in-time strict, sorties conservées avec rendement terminal.
- Signe de chaque signal fixé par prior économique, jamais par backtest.